

PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ

FACULTAD DE CIENCIAS E INGENIERÍA



**Desarrollo de agentes de inversión bursátiles mediante aprendizaje por
refuerzo y LLM con integración de información de mercado, estados
financieros y de noticias en la Bolsa de Valores de Lima**

Tesis para obtener el título profesional de Ingeniero Informático

AUTOR:

Rodrigo Alejandro Holguin Huari

ASESOR:

Dr. Edwin Rafael Villanueva Talavera

Lima, Abril, 2026

Resumen

(NO NECESARIO EN LOS CURSOS DE TESIS)

- La extensión debe ser de 200 a 300 palabras, sin exceder a una página.
- Escriba en tiempo verbal presente
- El resumen debe contener información sobre:
 - La justificación de la investigación
 - Los objetivos o hipótesis
 - La teoría o supuestos teóricos o metodológicos en la que se sustenta
 - El método o procedimiento realizado (de ser necesario)
 - Los resultados (de ser necesario)
 - La conclusión principal

Tema FCI

Aquí se debe colocar una copia del tema aprobado por el Decano de la FCI. No es necesario colocarlo durante los cursos de tesis.

Tabla de Contenido

Resumen	ii
Tema FCI	iii
Capítulo 1. Generalidades	6
1.1 Problemática.....	6
1.1.1 Árbol de Problemas	6
1.1.2 Descripción.....	7
1.1.3 Problema seleccionado	11
1.2 Objetivos.....	11
1.2.1 Objetivo general	11
1.2.2 Objetivos específicos	12
1.2.3 Resultados esperados	12
1.2.4 Mapeo de objetivos, resultados y verificación	14
1.3 Métodos y Procedimientos	16
Capítulo 2. Marco Legal/Regulatorio/Conceptual/otros	29
2.1 Introducción.....	29
2.2 Desarrollo del marco	29
Capítulo 3. Estado del Arte.....	40
3.1 Introducción.....	40
3.2 Objetivos de revisión.....	40
3.3 Preguntas de revisión.....	40
3.4 Estrategia de búsqueda.....	41
3.4.1 Motores de búsqueda a usar	41

3.4.2	Cadenas de búsqueda a usar	41
3.4.3	Documentos encontrados	41
3.4.4	Criterios de inclusión/exclusión	44
3.5	<i>Formulario de extracción de datos</i>	46
3.6	<i>Resultados de la revisión</i>	46
3.6.1	Respuesta a pregunta P1	¡Error! Marcador no definido.
3.6.2	Respuesta a pregunta P2	¡Error! Marcador no definido.
3.6.3	Respuesta a pregunta P3	¡Error! Marcador no definido.
3.7	<i>Conclusiones</i>	49
Capítulo 4.	Presentación de los resultados esperados	¡Error! Marcador no definido.
Capítulo 5.	Conclusiones y trabajos futuros	105
5.1	<i>Conclusiones</i>	105
5.2	<i>Trabajos futuros</i>	105
Referencias		106
Anexos		112
Anexo A: Plan de Proyecto		113

Capítulo 1. Generalidades

1.1 Problemática

La presente sección expone la problemática que motiva esta investigación a través de un análisis estructurado de las causas y efectos vinculados a la ausencia de evidencia empírica sobre el uso de agentes de deep reinforcement learning para la optimización de portafolios en la Bolsa de Valores de Lima. Para ello, se emplea la técnica del árbol de problemas, herramienta de diagnóstico que permite identificar el problema central junto con sus causas raíces y sus efectos observables, organizándolos de forma jerárquica y causal (Ortegón et al., 2005). A partir de dicho análisis, se presenta una descripción detallada del contexto que origina el problema identificado y, finalmente, se delimita el problema seleccionado que guiará el desarrollo de la investigación.

1.1.1 Árbol de Problemas

A continuación, se presenta el árbol de problemas de la investigación en la *Tabla 1*. Este esquema permite identificar las relaciones causales entre los problemas raíz, el problema central y los efectos observados, siguiendo una lógica de abajo hacia arriba.

Tabla 1. Árbol de problemas

Problemas efecto		
E1: Retornos ajustados al riesgo subóptimos para los inversionistas en la BVL frente a lo alcanzable con métodos adaptativos basados en inteligencia artificial.	E2: Baja adopción de estrategias cuantitativas y algorítmicas en el mercado bursátil peruano, lo que limita la competitividad de los gestores de portafolios locales.	E3: Brecha tecnológica creciente respecto a mercados donde el deep reinforcement learning ya se aplica con resultados favorables documentados.

Problema central Ausencia de evidencia empírica sobre el desempeño de agentes de deep reinforcement learning, entrenados con señales integradas de mercado, fundamentales y sentimiento, para la optimización dinámica de portafolios bajo las condiciones operativas propias de un mercado emergente como la Bolsa de Valores de Lima (altos costos de transacción, baja liquidez y alta concentración sectorial), las cuales impiden extrapolar directamente los resultados obtenidos en mercados desarrollados donde la técnica ya ha sido validada.		
Problemas causales		
C1: Las soluciones existentes de optimización de portafolios mediante DRL emplean entornos de simulación calibrados para mercados desarrollados o emergentes de alta capitalización, cuyos supuestos operativos (costos de transacción bajos, alta liquidez y diversificación sectorial amplia) no representan el entorno operativo ni las condiciones de la BVL.	C2: Existe información financiera diversa y potencialmente valiosa para el desarrollo de agentes de portafolios en la BVL (datos de mercado, indicadores fundamentales y noticias financieras locales), pero estas fuentes se encuentran dispersas y no han sido estructuradas ni integradas en un dataset unificado para su aprovechamiento por agentes DRL.	C3: Si bien diversos estudios han evaluado algoritmos DRL y combinaciones de señales de entrada en mercados desarrollados y algunos emergentes, no se ha realizado una evaluación comparativa que contraste el desempeño de estos algoritmos frente a estrategias tradicionales en la BVL, considerando distintas configuraciones de señales y múltiples métricas de desempeño (Sharpe ratio, Maximum Drawdown, retorno anualizado).

1.1.2 Descripción

La optimización de portafolios de inversión constituye un problema fundamental en las finanzas cuantitativas, donde el objetivo es determinar la asignación óptima de capital entre un conjunto de activos financieros para maximizar el retorno esperado sujeto a un nivel de riesgo aceptable. En años recientes, el interés por los métodos computacionales avanzados para abordar este problema ha crecido significativamente. Silva et al. (2025) realizaron una revisión sistemática que documenta el creciente número de investigaciones que aplican deep

reinforcement learning (DRL) a la gestión de portafolios, en el contexto del mercado brasileño. En este contexto, la Bolsa de Valores de Lima (BVL) representa un caso de estudio relevante como mercado emergente latinoamericano, caracterizado por su baja capitalización relativa, alta concentración en pocos emisores y volúmenes de negociación limitados en comparación con mercados desarrollados.

Los modelos clásicos de optimización de portafolios, como el modelo de media-varianza de Markowitz y las estrategias de Buy & Hold (B&H), asumen condiciones de mercado estáticas y distribuciones de retornos estacionarias, lo cual no refleja la dinámica real de los mercados financieros. Huang et al. (2025) demostraron que las 24 estrategias basadas en modelos tradicionales evaluados (incluyendo media-varianza, Conditional Value at Risk, Risk Parity, Hierarchical Risk Parity, Hierarchical Equal Risk Contribution y Nested Clustering Optimization) producen resultados homogéneos y no capturan adecuadamente la dinámica de ajuste de pesos necesaria en la operación real de portafolios. Santos et al. (2023) compararon cinco algoritmos de reinforcement learning contra las estrategias de mínima varianza (MINVAR) y B&H en un portafolio multi-mercado que incluía acciones brasileñas, mostrando que los agentes RL incrementaron el retorno promedio en un 12% sin un aumento proporcional del riesgo, con significancia estadística confirmada mediante el test de Ledoit-Wolf.

La evidencia acumulada en la literatura demuestra el potencial del DRL para superar a las estrategias tradicionales en diversos mercados. Huang et al. (2025) lograron un Sharpe ratio de 1.555 con Proximal Policy Optimization (PPO) frente a 1.229 del mejor modelo tradicional (CVaR-MinRisk) en el mercado chino. En mercados emergentes, Candar y Üstündağ (2022) reportaron un Sharpe ratio de 1.592 usando el algoritmo PPO en el índice BIST30 de Turquía, superando ampliamente al benchmark del mercado. Conegundes y Pereira (2020) alcanzaron un retorno acumulado de 311% en tres años utilizando Deep Deterministic Policy Gradient (DDPG) en la B3 de Brasil, superando tanto al Ibovespa (92.1%) como al mejor portafolio

institucional recomendado (176.6%). Estos resultados sugieren que los agentes DRL pueden adaptarse a las dinámicas cambiantes del mercado de manera más efectiva que los métodos estáticos convencionales.

No obstante, la mayor parte de la evidencia favorable al DRL proviene de mercados desarrollados, particularmente de Estados Unidos y China. Silva et al. (2025) identificaron en su revisión sistemática que no existen estudios que integren DRL con análisis de noticias en idiomas locales e indicadores fundamentales para mercados latinoamericanos. Los únicos estudios en mercados emergentes de la región identificados en la presente revisión corresponden a Brasil (Conegundes & Pereira, 2020; Silva et al., 2025; Santos et al., 2023) y Vietnam (Nguyen et al., 2022). Ningún estudio aborda la BVL ni otros mercados andinos. Esta brecha es particularmente relevante porque los resultados obtenidos en otros mercados no son directamente transferibles a la BVL, dadas las diferencias estructurales en términos de liquidez, costos de transacción, concentración sectorial y profundidad del mercado. Esta falta de representatividad de estudios aplicados al contexto del mercado peruano se ilustra en la *Figura 1* y *Figura 2*, tras realizar la búsqueda con las cadenas presentadas en el “Capítulo 3. Estado del Arte”.




Figura 1. Distribución de trabajos por país de estudio [obtenido de los resultados de búsqueda en Scopus]




Figura 2. Distribución de trabajos por país de estudio [obtenido de los resultados de búsqueda en Web of Science]

A esta ausencia de estudios se suma una limitación metodológica: los entornos de simulación empleados en la literatura (como FinRL y variantes basadas en OpenAI Gym, que se presentarán posteriormente en el “Capítulo 3. Estado del Arte”) están calibrados bajo supuestos de baja fricción y alta liquidez propios de mercados como el NYSE o el SSE de China. En la BVL, las comisiones de intermediación, el bajo volumen de negociación y la concentración en un número reducido de emisores del sector minero y financiero configuran condiciones operativas que dichos entornos no parametrizan, lo que impide evaluar de forma válida el desempeño de agentes DRL en el mercado peruano.

Por otra parte, un aspecto adicional que limita el desarrollo de agentes DRL para la BVL es la dispersión de las fuentes de información disponibles. Mientras los datos de precios (OHLCV – Open, High, Low, Close, Volume) son accesibles mediante plataformas como Yahoo Finance, los indicadores fundamentales de las empresas listadas en la BVL requieren consultas a fuentes locales como la Superintendencia del Mercado de Valores, y las noticias financieras relevantes en español se encuentran dispersas en múltiples portales. Candar y Üstündağ (2022) demostraron la utilidad de incorporar indicadores fundamentales (price-to-book ratio, price-to-sale ratio) como entrada del modelo, y Silva et al. (2025) identificaron que la integración de sentimiento de noticias con datos fundamentales mejora el control de riesgo. Sin embargo, la

combinación estructurada de estas tres fuentes (mercado, fundamentales y sentimiento en idioma local) no ha sido desarrollada para la BVL, limitando la capacidad de los agentes para aprovechar información valiosa que actualmente permanece sin explotar.

En síntesis, la BVL presenta condiciones estructurales que dificultan el manejo eficiente de portafolios, y aunque los agentes DRL han emergido como una alternativa promisorio en otros mercados, no existe evidencia empírica de su desempeño en este contexto específico. Esta situación se origina en tres causas concretas: la inexistencia de un entorno de simulación adaptado a las condiciones de la BVL (C1), la dispersión y falta de integración de las fuentes de información relevantes (C2), y la ausencia de una evaluación comparativa de algoritmos y configuraciones de señales en este mercado (C3). La presente investigación busca abordar estas tres causas de manera integral.

1.1.3 Problema seleccionado

El problema seleccionado para esta investigación es la falta de evidencia empírica sobre el desempeño de agentes de deep reinforcement learning para la optimización de portafolios en la BVL. Las características propias de este mercado emergente (altos costos de transacción, baja liquidez y alta concentración) impiden extrapolar resultados de otros mercados. Se requiere, por tanto, desarrollar un entorno de simulación adaptado, construir un dataset integrado con múltiples fuentes de información, y realizar una evaluación comparativa rigurosa de algoritmos y configuraciones de señales.

1.2 Objetivos

1.2.1 Objetivo general

Generar evidencia empírica sobre la viabilidad e idoneidad de agentes de deep reinforcement learning para la optimización dinámica de portafolios en la BVL, integrando señales de

mercado, indicadores fundamentales y análisis de sentimiento, a fin de proveer una base informada para la toma de decisiones de inversión.

1.2.2 Objetivos específicos

O 1. Diseñar e implementar un entorno de simulación para optimización de portafolios que represente las condiciones operativas de la BVL.

O 2. Construir un dataset unificado para la BVL mediante la implementación de pipelines de extracción, procesamiento e integración de datos de mercado, indicadores fundamentales y scores de sentimiento derivados de noticias financieras locales.

O 3. Evaluar comparativamente el desempeño de algoritmos DRL (PPO, DDPG, SAC) frente a estrategias tradicionales (Markowitz, Buy & Hold, Equal Weight) en la BVL, bajo distintas configuraciones de señales de entrada y métricas de desempeño (Sharpe ratio, Maximum Drawdown, retorno anualizado).

1.2.3 Resultados esperados

O 1. Diseñar e implementar un entorno de simulación para optimización de portafolios que represente las condiciones operativas de la BVL.

Resultado 1. Informe de aplicación de la metodología CRISP-DM para el diseño del entorno de simulación de la BVL (comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación e implementación).

Resultado 2. Entorno de simulación implementado que incorpore las condiciones operativas de la BVL (costos de transacción, restricciones de liquidez, universo de activos del mercado peruano).

O 2. Construir un dataset unificado para la BVL mediante la implementación de pipelines de extracción, procesamiento e integración de datos de mercado, indicadores fundamentales y scores de sentimiento derivados de noticias financieras locales.

Resultado 3. Pipeline funcional de recopilación y procesamiento de datos de mercado (OHLCV e indicadores técnicos) para el universo de activos seleccionado de la BVL.

Resultado 4. Pipeline de extracción de indicadores fundamentales trimestrales de empresas listadas en la BVL.

Resultado 5. Pipeline de recopilación de noticias financieras en español y generación de scores de sentimiento diarios mediante API de modelo de lenguaje de gran escala.

Resultado 6. Dataset unificado que integre las tres fuentes de señales (mercado, fundamentales, sentimiento) en un formato consumible por el entorno de simulación.

O 3. Evaluar comparativamente el desempeño de algoritmos DRL (PPO, DDPG, SAC) frente a estrategias tradicionales (Markowitz, Buy & Hold, Equal Weight) en la BVL, bajo distintas configuraciones de señales de entrada y métricas de desempeño (Sharpe ratio, Maximum Drawdown, retorno anualizado).

Resultado 7. Agentes DRL entrenados con los algoritmos PPO, DDPG y SAC en el entorno de la BVL.

Resultado 8. Estudio comparativo de desempeño entre agentes DRL y estrategias baseline (Markowitz, Buy & Hold, Equal Weight) bajo cuatro configuraciones de señales de entrada (solo mercado; mercado + sentimiento; mercado + fundamentales; combinación completa), evaluado con Sharpe ratio, Maximum Drawdown y retorno anualizado.

1.2.4 Mapeo de objetivos, resultados y verificación

Tabla 2. Mapeo de objetivos, resultados esperados y verificación

Resultado esperado	Medio de verificación	Indicador objetivamente verificable	Herramientas o métodos
OE1: Diseñar e implementar un entorno de simulación que represente las condiciones de la BVL			
R1: Informe de metodología CRISP-DM	Documento escrito con las seis fases de CRISP-DM desarrolladas.	Las seis fases de CRISP-DM se encuentran documentadas e incluyen, como mínimo: la definición del problema, el inventario y diagnóstico de las fuentes de datos disponibles para la BVL, los criterios de éxito y el plan de diseño del entorno de simulación.	Métodos: - CRISP-DM
R2: Entorno de simulación implementado	Código fuente del entorno en repositorio; pruebas unitarias ejecutadas	El entorno ejecuta episodios completos con costos de transacción, restricciones de liquidez y universo de activos de la BVL sin errores	Métodos: - CRISP-DM Herramientas: - Python - OpenAI Gym - FinRL - Stable-Baselines3
OE2: Construir un pipeline de integración de datos multi-fuente para la BVL			
R3: Pipeline de datos de mercado	Código fuente; estadísticas descriptivas del dataset de precios	Dataset de precios de cierre diarios con al menos 5 años de cobertura para el universo seleccionado, sin valores faltantes significativos	Herramientas: - API BVL - Pandas - Numpy
R4: Pipeline de indicadores fundamentales	Código fuente; muestra de datos extraídos validados manualmente	Indicadores fundamentales trimestrales (ROE, ROA, margen neto, deuda/patrimonio y deuda/activo) disponibles para el período de estudio	Herramientas: - API SMV - Pandas

Resultado esperado	Medio de verificación	Indicador objetivamente verificable	Herramientas o métodos
R5: Pipeline de sentimiento	Código fuente; métricas de calidad de clasificación en muestra manual	Scores de sentimiento diarios generados para el período de estudio con concordancia aceptable respecto a etiquetado manual	Métodos: - Procesamiento de lenguaje natural Herramientas: - API de Mediacloud - Modelo de lenguaje local - Python
R6: Dataset unificado	Archivo consolidado; diccionario de datos; estadísticas descriptivas	Dataset integrado con las tres fuentes de señales alineadas temporalmente, listo para consumo por el entorno de simulación	Herramientas: - Pandas - Numpy
OE3: Evaluar comparativamente algoritmos DRL bajo distintas configuraciones de señales			
R7: Agentes DRL entrenados (PPO, DDPG, SAC)	Curvas de entrenamiento; modelos almacenados	Convergencia estable de las curvas de recompensa en al menos 3 semillas por algoritmo	Métodos: - DRL Herramientas: - Pytorch - Stable-Baselines3 - FinRL
R8: Estudio comparativo bajo múltiples configuraciones	Tablas comparativas tipo escenario × algoritmo × métrica; pruebas estadísticas	Métricas (Sharpe, MDD, retorno anualizado) calculadas para cada combinación de algoritmo, configuración de señales y baseline, con intervalos de confianza	Métodos: - Backtesting walk-forward Herramientas: - Matplotlib - Seaborn

1.3 Métodos y Procedimientos

En esta sección se describen las herramientas, bibliotecas y métodos que se emplearán para la consecución de los resultados esperados detallados en la sección anterior. Cada herramienta se presenta con su definición, su justificación dentro del proyecto y una referencia a la literatura que respalda su uso.

1.3.1 CRISP-DM

El Cross-Industry Standard Process for Data Mining (CRISP-DM) es un marco metodológico ampliamente adoptado para la conducción de proyectos de ciencia de datos y minería de datos, propuesto originalmente por Chapman et al. (2000) como un proceso iterativo, independiente del dominio, la herramienta y la técnica empleadas. Una revisión sistemática reciente confirma a CRISP-DM como el modelo de proceso predominante en proyectos de aprendizaje automático y analítica avanzada, con aplicación documentada en finanzas, manufactura, salud y otros dominios (Schröer et al., 2021).

CRISP-DM organiza el ciclo de vida de un proyecto en seis fases interrelacionadas: (i) comprensión del negocio, en la que se traducen los objetivos del proyecto a objetivos analíticos y se definen los criterios de éxito; (ii) comprensión de los datos, que comprende la recopilación, descripción y exploración inicial de las fuentes disponibles; (iii) preparación de los datos, fase que abarca la limpieza, integración y construcción del dataset final de modelado; (iv) modelado, en la que se seleccionan y entrenan las técnicas analíticas; (v) evaluación, en la que se verifica que los modelos satisfagan los objetivos planteados; y (vi) despliegue, en la que los resultados se entregan en una forma utilizable para los usuarios finales (Chapman et al., 2000). El proceso es iterativo: los hallazgos de una fase pueden requerir el retorno a una fase anterior, propiedad especialmente valiosa en problemas donde la calidad y disponibilidad de los datos son heterogéneas (Schröer et al., 2021).

En la presente investigación, CRISP-DM constituye la metodología estructurante para el diseño e implementación del entorno de simulación de la BVL (OE1, R1). Esta elección se justifica porque el desarrollo del entorno requiere integrar fuentes de datos heterogéneas (mercado, fundamentales y sentimiento) en un dataset unificado, etapas que encajan directamente con las fases de comprensión y preparación de datos del marco. Adicionalmente, su naturaleza iterativa permite refinar el diseño del entorno y las señales de entrada a medida que se identifican limitaciones en las fuentes locales, y ajustar los criterios de éxito del experimento comparativo (R8) en función de los hallazgos de las fases tempranas.

1.3.2 Python

Python es un lenguaje de programación de alto nivel, interpretado y de propósito general, ampliamente adoptado en los campos de la ciencia de datos, el aprendizaje automático y las finanzas cuantitativas (Python Software Foundation, n.d.). Se caracteriza por una sintaxis clara y legible, una tipificación dinámica y una extensa comunidad de desarrollo que ha producido un ecosistema maduro de bibliotecas científicas de código abierto (McKinney, 2017).

En el dominio del aprendizaje por refuerzo profundo aplicado a finanzas, Python se ha consolidado como el lenguaje de referencia debido a la disponibilidad de frameworks especializados que exponen sus interfaces en este lenguaje (Liu et al., 2021). En la presente investigación, Python constituye el lenguaje principal utilizado para la implementación del entorno de simulación, los pipelines de datos, el entrenamiento de los agentes DRL y la generación de análisis comparativos. Las bibliotecas específicas empleadas para cada tarea se describen en las subsecciones siguientes.

1.3.3 PyTorch

PyTorch es una biblioteca de aprendizaje profundo de código abierto desarrollada por Facebook AI Research que proporciona un framework basado en tensores con capacidad de

diferenciación automática y soporte para aceleración por GPU (Paszke et al., 2019). Su diseño enfatiza una interfaz imperativa y pythónica que facilita la depuración y la experimentación, al tiempo que ofrece un rendimiento competitivo con otras bibliotecas de aprendizaje profundo.

En el presente proyecto, PyTorch se utiliza como framework subyacente a Stable-Baselines3 para la definición y el entrenamiento de las redes neuronales que componen los agentes DRL (actor y critic). La elección de PyTorch se justifica por su adopción mayoritaria en la comunidad de reinforcement learning y por ser la base sobre la que se construye la biblioteca Stable-Baselines3 empleada en la tesis (Raffin et al., 2021).

1.3.4 Pandas

Pandas es una biblioteca de Python para el análisis y la manipulación de datos estructurados, que introduce las estructuras de datos DataFrame y Series como abstracciones de alto nivel sobre arreglos numéricos (McKinney, 2010). Está diseñada específicamente para trabajar con datos tabulares y series temporales, funcionalidades altamente relevantes en el contexto del análisis financiero.

En el proyecto, Pandas se emplea en todas las etapas de manipulación de datos: lectura y consolidación de datos de mercado desde las APIs, cálculo de indicadores técnicos, gestión de los indicadores fundamentales trimestrales con propagación hacia adelante (forward-fill), integración temporal de los scores de sentimiento, y construcción del dataset unificado que alimenta al entorno de simulación. Su capacidad para manejar índices temporales y realizar operaciones de ventana (rolling) resulta fundamental para la implementación del backtesting con walk-forward validation.

1.3.5 NumPy

NumPy es la biblioteca fundamental para la computación científica en Python, que proporciona un objeto de arreglo multidimensional eficiente junto con un conjunto completo de operaciones

matemáticas optimizadas (Harris et al., 2020). Constituye la base sobre la cual se construyen muchas de las bibliotecas de mayor nivel en el ecosistema científico de Python, incluyendo Pandas y PyTorch.

En el proyecto, NumPy se utiliza para operaciones numéricas de bajo nivel, como el cálculo vectorizado de métricas de desempeño (Sharpe ratio, Maximum Drawdown, retorno anualizado), la generación de semillas aleatorias para la reproducibilidad de los experimentos, y la manipulación de los arreglos que componen los vectores de estado del entorno de simulación. Su eficiencia en operaciones vectorizadas es crítica para el rendimiento del ciclo de entrenamiento de los agentes DRL.

1.3.6 OpenAI Gym

OpenAI Gym es un toolkit de código abierto para el desarrollo y la comparación de algoritmos de aprendizaje por refuerzo (Brockman et al., 2016). Define una interfaz estandarizada entre agentes y entornos mediante un conjunto reducido de métodos (reset, step, observation_space, action_space), lo cual ha permitido que esta interfaz se haya convertido en un estándar de facto en la investigación de RL.

En la presente investigación, OpenAI Gym se emplea como base para la construcción del entorno de simulación personalizado para la BVL. El entorno implementado seguirá la interfaz Gym, lo que garantiza su compatibilidad con Stable-Baselines3 y con otros frameworks del ecosistema RL. Esta decisión facilita la reproducibilidad de los experimentos y permite que futuras extensiones de la investigación puedan aprovechar herramientas adicionales compatibles con el mismo estándar.

1.3.7 FinRL

FinRL es un framework de código abierto especializado en la aplicación de deep reinforcement learning a la gestión cuantitativa de portafolios y al trading automatizado, desarrollado por Liu

et al. (2020, 2021). Organizado en una arquitectura de tres capas (entorno, agente y aplicación), FinRL integra componentes para la descarga y preprocesamiento de datos de mercado, el entrenamiento de agentes DRL con algoritmos estándar y la evaluación mediante backtesting, incorporando además restricciones realistas como costos de transacción, liquidez de mercado y niveles de aversión al riesgo.

En el proyecto, FinRL se utilizará como base del entorno de simulación para la BVL, adaptando sus componentes para reflejar las condiciones operativas del mercado peruano. Santos et al. (2023) emplearon FinRL con éxito en un portafolio multi-mercado que incluía acciones brasileñas, demostrando la viabilidad del framework en contextos que abarcan mercados emergentes latinoamericanos. Silva et al. (2025) también utilizaron FinRL con el entorno StockPortfolioEnv para su estudio en la B3 de Brasil, validando su aplicabilidad al problema específico de esta tesis.

1.3.8 Stable-Baselines3

Stable-Baselines3 (SB3) es una biblioteca de código abierto que proporciona implementaciones confiables de algoritmos de deep reinforcement learning en PyTorch, incluyendo PPO, DDPG, SAC, A2C y TD3 (Raffin et al., 2021). Sus implementaciones han sido validadas contra códigos de referencia y cuentan con pruebas unitarias que cubren el 95% del código, garantizando un alto nivel de calidad y reproducibilidad.

En la presente investigación, SB3 se emplea como la biblioteca principal para el entrenamiento de los tres algoritmos DRL seleccionados. La interfaz consistente de SB3 entre algoritmos facilita la comparación experimental bajo las mismas condiciones del entorno, y su integración nativa con entornos compatibles con OpenAI Gym permite utilizar directamente el entorno de simulación construido para la BVL.

1.3.9 Deep Reinforcement Learning: enfoque metodológico y algoritmos

El deep reinforcement learning (DRL) es un paradigma del aprendizaje automático que combina los principios del reinforcement learning (RL) clásico con las capacidades de representación de las redes neuronales profundas (Sutton & Barto, 2018; Mnih et al., 2015). El RL formula la toma de decisiones secuenciales como un Proceso de Decisión de Markov (MDP), en el que un agente aprende (mediante interacción con un entorno) una política que mapea estados a acciones con el objetivo de maximizar la recompensa esperada acumulada. El uso de redes neuronales como aproximadores de función permite generalizar a espacios de estados de alta dimensionalidad y manejar espacios de acciones continuos, condiciones ambas presentes en el problema de optimización dinámica de portafolios. Las definiciones formales del MDP, así como su instanciación al problema de gestión de portafolios, se desarrollan en el Marco Conceptual (sección 2.8).

Desde el punto de vista metodológico, los algoritmos de DRL se clasifican habitualmente según tres criterios complementarios (Arulkumaran et al., 2017; Sutton & Barto, 2018). En primer lugar, según el uso de un modelo del entorno, se distinguen los métodos model-based, que aprenden o emplean un modelo explícito de las transiciones, y los métodos model-free, que aprenden directamente de la experiencia recogida durante la interacción; en problemas financieros, donde la dinámica subyacente del mercado es desconocida y no estacionaria, los enfoques model-free son los predominantes. En segundo lugar, según el objeto de aprendizaje, los algoritmos se agrupan en métodos value-based (como Q-learning y DQN), policy-based (como REINFORCE) y actor-critic, que combinan ambos enfoques empleando una red para representar la política (actor) y otra para estimar el valor (critic). En tercer lugar, según la relación entre la política que genera la experiencia y la política que se optimiza, se diferencian los métodos on-policy, que utilizan únicamente datos generados por la política actual, y los

métodos off-policy, que pueden reutilizar experiencia previa almacenada en un buffer de repetición.

Para la optimización de portafolios, en la que el vector de acciones (los pesos del portafolio) es continuo y de dimensionalidad igual al número de activos, los métodos actor-critic resultan particularmente apropiados, ya que permiten aprender directamente políticas en espacios continuos sin requerir discretización del espacio de acciones (Sutton & Barto, 2018). Adicionalmente, la incorporación de un crítico que estima la función de valor reduce la varianza de las actualizaciones del gradiente de política y, en consecuencia, mejora la estabilidad del entrenamiento respecto a los métodos puramente basados en política. Con base en estos criterios y en la prevalencia documentada en la literatura de DRL para portafolios (presentada en el Capítulo 3. Estado del Arte), se seleccionaron para la comparación experimental tres algoritmos actor-critic de naturaleza complementaria: Proximal Policy Optimization (PPO), de carácter on-policy, y Deep Deterministic Policy Gradient (DDPG) y Soft Actor-Critic (SAC), ambos off-policy. Esta selección cubre las dos principales subfamilias actor-critic, lo cual permite contrastar la eficiencia de muestra y la estabilidad de entrenamiento entre enfoques on-policy y off-policy en el contexto operativo específico de la BVL.

Deep Deterministic Policy Gradient (DDPG) es un algoritmo off-policy propuesto por Lillicrap et al. (2016) que extiende el aprendizaje Q a espacios de acciones continuos mediante una política determinista, redes objetivo y un buffer de repetición de experiencia; fue empleado en 10 estudios revisados. Soft Actor-Critic (SAC) es un algoritmo off-policy propuesto por Haarnoja et al. (2018) que maximiza conjuntamente el retorno esperado y la entropía de la política, fomentando la exploración y produciendo políticas más robustas ante la incertidumbre. Estos tres algoritmos cubren las dos principales familias de métodos actor-critic (on-policy y off-policy), lo cual permite una comparación balanceada de enfoques complementarios.

1.3.10 Procesamiento de Lenguaje Natural (PLN)

El procesamiento de lenguaje natural (PLN) es la disciplina de la inteligencia artificial dedicada al diseño de sistemas computacionales capaces de interpretar, generar y razonar sobre el lenguaje humano (Jurafsky & Martin, 2025). Sus fundamentos conceptuales y la caracterización de la tarea específica de análisis de sentimiento financiero, central para esta investigación, se desarrollan en el Marco Conceptual (sección 2.2.8). Desde una perspectiva metodológica, la incorporación de señales de sentimiento al vector de estado del agente DRL requiere la implementación de un pipeline de PLN compuesto por una secuencia de etapas que transforman texto en bruto en señales numéricas alineadas temporalmente con los demás datos del entorno.

El pipeline metodológico empleado en este trabajo se estructura en las siguientes etapas:

1. Recopilación de noticias. Extracción automatizada de noticias financieras en español publicadas por portales locales, restringida al universo de activos seleccionado y al horizonte temporal de estudio.
2. Preprocesamiento. Asociación de cada noticia al emisor correspondiente, normalización del texto y filtrado por relevancia y fecha de publicación.
3. Clasificación de sentimiento. Inferencia de la polaridad (positiva, negativa o neutral) de cada noticia mediante un modelo de lenguaje de gran escala (LLM) ejecutado localmente (Ollama, gemma3:4b), bajo un esquema de clasificación zero-shot. Este enfoque aprovecha las capacidades emergentes de comprensión y razonamiento de los LLMs sin requerir un dataset etiquetado del dominio (Brown et al., 2020; Liu et al., 2024).

4. Agregación temporal. Cálculo de un score diario de sentimiento por activo a partir de la polaridad de las noticias publicadas en cada día, tomando como referencia el procedimiento descrito por Du et al. (2024).
5. Integración al estado. Incorporación del score como señal adicional en el vector de estado del entorno DRL, alineado temporalmente con los datos de mercado y los indicadores fundamentales.
6. Validación. Contraste del desempeño del clasificador respecto a una muestra de noticias etiquetadas manualmente, mediante métricas estándar de clasificación (concordancia, F1 macro).

La elección de un esquema basado en LLM frente a alternativas tradicionales (léxicos especializados o modelos discriminativos como FinBERT) responde a tres consideraciones metodológicas: el carácter zero-shot del clasificador elimina la necesidad de construir un dataset etiquetado en español del dominio financiero peruano; la comprensión contextual multilingüe del modelo permite operar sobre noticias en español sin pasos adicionales de traducción o adaptación; y el enfoque ha sido ya validado en mercados emergentes con resultados competitivos (Silva et al., 2025). Las herramientas y bibliotecas específicas que soportan este pipeline se describen en las subsecciones siguientes.

1.3.11 API de la SMV y la BVL para datos de mercado y fundamentales

Una Application Programming Interface (API) es un conjunto de reglas, protocolos y definiciones que permite a dos aplicaciones de software comunicarse entre sí para intercambiar datos, funcionalidades y servicios (IBM, 2024). Las APIs operan habitualmente bajo un modelo cliente-servidor: el cliente envía una solicitud estructurada al servidor y recibe una respuesta en formatos como JSON o XML. En la presente investigación, las APIs constituyen el mecanismo principal para la obtención estructurada y reproducible de las fuentes de datos que

alimentan los pipelines de integración, lo que evita la recolección manual y permite la actualización periódica del dataset unificado.

La Superintendencia del Mercado de Valores (SMV) es el organismo regulador del mercado de valores peruano y publica información de los emisores que cotizan en la BVL, incluyendo estados financieros trimestrales y hechos de importancia. La Bolsa de Valores de Lima (BVL), por su parte, provee acceso a datos históricos de cotizaciones y volúmenes de negociación de los instrumentos listados. Ambas entidades exponen interfaces de acceso a la información que permiten consultas programáticas.

En el proyecto, el precio de cierre diario se obtiene de la API de la BVL y los indicadores fundamentales trimestrales (ROE, ROA, margen neto, deuda/patrimonio, deuda/activo) se extraen del web service SOAP de la SMV. Esta elección es coherente con las recomendaciones de trabajos previos en mercados emergentes, como el de Silva et al. (2025), quienes utilizaron fuentes locales (Status Invest, en el caso de Brasil) para acceder a datos fundamentales con historial completo del mercado objetivo. La tercera API empleada en la investigación (la asociada al modelo de lenguaje de gran escala para la clasificación de sentimiento) se describe en la subsección siguiente.

1.3.12 API de Media Cloud

Media Cloud es una plataforma de código abierto para la recopilación y el estudio de ecosistemas de noticias en la web abierta, en operación por más de una década y mantenida por un consorcio académico (Universidad de Harvard, MIT y Northeastern University), que expone una API abierta y un directorio de fuentes organizadas en colecciones nacionales y temáticas (Roberts et al., 2021). A diferencia de los repositorios comerciales de noticias, que suelen estar limitados por costo, cobertura geográfica y diversidad lingüística, Media Cloud ofrece acceso

gratuito y una amplia cobertura internacional, incluyendo medios en idiomas distintos del inglés (Roberts et al., 2021).

En el proyecto, la API de Media Cloud es la fuente de las noticias financieras en español del mercado peruano. Para cada empresa del universo se construye una consulta booleana que combina los nombres y alias del emisor con un vocabulario de anclaje financiero, acotada a la colección nacional de Perú y filtrada a un conjunto de medios económicos de referencia. Cada noticia recuperada conserva su identificador, fecha de publicación, medio, título y URL, que constituyen la entrada del pipeline de clasificación de sentimiento descrito en la subsección siguiente. Conviene anotar una limitación de la fuente relevante para esa etapa: la operación de listado de la API no devuelve el cuerpo del artículo, por lo que la clasificación opera sobre el titular.

1.3.13 Modelo de lenguaje local

Los modelos de lenguaje de gran escala (Large Language Models, LLMs) son modelos de aprendizaje profundo entrenados sobre grandes volúmenes de texto que han demostrado capacidades sobresalientes para la comprensión contextual del lenguaje natural en contextos *zero-shot*, sin requerir entrenamiento específico por tarea (Nie et al., 2024). Si bien los LLMs comerciales como Claude, GPT o Gemini son accesibles mediante APIs de pago, también existe una familia creciente de modelos de pesos abiertos que pueden ejecutarse de forma local; en particular, Gemma 3 es una familia de modelos abiertos y ligeros de Google DeepMind, cuya variante de 4 000 millones de parámetros (gemma3:4b) alcanza un desempeño competitivo con modelos considerablemente mayores y ofrece capacidades multilingües mejoradas (Gemma Team, 2025). La ejecución local de estos modelos se gestiona con Ollama, una herramienta de código abierto que simplifica la descarga, la administración y el servicio de LLMs en la máquina del usuario mediante una API local (Ollama, n.d.).

En el proyecto, la clasificación de sentimiento de las noticias recopiladas se realiza con el modelo `gemma3:4b` servido localmente mediante Ollama, bajo un esquema de clasificación *zero-shot*. Cada titular se envía al modelo junto con un *prompt* de clasificación que solicita una etiqueta de polaridad (positiva, negativa o neutral) en formato estructurado, y los resultados por noticia se agregan a un *score* de sentimiento diario por activo. La elección de un LLM frente a alternativas tradicionales como los léxicos especializados o los modelos discriminativos tipo FinBERT se fundamenta en que el enfoque generativo *zero-shot* no requiere construir un *dataset* etiquetado en español del dominio financiero peruano y aprovecha la comprensión contextual multilingüe ya incorporada en el modelo (Liu et al., 2024); este tipo de enfoque ha mostrado superar a los métodos clásicos en la tarea de análisis de sentimiento de noticias financieras (Teles & Figueiredo, 2025). La decisión de ejecutarlo localmente, en lugar de consumir una API comercial, responde además a consideraciones de costo y autonomía: el procesamiento del corpus completo se realiza sin costo por consumo de API ni dependencia de un servicio externo, manteniendo los datos en la máquina del proyecto (Ollama, n.d.).

1.3.14 Matplotlib

Matplotlib es una biblioteca de Python para la generación de gráficos en dos dimensiones con calidad de publicación, desarrollada originalmente por Hunter (2007). Soporta múltiples formatos de salida y proporciona una interfaz de bajo nivel que permite un control detallado sobre cada elemento de la figura, lo que la convierte en la base sobre la que se construyen otras bibliotecas de visualización de mayor nivel.

En el proyecto, Matplotlib se emplea para la generación de gráficos del estudio comparativo de desempeño (R7), incluyendo curvas de evolución del valor del portafolio, gráficos de drawdown y curvas de aprendizaje de los agentes DRL. Su integración con Pandas facilita la visualización directa de series temporales a partir de DataFrames.

1.3.15 Seaborn

Seaborn es una biblioteca de visualización estadística en Python basada en Matplotlib, que proporciona una interfaz de alto nivel orientada a conjuntos de datos (Waskom, 2021). Está diseñada para simplificar la creación de gráficos estadísticos complejos y se integra estrechamente con las estructuras de datos de Pandas, permitiendo traducir preguntas sobre los datos en gráficos de manera declarativa.

En el proyecto, Seaborn se utiliza para la generación de visualizaciones estadísticas del estudio comparativo, como mapas de calor (heatmaps) que muestran el desempeño por escenario $\times$ algoritmo $\times$ métrica, diagramas de caja (boxplots) para la comparación de distribuciones de resultados entre múltiples semillas, y gráficos de correlación entre las distintas señales de entrada del dataset unificado.

1.3.16 Backtesting con walk-forward validation

El backtesting es el proceso de evaluar una estrategia de inversión utilizando datos históricos para estimar su desempeño en condiciones pasadas. La walk-forward validation, propuesta por Pardo (2008), es una metodología de backtesting que divide los datos en múltiples ventanas temporales, utilizando cada ventana para optimización in-sample y la ventana siguiente para evaluación out-of-sample. Este enfoque se considera el estándar de referencia en la validación de estrategias cuantitativas, dado que mitiga el sobreajuste y simula el proceso iterativo real de recalibración de modelos en entornos de trading (Pardo, 2008).

En la presente investigación, la walk-forward validation se implementará con un esquema de rolling window, siguiendo un enfoque análogo al de Nguyen et al. (2022), quienes emplearon reentrenamiento trimestral del agente con selección del mejor modelo por Sharpe ratio en la ventana de validación. Este esquema se ejecutará con múltiples semillas para asegurar la robustez estadística de la comparación entre algoritmos y configuraciones de señales.

Capítulo 2. Marco Conceptual

2.1 Introducción

El presente capítulo establece las bases conceptuales necesarias para comprender los componentes teóricos y metodológicos sobre los que se sustenta el desarrollo de agentes de inversión bursátiles mediante aprendizaje por refuerzo profundo (DRL) en la Bolsa de Valores de Lima (BVL). Las definiciones presentadas no constituyen una revisión exhaustiva de cada disciplina, sino una selección orientada a equipar al lector con los elementos indispensables para interpretar el problema de investigación, las decisiones de diseño del entorno de simulación y los criterios de evaluación del estudio comparativo.

La organización refleja la articulación entre los conceptos y los objetivos específicos de la investigación. La sección 2.2.1 introduce los mercados financieros como contexto general; la sección 2.2.2 caracteriza los mercados emergentes y la BVL, dado que sus particularidades justifican la necesidad de una validación local (OE1, OE3). La sección 2.2.3 define el portafolio de inversión como objeto de gestión, mientras que la 2.2.4 presenta las estrategias tradicionales que conforman los benchmarks comparativos (OE3). Las secciones 2.2.5 y 2.2.6 introducen las medidas de riesgo y las métricas de desempeño con las que se evaluarán los agentes (OE3). Finalmente, las secciones 2.2.7 y 2.2.8 presentan, a nivel conceptual, los paradigmas de aprendizaje por refuerzo y de procesamiento de lenguaje natural sobre los que se construyen el agente y el módulo de sentimiento (OE2, OE3).

2.2 Desarrollo del marco

2.2.1 Mercados financieros

Un mercado financiero es un sistema económico organizado en el que se transan instrumentos financieros entre agentes con superávit y déficit de capital, cumpliendo funciones esenciales

de asignación de recursos, descubrimiento de precios, provisión de liquidez y transferencia de riesgo (Bodie et al., 2014; Mishkin, 2019). Estos mercados se clasifican según el tipo de instrumento negociado en mercados de renta variable (acciones), de renta fija (bonos y similares), de divisas, de derivados (futuros, opciones, swaps) y de commodities; y según el momento de la transacción en mercados primarios, donde se emite por primera vez un instrumento, y secundarios, donde se negocia con instrumentos previamente emitidos (Fabozzi & Modigliani, 2009).

Cada categoría de mercado posee dinámicas propias en cuanto a horizontes, volatilidades, correlaciones y estructura microeconómica. No obstante, los conceptos centrales que se desarrollan en este capítulo (portafolio, riesgo, desempeño ajustado al riesgo, costos de transacción y rebalanceo dinámico) son aplicables, con ajustes, a cualquier conjunto de instrumentos negociables (Bodie et al., 2014). La presente investigación se enfoca en el mercado secundario de renta variable, dado que constituye el dominio natural para la aplicación de algoritmos de optimización dinámica de portafolios y concentra la mayor parte de la literatura empírica de DRL aplicado a finanzas.

2.2.2 Mercados emergentes y la Bolsa de Valores de Lima

Los mercados emergentes constituyen una categoría caracterizada por economías en proceso de desarrollo que exhiben condiciones estructurales sustancialmente distintas a las de los mercados desarrollados. Bekaert y Harvey (2003) identifican como rasgos definitorios la menor capitalización bursátil, los volúmenes de negociación reducidos, la mayor concentración sectorial y geográfica, la mayor volatilidad de los retornos y la integración parcial con los mercados internacionales de capital. Estas particularidades tienen implicaciones directas sobre la aplicabilidad de modelos cuantitativos diseñados para mercados desarrollados, ya que supuestos habituales como la liquidez ilimitada, la ausencia de impacto de mercado o costos de transacción negligibles dejan de cumplirse. La clasificación de un mercado como emergente

o desarrollado es realizada periódicamente por proveedores de índices como MSCI, S&P Dow Jones y FTSE Russell, mediante criterios de tamaño, liquidez y accesibilidad para inversionistas institucionales internacionales (MSCI, 2024).

Dentro de esta categoría, la Bolsa de Valores de Lima (BVL) es el principal mercado de valores del Perú, operado por el Grupo BVL y supervisado por la Superintendencia del Mercado de Valores (SMV), entidad reguladora que garantiza la transparencia y la protección del inversionista (SMV, 2023). La BVL ofrece a los emisores nacionales y extranjeros un mecanismo organizado para la negociación de instrumentos de renta variable, renta fija y derivados, y dispone de varios índices que sintetizan el comportamiento agregado del mercado, entre los que destacan el S&P/BVL Peru General y el S&P/BVL Peru Selectivo (BVL, 2023). La BVL constituye un caso paradigmático de mercado emergente latinoamericano, cuyas características operativas se manifiestan en tres dimensiones críticas para el diseño de un agente DRL:

- **Costos de transacción elevados.** Las comisiones de intermediación cobradas por las sociedades agentes de bolsa, los aportes a la SMV y los aranceles de la BVL incrementan el costo efectivo de cada operación, penalizando estrategias con alto rebalanceo. Estos costos se descomponen en explícitos (comisiones, aranceles e impuestos) e implícitos (bid-ask spread, impacto de mercado y slippage), y su incorporación en los modelos cuantitativos altera de manera significativa las decisiones óptimas (Hasbrouck, 2007). Este factor diferencia a la BVL de mercados como el NYSE o el Shanghai Stock Exchange, donde las fricciones operativas son sensiblemente menores.
- **Baja liquidez.** El volumen diario de negociación de muchos valores listados es reducido, lo que impone restricciones efectivas sobre el tamaño de las posiciones que un agente puede asumir o liquidar sin generar un impacto de precio significativo. Esta

condición, no parametrizada por la mayoría de los entornos de simulación estándar empleados en la literatura, debe incorporarse explícitamente al diseño del entorno BVL.

- **Alta concentración sectorial.** La estructura del mercado peruano refleja la composición de su economía, con una marcada presencia del sector minero y, en menor medida, del financiero. Esta concentración limita las posibilidades de diversificación frente a las disponibles en mercados desarrollados y exige incorporar mecanismos explícitos para fomentar la diversificación dentro de la política aprendida por el agente.

La conjunción de estos tres factores justifica la imposibilidad de transferir directamente los resultados obtenidos en otros mercados (incluso en otros mercados emergentes como el chino o el brasileño) al contexto peruano, y motiva el desarrollo de un entorno de simulación calibrado específicamente para la BVL.

2.2.3 Portafolio de inversión y vector de pesos

Un portafolio de inversión se define como una colección de activos financieros (acciones, bonos, derivados o efectivo) en los que un inversionista asigna su capital con el objetivo de obtener rendimientos sujetos a un nivel de riesgo determinado (Bodie et al., 2014). Para un universo de n activos, la composición de un portafolio se expresa mediante un vector de pesos $w = (w_1, w_2, \dots, w_n)$, donde cada componente w_i representa la fracción del capital total asignada al activo i . Bajo la restricción presupuestaria los pesos satisfacen $\sum_i w_i = 1$; cuando se prohíben las ventas en corto se añade además $w_i \geq 0$ para todo i . La decisión de cómo distribuir el capital entre los activos disponibles, y de cómo modificar dicha distribución a lo largo del tiempo, constituye el problema fundamental de la gestión de portafolios.

La gestión se clasifica tradicionalmente en pasiva, que busca replicar un índice de referencia mediante estrategias estáticas o de bajo rebalanceo, y activa, que busca generar rendimientos superiores al benchmark mediante la modificación periódica de los pesos en respuesta a

información nueva (Bodie et al., 2014). El rebalanceo dinámico parte del reconocimiento de que los mercados no son estacionarios: las condiciones macroeconómicas, los regímenes de volatilidad y las correlaciones entre activos cambian a lo largo del tiempo, por lo que los pesos óptimos también deberían adaptarse. La presente investigación se enmarca en este enfoque dinámico, donde un agente computacional aprende, a partir de la interacción con un entorno de simulación, una política que rebalancea los pesos de manera secuencial en función de las señales de entrada disponibles en cada paso temporal.

2.2.4 Estrategias y modelos de gestión de portafolios

A continuación, se describen las tres estrategias tradicionales empleadas como benchmarks en el estudio comparativo (OE3): el modelo de Markowitz como representante de la optimización activa clásica, y Buy & Hold y Equal Weight como representantes de la gestión pasiva. Estas tres estrategias son recurrentes en la literatura de DRL para portafolios y permiten contrastar al agente frente a enfoques de naturaleza heterogénea.

Modelo de Markowitz

La teoría moderna de portafolios fue formalizada por Markowitz (1952) mediante el modelo de media-varianza. El modelo plantea que un inversionista racional busca maximizar el retorno esperado del portafolio para un nivel dado de riesgo o, equivalentemente, minimizar el riesgo para un retorno esperado dado. El riesgo se cuantifica mediante la varianza de los retornos y el conjunto de portafolios óptimos conforma la frontera eficiente. Formalmente, dado un vector de retornos esperados μ y una matriz de covarianzas Σ , el problema consiste en encontrar el vector w que minimice $w^T \Sigma w$ sujeto a $w^T \mu = \mu^*$ y a la restricción presupuestaria $\sum_i w_i = 1$.

A pesar de su elegancia teórica, el modelo presenta limitaciones reconocidas. Michaud (1989) acuñó el término «*error maximizer*» para describir cómo el optimizador media-varianza tiende a sobre-asignar peso a aquellos activos cuyos retornos esperados están sobreestimados,

amplificando los errores en la estimación de μ y Σ . Adicionalmente, el modelo asume distribuciones aproximadamente normales (supuesto incumplido en mercados reales debido a la asimetría y al exceso de curtosis) y es esencialmente un modelo de un solo período. Ledoit y Wolf (2004) propusieron estimadores de tipo *shrinkage* para mitigar el problema, pero estas mejoras no eliminan la rigidez intrínseca del enfoque, lo cual motiva la exploración de paradigmas adaptativos como el DRL. En el presente estudio, el modelo de Markowitz se aplica mediante la formulación clásica con estimación de retornos esperados y matriz de covarianza por ventana móvil.

Buy & Hold y Equal Weight

Buy & Hold (B&H) es una estrategia pasiva en la cual los pesos se determinan al inicio del horizonte de inversión y se mantienen sin cambios, sirviendo como referencia robusta frente a estrategias activas con alto rebalanceo, especialmente en mercados con costos de transacción elevados como la BVL. La asignación equiponderada o $1/N$, por su parte, asigna a cada activo un peso igual a $1/n$. DeMiguel et al. (2009) demostraron empíricamente que la regla $1/N$ produce desempeños fuera de muestra competitivos, e incluso superiores, frente a numerosos modelos de optimización media-varianza, debido a que estos últimos son extremadamente sensibles a errores de estimación en los parámetros de entrada. Por estos motivos, B&H y Equal Weight constituyen referencias estándar en estudios comparativos y son adoptadas como dos de los baselines del presente trabajo.

2.2.5 Riesgo financiero: volatilidad, drawdown, VaR y CvaR

El riesgo financiero, en el contexto de la gestión de portafolios, hace referencia a la posibilidad de que el valor del portafolio se desvíe negativamente del valor esperado. Su cuantificación admite múltiples enfoques. La volatilidad, medida como la desviación estándar de los retornos, es la métrica más extendida y constituye el componente central del modelo de Markowitz; sin

embargo, penaliza por igual las desviaciones positivas y negativas, lo cual no captura adecuadamente la noción intuitiva de riesgo de los inversionistas, quienes típicamente solo consideran perjudiciales las desviaciones a la baja.

Para abordar esta limitación, la literatura ha desarrollado métricas de riesgo a la baja. El drawdown cuantifica la pérdida porcentual experimentada por un portafolio desde un máximo histórico hasta un valle subsiguiente, y el Maximum Drawdown (MDD) recoge el mayor de estos episodios durante el período evaluado. El MDD es especialmente relevante para inversionistas con aversión a las pérdidas, dado que captura el peor escenario experimentado durante la vida del portafolio.

El Value at Risk (VaR) al nivel de confianza α se define como la pérdida máxima esperada que no será excedida con probabilidad α durante un horizonte temporal dado. A pesar de su uso extendido en la regulación financiera, el VaR presenta dos limitaciones reconocidas: no es una medida coherente de riesgo en el sentido de Artzner et al. (1999) (viola la propiedad de subaditividad) y no informa sobre la magnitud de las pérdidas en la cola más allá del cuantil.

El Conditional Value at Risk (CVaR), también denominado Expected Shortfall, supera estas limitaciones al definirse como el valor esperado de la pérdida condicional a que esta exceda el VaR. Rockafellar y Uryasev (2000) demostraron que es una medida coherente y admite una formulación de optimización lineal computacionalmente tratable. En el contexto de DRL para portafolios, varios estudios incorporan el CVaR directamente en la función de recompensa o en la arquitectura del agente para el control explícito del riesgo de cola.

2.2.6 Métricas de desempeño de portafolios

La evaluación cuantitativa del desempeño combina métricas que capturan rentabilidad, riesgo total, riesgo a la baja y eficiencia ajustada por riesgo. La presente investigación emplea el

siguiente conjunto, seleccionado por su prevalencia en la literatura revisada de DRL para portafolios.

- **Sharpe ratio.** Métrica más utilizada para evaluar el desempeño ajustado al riesgo (Sharpe, 1994). Se define como el cociente entre el exceso de retorno del portafolio sobre la tasa libre de riesgo y la desviación estándar de dichos excesos: $SR = (R_p - R_f) / \sigma_p$. Para reportarlo anualizado a partir de retornos diarios se multiplica por $\sqrt{252}$. Constituye el indicador principal de desempeño del estudio, consistente con su uso predominante en la literatura de DRL para portafolios.
- **Sortino ratio.** Variante del Sharpe ratio que reemplaza la desviación estándar total por la *downside deviation*, calculada únicamente sobre los retornos por debajo de un umbral (habitualmente cero o la tasa libre de riesgo). Es especialmente apropiada cuando la distribución de retornos es asimétrica, situación frecuente en mercados emergentes y en estrategias activas (Sortino & van der Meer, 1991).
- **Maximum Drawdown (MDD).** Cuantifica la mayor pérdida porcentual experimentada desde un máximo histórico hasta un valle subsiguiente, expresada como $MDD = \max_t \{(V_{max,t} - V_t) / V_{max,t}\}$. Es una medida de riesgo de cola muy informativa para inversionistas con aversión a las pérdidas extremas, particularmente relevante en mercados concentrados como la BVL.
- **Retorno acumulado y retorno anualizado.** El retorno acumulado mide la ganancia o pérdida total del portafolio durante el horizonte de evaluación. El retorno anualizado normaliza esta magnitud mediante $R_{anual} = (V_{final} / V_{inicial})^{(252/n)} - 1$, donde n es el número de días de negociación, permitiendo la comparación entre horizontes temporales distintos.

- **Volatilidad anualizada.** Calculada como la desviación estándar de los retornos diarios multiplicada por $\sqrt{252}$, cuantifica la dispersión total y caracteriza la suavidad de la trayectoria del portafolio. Es el componente del denominador del Sharpe ratio.

La combinación de estas métricas proporciona una visión integral del comportamiento del portafolio. En el estudio comparativo (R8) se reportarán todas para cada combinación de algoritmo, configuración de señales y baseline, junto con intervalos de confianza derivados de la repetición sobre múltiples semillas aleatorias.

2.2.7 Aprendizaje por refuerzo

El aprendizaje por refuerzo (Reinforcement Learning, RL) es un paradigma del aprendizaje automático en el cual un agente aprende a tomar decisiones secuenciales mediante la interacción con un entorno, optimizando una señal escalar de recompensa acumulada a lo largo del tiempo (Sutton & Barto, 2018). El problema se formaliza típicamente como un Proceso de Decisión de Markov (Markov Decision Process, MDP), caracterizado por un espacio de estados, un espacio de acciones, una función de transición y una función de recompensa. El objetivo del agente es aprender una política (una función que mapea estados a acciones) que maximice el valor esperado de la recompensa acumulada descontada. Esta formulación es especialmente adecuada para problemas en los que las decisiones presentes afectan los estados futuros, como ocurre en la gestión activa de portafolios, donde la composición actual condiciona los costos de rebalanceo y las oportunidades de inversión subsiguientes.

El aprendizaje por refuerzo profundo (Deep Reinforcement Learning, DRL) extiende este paradigma mediante el uso de redes neuronales profundas como aproximadores de funciones, lo cual permite abordar problemas con espacios de estados y acciones de alta dimensionalidad. El trabajo de Mnih et al. (2015), que introdujo Deep Q-Network y alcanzó desempeño humano en juegos Atari a partir de píxeles, marcó la consolidación del DRL como subcampo. Para la

optimización de portafolios, donde el espacio de acciones es continuo (el vector de pesos w) y el estado puede integrar numerosas señales financieras, los algoritmos de la familia actor-critic resultan particularmente apropiados, dado que permiten manejar acciones continuas y exhiben mayor estabilidad de entrenamiento (Sutton & Barto, 2018). Los algoritmos específicos seleccionados para la evaluación experimental (PPO, DDPG y SAC) y el método de su aplicación fueron descritos en el capítulo de Métodos y Procedimientos.

2.2.8 Procesamiento de lenguaje natural y modelos de lenguaje de gran escala

El procesamiento de lenguaje natural (Natural Language Processing, NLP) es el área de la inteligencia artificial dedicada al diseño de sistemas computacionales capaces de interpretar, generar y razonar sobre el lenguaje humano (Jurafsky & Martin, 2025). Una tarea pertinente para la presente investigación es el análisis de sentimiento financiero, que consiste en clasificar la polaridad emocional (positiva, negativa o neutral) de textos relacionados con eventos económicos o corporativos (Du et al., 2024). Su utilidad en la gestión de portafolios radica en que las noticias y los reportes contienen información proyectiva que los precios pueden tardar en incorporar, y por tanto su procesamiento sistemático puede aportar señales útiles para la toma de decisiones de inversión.

Las aproximaciones tradicionales al análisis de sentimiento financiero se han basado en léxicos especializados (Loughran & McDonald, 2011) y en modelos discriminativos pre-entrenados como FinBERT (Araci, 2019), los cuales requieren datasets etiquetados específicos para su ajuste fino. Los modelos de lenguaje de gran escala (Large Language Models, LLMs), surgidos a partir de la arquitectura Transformer, han transformado este escenario al exhibir capacidades emergentes de comprensión y razonamiento en contextos zero-shot y few-shot, sin requerir entrenamiento específico para cada tarea (Brown et al., 2020). Si bien los LLMs comerciales como Claude, GPT y Gemini son accesibles mediante APIs de pago, también existe una familia creciente de modelos de pesos abiertos que pueden ejecutarse de forma local, lo cual permite

integrar sus capacidades de procesamiento de lenguaje natural en aplicaciones propias sin depender de un servicio externo ni entrenar modelos desde cero (Nie et al., 2024).

La decisión de emplear un LLM de pesos abiertos ejecutado localmente, en lugar de entrenar un modelo propio o ajustar un modelo discriminativo como FinBERT, se justifica por tres razones. Primero, el enfoque generativo zero-shot elimina la necesidad de construir y mantener un dataset etiquetado en español del dominio financiero peruano, recurso que actualmente no existe y cuya construcción representaría un esfuerzo desproporcionado para el alcance del estudio. Segundo, aprovecha la comprensión contextual multilingüe ya incorporada en estos modelos, que iguala o supera a alternativas especializadas en escenarios de transferencia entre idiomas y dominios (Liu et al., 2024). Tercero, sigue un enfoque ya validado en mercados emergentes: Silva et al. (2025) demostraron la viabilidad de clasificar noticias en idiomas distintos del inglés (portugués del mercado brasileño) mediante un LLM con resultados competitivos, antecedente metodológico que la presente investigación adapta al español. Frente a ese antecedente, que empleó una API comercial, la ejecución local añade además ventajas de costo y autonomía: el procesamiento del corpus se realiza sin costo por consumo de API ni dependencia de la disponibilidad de un proveedor, manteniendo los datos dentro del entorno del proyecto. Los detalles de la metodología de aplicación de PLN se describen en el capítulo de Métodos y Procedimientos.

Capítulo 3. Estado del Arte

3.1 Introducción

El presente capítulo desarrolla la revisión sistemática de la literatura sobre la aplicación de deep reinforcement learning a la optimización de portafolios de inversión. La revisión sigue la metodología propuesta por Kitchenham y Charters (2007), empleada también por Silva et al. (2025) en su revisión del mismo dominio para el mercado brasileño. El objetivo es identificar el estado actual del conocimiento, las tendencias metodológicas, los resultados reportados y las brechas de investigación que justifican la presente tesis, con especial énfasis en la aplicabilidad de los hallazgos a mercados emergentes y, en particular, a la BVL.

3.2 Objetivos de revisión

Los objetivos de la revisión sistemática son: (a) identificar los algoritmos y arquitecturas DRL utilizados para optimización de portafolios y su desempeño comparativo; (b) determinar qué representaciones del estado y combinaciones de señales de entrada se emplean; (c) analizar las funciones de recompensa y mecanismos de gestión de riesgo incorporados; (d) evaluar cómo se han adaptado los modelos DRL a mercados emergentes; y (e) caracterizar los entornos de simulación utilizados, las brechas identificadas y el grado de reproducibilidad.

3.3 Preguntas de revisión

- P1. ¿Qué algoritmos y arquitecturas DRL se utilizan para optimización de portafolios, y cuál es su desempeño comparativo?
- P2. ¿Qué representaciones del estado y combinaciones de señales de entrada se emplean en modelos DRL para portafolios?
- P3. ¿Qué funciones de recompensa y mecanismos de gestión de riesgo se incorporan en agentes DRL para portafolios?

- P4. ¿Cómo se han adaptado los modelos DRL a mercados emergentes y qué desafíos específicos enfrentan?
- P5. ¿Qué entornos de simulación se utilizan, qué brechas se identifican y qué tan reproducibles son los estudios?

3.4 Estrategia de búsqueda

3.4.1 Motores de búsqueda a usar

Se utilizaron tres motores de búsqueda: Scopus, Web of Science y arXiv. Scopus fue seleccionado por su amplia cobertura en ingeniería, ciencias de la computación y finanzas. Web of Science complementa la búsqueda con publicaciones de alto impacto. arXiv fue incluido para capturar preprints recientes en áreas de rápida evolución como el DRL aplicado a finanzas.

3.4.2 Cadenas de búsqueda a usar

Las cadenas de búsqueda fueron construidas siguiendo la estrategia de descomposición por facetas recomendada por Kitchenham y Charters (2007) para la elaboración de revisiones sistemáticas en ingeniería del software, adaptada al dominio de la inteligencia artificial aplicada a finanzas. La pregunta de investigación se descompuso en tres facetas: método, correspondiente a la técnica de aprendizaje automático empleada (deep reinforcement learning y sus variantes); tarea, referida al problema financiero abordado (optimización y gestión de portafolios o asignación de activos); y contexto, relativo al entorno de aplicación (mercados financieros de renta variable, con énfasis en mercados emergentes y latinoamericanos). Para cada faceta se identificaron términos equivalentes y sinónimos frecuentes en la literatura. La Tabla 3 presenta las cadenas resultantes, adaptadas a la sintaxis propia de cada motor de búsqueda.

Tabla 3. Cadenas de búsqueda por motor

Motor	Cadena de búsqueda
Scopus	TITLE(("deep reinforcement learning" OR "drl" OR "deep rl" OR "reinforcement learning")) AND TITLE(("portfolio" OR "portfolios" OR "portfolio optimization" OR "portfolio management" OR "portfolio performance" OR "asset allocation" OR "asset management")) AND TITLE-ABS-KEY(("stock market" OR "stocks" OR "financial market" OR "trading" OR "stock trading" OR "emerging market" OR "latin american market" OR "small market" OR "illiquid market")) AND (LIMIT-TO (PUBYEAR, 2026) OR LIMIT-TO (PUBYEAR, 2025) OR LIMIT-TO (PUBYEAR, 2024) OR LIMIT-TO (PUBYEAR, 2023) OR LIMIT-TO (PUBYEAR, 2022) OR LIMIT-TO (PUBYEAR, 2021) OR LIMIT-TO (PUBYEAR, 2020))
Web of Science	TI=(("deep reinforcement learning" OR "drl" OR "deep rl" OR "reinforcement learning")) AND TI=(("portfolio" OR "portfolios" OR "portfolio optimization" OR "portfolio management" OR "portfolio performance" OR "asset allocation" OR "asset management")) AND TS=(("stock market" OR "stocks" OR "financial market" OR "trading" OR "stock trading" OR "emerging market" OR "latin american market" OR "small market" OR "illiquid market")) AND PY=(2020-2026)
arXiv	TITLE: "deep reinforcement learning" OR "drl" OR "deep rl" OR "reinforcement learning" AND TITLE: "portfolio" OR "portfolios" OR "portfolio optimization" OR "portfolio management" OR "portfolio performance" OR "asset allocation" OR "asset management" AND ALL: "stock market" OR "stocks" OR "financial market" OR "trading" OR "stock trading" OR "emerging market" OR "latin american market" OR "small market" OR "illiquid market" Con filtro de 2020 a 2026

3.4.3 Documentos encontrados

La búsqueda inicial arrojó un total de 380 documentos distribuidos según la Tabla 4.

Tabla 4. Documentos encontrados por motor de búsqueda.

Motor de búsqueda	Documentos encontrados
Scopus	215
Web of Science	113
arXiv	52
Total	380

Se realizó un proceso de deduplicación por DOI. Se eliminaron 102 duplicados entre los tres motores de búsqueda, obteniendo 278 documentos únicos. La Tabla 5 resume el filtrado.

Tabla 5. Proceso de filtrado de documentos

Etapas	N.º de documentos
Documentos encontrados inicialmente	380
Duplicados de Scopus y WoS eliminados	99
Duplicados de Scopus y arXiv eliminados	3
Duplicados de WoS y arXiv eliminados	2
Duplicados de Scopus, WoS y arXiv eliminados	2
Documentos tras deduplicación	278

Tras aplicar los criterios de inclusión y exclusión presentados a continuación, se realizó una vista rápida a los resúmenes de artículos resultantes para identificar aquellos que tendrían mayor relevancia para responder a las preguntas de investigación.

3.4.4 Criterios de inclusión/exclusión

Criterios de inclusión

- CI1 – Periodo de publicación: Artículos publicados entre 2020 y 2026. Se prioriza dicho periodo porque concentra avances metodológicos más relevantes sobre el campo.
- CI2 – Tipo de documento: Artículos de revista, conferencia o preprint (arXiv)
- CI3 – Idioma: Inglés o Español
- CI4 – Temática principal: Uso explícito de DRL (DQN, DDQN, PPO, A2C, DDPG, SAC, TD3 u otro) para optimización de portafolios o trading de acciones
- CI5 – Mercado de aplicación: Cualquier mercado financiero de renta variable (acciones); se prioriza mercados emergentes y/o latinoamericanos
- CI6 – Disponibilidad de métricas: El artículo reporta al menos una métrica de desempeño cuantitativa (retorno, Sharpe ratio, drawdown, etc.)
- CI7 – Descripción del entorno: El artículo describe el entorno de simulación, incluyendo supuestos sobre costos de transacción

Criterios de exclusión

- CE1 – Temática fuera de alcance: Artículos que aplican RL únicamente a criptomonedas, forex o commodities sin acciones
- CE2 – Sin componente DRL: Artículos que usan únicamente ML supervisado (LSTM, GBM, etc.) sin componente de decisión RL
- CE3 - Sin evaluación empírica: Propuestas puramente teóricas sin experimentos sobre datos reales de mercado (a excepción de papers comparativos)

- CE4 – Acceso restringido total: Artículos sin abstract disponible ni acceso a texto completo ni preprint

3.5 Documentos revisados

Posterior al filtrado realizado, se incluyeron los estudios E03, E04, E07 y E08, que no aparecieron en la búsqueda inicial debido a la estructura de la cadena de búsqueda, pero que otros autores referencian como relevantes y su contenido es importante para dar respuesta a las preguntas de investigación. Los estudios seleccionados se presentan en la Tabla 6, junto con su identificador y referencia en APA.

ID	Nombre del artículo	Referencia APA 7
E01	Systematic Review of Portfolio Optimization in the Brazilian Financial Market: Integrating News and Fundamental Indicators with Deep Reinforcement Learning	Silva, K. C., Fernandes, D., Fernandes, M., Soares, F., & Sousa, T. M. de. (2025). Systematic review of portfolio optimization in the Brazilian financial market: Integrating news and fundamental indicators with deep reinforcement learning. In CSCI 2024, Communications in Computer and Information Science (Vol. 2503, pp. 19–32). Springer Nature Switzerland AG. https://doi.org/10.1007/978-3-031-94940-1_2
E02	A Deep Reinforcement Learning Approach for Portfolio Optimization of Brazilian Assets Using Fundamental and Sentiment Indicators	Silva, K. C., Sá, F., Fernandes, D., Fernandes, M., & Soares, F. (2025). A deep reinforcement learning approach for portfolio optimization of Brazilian assets using fundamental and sentiment indicators. In Proceedings of the 49th IEEE Annual Computers, Software, and Applications Conference (COMPSAC 2025). IEEE. https://doi.org/10.1109/COMPSAC65507.2025.00258
E03	A Combined Algorithm Approach for Optimizing Portfolio Performance in Automated Trading: A Study of SET50 Stocks	Thongkairat, S., & Yamaka, W. (2025). A combined algorithm approach for optimizing portfolio performance in automated trading: A study of SET50 stocks. Mathematics, 13(3), 461. https://doi.org/10.3390/math13030461
E04	Deep Reinforcement Learning for Automated Stock Trading using Different Reward Schemes	Lawton, S. R., & Jeewa, A. (2024). Deep reinforcement learning for automated stock trading using different reward schemes. In 2024 IEEE International Conference on Future Machine Learning and Data Science (FMLDS). IEEE. https://doi.org/10.1109/FMLDS63805.2024.00101
E05	A Deep Reinforcement Learning Framework for Dynamic Portfolio Optimization: Evidence from China's Stock Market	Huang, G., Zhou, X., & Song, Q. (2025). A deep reinforcement learning framework for dynamic portfolio optimization: Evidence from China's stock market [Working paper]. Chongqing University.
E06	Equity Portfolio Optimization Using Reinforcement Learning: Emerging Market Case	Candar, M., & Üstündağ, A. (2022). Equity portfolio optimization using reinforcement learning: Emerging market case. In Intelligent and Fuzzy Systems, Lecture Notes in Networks and Systems (Vol. 505, pp. 131–139). Springer Nature Switzerland AG. https://doi.org/10.1007/978-3-031-09176-6_16
E07	Beating the Stock Market with a Deep Reinforcement Learning Day Trading System	Conegundes, L., & Pereira, A. C. M. (2020). Beating the stock market with a deep reinforcement learning day trading system. In 2020 IEEE International Joint Conference on Neural Networks (IJCNN). IEEE.

E08	Deep Reinforcement Learning Approach Using Customized Technical Indicators for A Pre-emerging Market: A Case Study of Vietnamese Stock Market	Nguyen, H.-T. N., Mac, B.-N. N., Tran, A.-D., Nguyen, N.-T., & Pham, D.-T. (2022). Deep reinforcement learning approach using customized technical indicators for a pre-emerging market: A case study of Vietnamese stock market. In 2022 RIVF International Conference on Computing and Communication Technologies (RIVF). IEEE. https://doi.org/10.1109/RIVF55975.2022.10013836
E09	Management of investment portfolios employing reinforcement learning	Santos, G. C., Garruti, D., Barboza, F., Souza, K. G. de, Domingos, J. C., & Veiga, A. (2023). Management of investment portfolios employing reinforcement learning. PeerJ Computer Science, 9, e1695. https://doi.org/10.7717/peerj-cs.1695
E10	Optimizing stock portfolios with deep reinforcement learning after FNN-based fundamental analysis	Sun, Y. J., Lu, Z. Y., Liao, C. H., Dai, T. S., & Yuan, S. M. (2026). Optimizing stock portfolios with deep reinforcement learning after FNN-based fundamental analysis. Quantitative Finance, 26(1), 137–159. https://doi.org/10.1080/14697688.2025.2604770
E11	Attention-Enhanced Reinforcement Learning for Dynamic Portfolio Optimization	Xue, P., & Ye, Y. (2025). Attention-enhanced reinforcement learning for dynamic portfolio optimization (arXiv:2510.06466). arXiv. https://arxiv.org/abs/2510.06466
E12	Feature configuration effects in DRL portfolio management: a risk-focused evaluation under market stress	Ayari, R. (2026). Feature configuration effects in DRL portfolio management: A risk-focused evaluation under market stress. Quantitative Finance, 26(1), 119–136. https://doi.org/10.1080/14697688.2025.2592822
E13	MTS: A Deep Reinforcement Learning Portfolio Management Framework with Time-Awareness and Short-Selling	Gu, F., Jiang, Z., García-Fernández, A. F., Stefanidis, A., Su, J., & Li, H. (2025). MTS: A deep reinforcement learning portfolio management framework with time-awareness and short-selling (arXiv:2503.04143). arXiv. https://doi.org/10.48550/arXiv.2503.04143
E14	Portfolio management based on value distribution reinforcement learning algorithm	Yang, Y., Wang, T., Fu, Y., Huang, J., & Zhou, D. (2026). Portfolio management based on value distribution reinforcement learning algorithm. Frontiers in Artificial Intelligence, 8, 1709493. https://doi.org/10.3389/frai.2025.1709493
E15	Graph attention-based heterogeneous multi-agent deep reinforcement learning for adaptive portfolio optimization	Zhang, B. (2026). Graph attention-based heterogeneous multi-agent deep reinforcement learning for adaptive portfolio optimization. Scientific Reports, 16, 2674. https://doi.org/10.1038/s41598-025-32408-w

3.6 Formulario de extracción de datos

Se diseñó un formulario de extracción con 56 columnas organizadas en campos generales y cinco bloques temáticos alineados con las preguntas P1 a P5. La Tabla 7 presenta un resumen.

Tabla 7. Estructura del formulario de extracción de datos

Bloque	Campos del bloque	Descripción
Campos generales (A-K)	“ID”, “Año de publicación”, “Título del artículo”,	Información bibliográfica básica para localizar, citar y verificar la procedencia

	“Autores”, “Fuente / Revista / Conf.”, “Tipo de documento”, “Resumen (Abstract)”, “URL / DOI”, “¿Código disponible?”, “Enlace al código”	del artículo, incluyendo si el código fuente está disponible y dónde acceder a él.
P1: Algoritmos y desempeño (L-W)	“Algoritmos / Arquitecturas DRL utilizados”, “Familia del algoritmo (on/off-policy)”, “Red neuronal subyacente (MLP, LSTM, CNN...)”, “Comparación con baselines (B&H, Markowitz, etc.)”, “Métricas de desempeño reportadas”, “Retorno anualizado (%)”, “Sharpe Ratio”, “Otras métricas de riesgo reportadas”, “Estabilidad del entrenamiento (observaciones)”, “Costo computacional (GPU/CPU, horas)”, “Ventajas del enfoque”, “Limitaciones del enfoque”	Caracterización del algoritmo de Deep Reinforcement Learning usado, su familia, arquitectura de red neuronal, comparación con estrategias tradicionales (como Buy & Hold o Markowitz), y métricas financieras reportadas (rentabilidad, Sharpe ratio, riesgo, estabilidad y costo computacional).
P2: Señales de entrada (X-AH)	“Señales de entrada utilizadas (resumen)”, “¿Usa OHLCV?”, “¿Usa indicadores técnicos? ¿Cuáles?”, “¿Usa datos fundamentales? ¿Cuáles?”, “¿Usa análisis de sentimiento / noticias?”, “¿Usa datos alternativos? (otros)”, “Dimensión del espacio de observación”, “Espacio de acciones (discreto/continuo)”, “Frecuencia de operación (diaria/intradiaria...)”, “Horizonte de datos históricos usados”, “Impacto de la combinación de señales (resultado)”	Tipos de información utilizada para tomar decisiones (OHLCV, indicadores técnicos, fundamentales, sentimiento de noticias, datos alternativos), dimensión del espacio de observación, tipo de acción (discreta/continua), frecuencia de trading y horizonte histórico.

P3: Recompensa y riesgo (AI-AN)	“Función de recompensa utilizada”, “¿Incorpora Sharpe ratio en recompensa?”, “¿Incorpora Sortino/Drawdown en recompensa?”, “¿Incorpora CVaR u otra métrica de riesgo?”, “Efecto de la recompensa ajustada al riesgo”, “Comportamiento bajo volatilidad extrema”	Cómo se define la recompensa para el agente DRL, si incorpora métricas ajustadas por riesgo (Sharpe, Sortino, Drawdown, CVaR), y cómo se comporta el modelo en entornos de alta volatilidad.
P4: Mercados emergentes (AO-AV)	“Mercado financiero aplicado”, “Tipo de mercado (desarrollado / emergente / frontera)”, “País / Bolsa de valores”, “Nº de activos en el portafolio”, “¿Considera baja liquidez?”, “Costos de transacción asumidos (%)”, “Adaptaciones para mercado emergente”, “¿Limitaciones de datos históricos?”	Contexto financiero de aplicación: tipo de mercado (desarrollado, emergente o frontera), país o bolsa, número de activos, consideración de liquidez baja, costos de transacción asumidos y adaptaciones específicas para mercados emergentes.
P5: Entornos y brechas (AW-BD)	“Entorno de simulación utilizado”, “Supuestos sobre ejecución de órdenes”, “¿Incluye slippage?”, “Periodo de entrenamiento y prueba”, “¿Reproducible? (semilla, código público)”, “Brechas identificadas / Trabajo futuro propuesto”, “Relevancia para la BVL (observaciones)”	Entorno de simulación usado, supuestos de ejecución (slippage, órdenes), periodos de entrenamiento y prueba, reproducibilidad del estudio (semillas, código público), brechas identificadas y relevancia para la Bolsa de Valores de Lima (BVL).
Campos generales	“Comentarios Generales”	Observaciones adicionales no cubiertas en los bloques anteriores, como limitaciones generales del estudio, fortalezas cualitativas, contexto de aplicación atípico o recomendaciones para trabajos futuros.

El formulario completo con los datos extraídos de los 15 estudios primarios se adjunta en el Anexo B.

3.7 Resultados de la revisión

3.7.1 Respuesta a la pregunta P1

La revisión confirma un predominio claro de los métodos actor-critic en la literatura reciente sobre optimización de portafolios mediante deep reinforcement learning. La Tabla 8 sintetiza la prevalencia de cada algoritmo en los 14 estudios primarios (excluyendo E01, que corresponde a una revisión secundaria).

Tabla 8. Algoritmos DRL empleados en los estudios revisados

Algoritmo	Familia	N.º estudios	Estudios
PPO	On-policy	10	E02, E03, E04, E05, E06, E08, E09, E10, E11, E13
DDPG	Off-policy	8	E02, E03, E04, E06, E07, E09, E10, E14
SAC	Off-policy	6	E02, E03, E08, E09, E10, E14
A2C	On-policy	6	E02, E03, E04, E08, E09, E11
TD3	Off-policy	5	E02, E03, E09, E12, E14
VD-MEAC	Off-policy (propuesto)	1	E14
REINFORCE	On-policy	1	E11
DQN	Off-policy	1	E15 (como componente de baseline Transformer-DRL)
Multi-agente con GAT	Híbrido	1	E15 (algoritmo propuesto)

Proximal Policy Optimization (PPO) se consolida como el algoritmo más utilizado, presente en 10 de los 14 estudios empíricos. Su preferencia se sustenta en tres propiedades documentadas reiteradamente: la estabilidad del entrenamiento, la facilidad de implementación a través de bibliotecas estándar como Stable-Baselines3, y un balance favorable entre eficiencia de muestra y exploración. Huang et al. (2025; E05) lo eligen como única arquitectura para su

propuesta sobre el CSI 300 e introducen una recompensa de Sharpe ratio promedio que asegura convergencia con valores positivos, alcanzando un Sharpe de 1.555 frente a 1.229 del mejor baseline tradicional (CVaR-MinRisk). Gu et al. (2025; E13) también lo adoptan como núcleo de su marco MTS para el DJIA, donde el algoritmo logra un Sharpe de 2.69 en el dataset de 2019 y un retorno acumulado quinquenal de 227.39%.

Deep Deterministic Policy Gradient (DDPG) ocupa el segundo lugar con 8 apariciones. Su ventaja en espacios de acciones continuos (indispensables para representar vectores de pesos del portafolio) explica su adopción temprana en trabajos pioneros como el de Conegundes y Pereira (2020; E07), quienes lo aplicaron a un sistema de day trading sobre las diez acciones más líquidas de la B3, obteniendo 311% de retorno acumulado en tres años frente al 92.1% del Ibovespa. No obstante, varios autores reportan que DDPG es más sensible a hiperparámetros y al ruido de exploración que PPO. Soft Actor-Critic (SAC) y Advantage Actor-Critic (A2C) aparecen empatados con 6 apariciones cada uno; SAC destaca por su mecanismo de entropía máxima que favorece exploraciones más robustas, mientras que A2C ofrece simplicidad pero con desempeño irregular; en Thongkairat y Yamaka (2025; E03) PPO produjo Sharpe de apenas 0.106 en el SET50, mientras que A2C alcanzó 0.246. TD3, variante mejorada de DDPG con doble crítica y actualización retardada, aparece en 5 estudios, y resulta especialmente relevante en E12 (Ayari, 2026), donde fue elegido como único algoritmo para aislar el efecto de la información de features sin confundirlo con tuning algorítmico.

Más allá de los algoritmos canónicos, la literatura reciente explora arquitecturas neuronales especializadas y variantes algorítmicas propias. Mientras los MLP siguen siendo la opción mayoritaria (por defecto en las implementaciones de FinRL/SB3), Huang et al. (2025; E05) emplean una red basada en VGG para procesar tensores 3D de precios, Sun et al. (2026; E10) introducen una Temporal Convolutional Network concatenada (CTCN) que extrae patrones temporales a múltiples escalas, Xue y Ye (2025; E11) combinan codificadores temporales por

activo (LSTM o Transformer) con un Transformer cross-seccional y una cabeza de política Dirichlet que garantiza factibilidad en el simplex, Gu et al. (2025; E13) proponen un mecanismo Time-aware Relative Multi-Head Attention con embeddings semanales y mensuales, Yang et al. (2026; E14) introducen el algoritmo VD-MEAC (Value Distribution Maximum Entropy Actor-Critic) cuyo crítico aprende la distribución completa de retornos futuros mediante Fully-Parameterized Quantile Functions, y Zhang (2026; E15) desarrolla un marco multi-agente heterogéneo donde tres agentes especializados (evaluación de riesgo, predicción de retornos y percepción del entorno) cooperan mediante Graph Attention Networks. Estas innovaciones señalan una tendencia clara hacia arquitecturas que modelan explícitamente la estructura temporal y de correlaciones entre activos.

En cuanto al desempeño comparativo, los Sharpe ratios reportados muestran una dispersión considerable que refleja tanto la heterogeneidad de mercados como las diferencias metodológicas. Los valores más altos, con Sharpe de 2.978 promedio en VD-MEAC (E14) sobre 100 simulaciones del CSI 300 y de 2.69 en MTS (E13) sobre el DJIA 2019, corresponden a propuestas con mecanismos elaborados de gestión de riesgo (distribución cuantílica, ICVaR) y a períodos de prueba favorables. En el rango medio, valores típicos de 0.7 a 1.6 se asocian a configuraciones más estándar: Silva et al. (2025; E02) reportan medianas de Sharpe entre 0.69 y 0.71 sobre cinco activos del Ibovespa con 44 réplicas, Candar y Üstündağ (2022; E06) obtienen 1.59 con PPO sobre el BIST30, y Xue y Ye (2025; E11) alcanzan 0.73 con PPO sobre el S&P 500. En el extremo inferior, Ayari (2026; E12) reporta valores negativos (entre -0.28 y -0.39) debido a que su evaluación se circunscribió al año bajista 2022; estos resultados, lejos de invalidar el enfoque, evidencian que las métricas absolutas son altamente dependientes del régimen de mercado evaluado, lo cual refuerza la importancia de una evaluación walk-forward en múltiples ventanas temporales, metodología que la presente investigación adoptará para la BVL.

3.7.2 Respuesta a la pregunta P2

La caracterización de las señales de entrada empleadas en los 14 estudios primarios revela un núcleo común basado en datos de precios, con una incorporación progresiva pero todavía minoritaria de fuentes complementarias como indicadores fundamentales, sentimiento de noticias y datos alternativos. La Tabla 9 sintetiza esta distribución.

Tabla 9. Tipos de señales de entrada empleadas

Tipo de señal	N.º estudios	Estudios
Precios (OHLCV o derivados)	14	Todos los estudios primarios (E02–E15); E01 es revisión sistemática
Indicadores técnicos	10	E03, E04, E06, E08, E09, E11, E12, E13, E14, E15
Indicadores fundamentales	6	E02, E06, E10, E12, E14, E15
Sentimiento / noticias	3	E02, E03, E15
Datos alternativos (commodities, factores macro, VIX)	4	E03, E09, E11, E15

Los precios constituyen la señal universalmente adoptada: los 14 estudios primarios utilizan datos OHLCV o variantes derivadas (precios relativos close/open en E07, retornos y volatilidad en E06, tensores 3D normalizados por el último cierre en E05 y E10). La frecuencia de operación predominante es diaria (presente en 11 estudios), aunque también aparecen frecuencias alternativas: mensual en Candar y Üstündağ (2022; E06) para acomodar el rebalanceo en un mercado emergente con costos relativamente altos, semanal en Sun et al. (2026; E10) tras una evaluación empírica que identificó esta frecuencia como óptima frente a las alternativas diaria, quincenal y mensual, e intradiaria (day trading) en Conegundes y Pereira (2020; E07) con compras en la subasta de apertura y ventas en la subasta de cierre.

Los indicadores técnicos están presentes en 10 estudios y conforman el segundo bloque más utilizado. Los más recurrentes son MACD (8 estudios), RSI (8), Bollinger Bands (4), CCI (4) y ADX (4), seguidos de variantes como ATR, SAR, Stochastic Oscillator, Williams %R, ROC, OBV, MFI y True Range. Nguyen et al. (2022; E08) realizan un aporte particular al respecto al adaptar el conjunto de indicadores al contexto pre-emergente de Vietnam, basándose en validaciones locales previas que destacaron la efectividad de la SMA y las Bandas de Bollinger en el VN30; el vector de estado resultante alcanza 271 dimensiones (30 acciones $\times$ 9 features + 1 balance). Esta estrategia de personalización de indicadores por mercado constituye un antecedente directo para la selección de indicadores en la BVL.

Los indicadores fundamentales aparecen en 6 estudios y reflejan la creciente conciencia de que las señales puramente técnicas son insuficientes para capturar la salud financiera subyacente de los emisores. Candar y Üstündağ (2022; E06) emplean Price-to-Book (P/B) y Price-to-Sales (P/S) ratios sobre el BIST30, Silva et al. (2025; E02) incorporan Dividend Yield, Price-to-Earnings, Return on Equity y Gross Margin con frecuencia trimestral sobre cinco activos del Ibovespa, Sun et al. (2026; E10) llevan al extremo este enfoque utilizando 18 ratios financieros trimestrales (Current Ratio, Debt-to-Capital, Debt-to-Equity, Asset Turnover, Inventory Turnover, Receivable Turnover, Gross/Operating/Net Margin, ROE, ROA, ROI, FCF/Share, Book Value/Share, entre otros) mediante una red FNN previa para la selección de activos antes del paso DRL, Ayari (2026; E12) opta por factores de riesgo sistemático del modelo BARRA (Market Beta, Volatility, Size, Value, Leverage, Momentum más 24 clasificaciones industriales SIC), Yang et al. (2026; E14) incorporan ratios como PEG y `net_profit_to_total_operate_revenue_ttm` seleccionados por LightGBM dentro de un conjunto más amplio de 15 factores, y Zhang (2026; E15) adopta sensibilidades al modelo Fama-French de cinco factores (Market, SMB, HML, RMW, CMA). El hallazgo más significativo en esta línea proviene de E10: en su estudio, la selección de acciones basada en fundamentales

contribuyó aproximadamente trece veces más al desempeño final del sistema (APV 5.354) que la optimización DRL por sí sola (APV 1.883), lo que sugiere que en universos con alta dispersión de calidad financiera (como es el caso de la BVL) la fase de filtrado fundamental puede aportar más valor que la sofisticación del algoritmo de asignación.

El análisis de sentimiento de noticias es la fuente más escasamente representada: únicamente tres estudios la incorporan. Silva et al. (2025; E02) procesan 177.155 artículos de Investing.com en portugués mediante la API de Gemini Pro, generando un score diario por activo definido como $S_i = (N_{pos} - N_{neg}) / N_{total}$. Thongkairat y Yamaka (2025; E03) combinan sentimiento de Google News y Twitter usando VADER, ponderando este último por likes y retweets para reflejar el alcance social. Zhang (2026; E15) integra news sentiment como una de múltiples fuentes en su marco multi-agente. Ningún estudio incorpora sentimiento en español, lo que confirma una brecha directamente abordable por la presente investigación. Adicionalmente, cuatro estudios incorporan datos alternativos: derivados de commodities (E09: arroz, ganado, café, etanol, maíz, hierro, oro, petróleo, soya y trigo), engagement social (E03), VIX y factor returns (E11), y 25 indicadores macroeconómicos de FRED (E15).

Respecto a la representación formal del estado, se observan dos paradigmas dominantes. El primero emplea vectores planos que concatenan balance, holdings y features por activo (E04: 181 dimensiones; E08: 271 dimensiones; E12: variable según configuración). El segundo utiliza tensores 3D o 4D que preservan la estructura ventana temporal $\times$ activos $\times$ features, lo cual permite aprovechar arquitecturas convolucionales o de atención (E05: $4 \times 10 \times n$; E06: $21 \times 30 \times 12$; E10: $4 \times (m+1) \times n$; E11: $30 \times 482 \times 19$). La elección entre uno y otro depende de la arquitectura neuronal: MLP estándar para vectores planos, CNN/TCN/atención para tensores estructurados. En lo que respecta al impacto de combinar señales, la evidencia es mixta: mientras Silva et al. (2025; E02) no encontraron diferencias estadísticamente significativas (Kruskal-Wallis, $p > 0.05$) entre las cuatro configuraciones de señales evaluadas (solo OHLCV;

OHLCV + sentimiento; OHLCV + fundamentales; combinación completa), Ayari (2026; E12) demostró mediante 800 corridas independientes y permutation tests con corrección de FDR Benjamini-Hochberg que los factores BARRA mejoran significativamente el Maximum Drawdown (+0.71%, $p=0.02$) frente a un baseline sin features, mientras que indicadores técnicos solos no aportan beneficio significativo. Sun et al. (2026; E10) reportan que su sistema integrado de selección fundamental más optimización DRL alcanzó APV de 5.354 frente a 2.810 (solo selección) y 1.883 (solo optimización), evidenciando interacciones favorables entre las fuentes.

3.7.3 Respuesta a la pregunta P3

Las funciones de recompensa empleadas en la literatura revisada pueden clasificarse en cuatro categorías no excluyentes en función del énfasis predominante: recompensas basadas en el retorno simple, recompensas explícitamente ajustadas al riesgo, recompensas compuestas con términos de penalización adicionales y recompensas con regularización por entropía. La Tabla 10 sintetiza esta distribución.

Tabla 10. Tipos de función de recompensa empleadas

Tipo de función de recompensa	N.º estudios	Estudios
Retorno simple del portafolio (log-retorno o cambio de valor)	5	E02, E07, E08, E09, E14
Ajustada al riesgo (Sharpe, varianza, CVaR/ES, ICVaR)	5	E04, E05, E11, E12, E13
Compuesta con penalización adicional (costos, sentimiento, benchmark)	3	E03, E10, E15
Con entropía o diversificación explícita	1	E06

El grupo más numeroso, junto con el de recompensas ajustadas al riesgo, corresponde a las recompensas basadas en retorno. Conegundes y Pereira (2020; E07) emplean $r_t = \log(\beta \cdot y_t \cdot w_t)$, donde $\beta = 1 - \alpha$ actúa como factor de remanente tras costos de transacción; esta formulación logarítmica es consistente con el framework canónico de Jiang et al. (2017) y reaparece en Yang et al. (2026; E14) y en el primer término de E11. Otros estudios optan por el cambio simple del valor del portafolio (E08, E09) o por un retorno normalizado por el valor del portafolio (E02). Si bien estas recompensas son las más sencillas de implementar, no incentivan explícitamente la gestión del riesgo, lo que típicamente se compensa mediante el monitoreo externo del Sharpe ratio en la fase de validación.

El segundo bloque incorpora métricas de riesgo directamente en la señal de recompensa, una práctica que la literatura más reciente posiciona como superior para el control del drawdown. Huang et al. (2025; E05) proponen una recompensa basada en el Sharpe ratio promedio anualizado normalizado por los steps del episodio, diseñada específicamente para algoritmos actor-critic; esta normalización resulta crítica para asegurar convergencia estable y obtener Sharpe positivo de forma consistente. Lawton y Jeewa (2024; E04) comparan sistemáticamente tres funciones —valor del portafolio, Sharpe ratio y varianza del portafolio— bajo tres ventanas temporales (5, 10 y 15 días), y reportan que las recompensas de riesgo producen retornos ligeramente inferiores pero significativamente más estables entre semillas (desviación estándar 0.1 con Sharpe-15d frente a 0.4 con valor del portafolio). Xue y Ye (2025; E11) introducen $R_t = \log(1 + w'_t r_t) - \kappa \cdot TC_t - \lambda \cdot w'_t \Sigma_t w_t$, donde la penalización de varianza ($w' \Sigma w$) basada en una matriz de covarianza rolling actúa como regularizador clásico de Markowitz incorporado al objetivo de RL. Las propuestas más sofisticadas corresponden a Ayari (2026; E12) y Gu et al. (2025; E13). El primero introduce el Differential Expected Shortfall (DES), una recompensa basada en la contribución marginal al ratio retorno/Expected Shortfall que utiliza una media EWMA del retorno y una magnitud del ES con ventana expandente; el

segundo introduce el Incremental Conditional Value at Risk (ICVaR), definido como el cambio incremental del CVaR entre períodos consecutivos, integrado en la recompensa mediante $r = \Delta P_t - \lambda \cdot \text{ICVaR}_{\{\alpha, t\}}(X)$. Los estudios de ablación de E13 muestran que retirar el componente ICVaR provoca una caída promedio de 4.6% en el Sharpe ratio, llegando a 16.5% en el dataset bajista de 2022.

La tercera categoría agrupa recompensas compuestas con términos de penalización adicionales que no son métricas de riesgo en sentido estricto. Thongkairat y Yamaka (2025; E03) emplean $R_i = \text{Portfolio Return}_i - \lambda_1 \cdot \text{Transaction Cost}_i - \lambda_2 \cdot \text{Sentiment}_i$, donde el sentimiento negativo penaliza explícitamente la exposición a activos con percepción adversa. Sun et al. (2026; E10) introducen una recompensa relativa al benchmark equal-weight: $R_t = r_t + \lambda \cdot (\rho_t - \rho^{\text{EW}}_t)$ con $\lambda = 0.5$; esta formulación incentiva al agente a superar al portafolio igualitario y, según los autores, mejora el APV de 4.758 ($\lambda=0$) a 5.354 ($\lambda=0.5$), un incremento del 59.6%. Zhang (2026; E15) emplea una pérdida compuesta $L(\theta) = \alpha_1 \cdot L_{\text{return}} + \alpha_2 \cdot L_{\text{risk}} + \alpha_3 \cdot L_{\text{transaction}}$, con L_{risk} incluyendo CVaR y volatilidad, y coeficientes λ_i ajustables dinámicamente en función del régimen de mercado detectado mediante un modelo de Markov oculto.

Finalmente, Candar y Üstündağ (2022; E06) constituyen un caso singular al incorporar entropía de Shannon en la recompensa mediante $R(a, r; \mu, \sigma) = r_{\{\mu, \sigma\}} \times H_n(a)$, donde $r_{\{\mu, \sigma\}} = \Phi(r; \mu, \sigma) - 0.5$ es una transformación CDF gaussiana del retorno respecto a su distribución histórica y $H_n(a)$ es la entropía normalizada del vector de pesos. Este término penaliza la concentración excesiva del portafolio y favorece la diversificación, mecanismo de especial interés para mercados con alta concentración sectorial como la BVL. PPO con esta recompensa alcanzó un Sharpe de 1.59 sobre el BIST30.

Más allá de la función de recompensa, varios estudios introducen mecanismos externos de gestión del riesgo. El turbulence index basado en la distancia de Mahalanobis aparece en E04,

E08 y E10 como detector de regímenes extremos que fuerza la liquidación a cash; en E08 se calibra al percentil 99.9% del periodo in-sample y permite detectar las crisis de 2018 y 2020 que un baseline sin este mecanismo no captura, reduciendo el MDD del ensemble a -33.32% frente al -48.14% del VN30INDEX. En E10 el turbulence index reduce el MDD durante la pandemia de 49.8% a 35.6% y mejora el APV en 47.3% . Otros mecanismos relevantes incluyen la entropía de Shannon ya descrita (E06), la modelación distribucional completa de los retornos futuros mediante FQF (E14) que captura implícitamente el riesgo de cola sin necesidad de incorporarlo explícitamente en la recompensa, y la aversión al riesgo dinámica dependiente del VIX y del drawdown actual (E15). El comportamiento bajo volatilidad extrema confirma la utilidad de estos mecanismos: en el dataset bajista de 2022, el marco MTS de E13 mantuvo un retorno positivo de 26.42% mientras la mayoría de baselines presentaban retornos negativos.

3.7.4 Respuesta a la pregunta P4

La distribución geográfica de los estudios revisados revela un sesgo persistente hacia los mercados desarrollados, particularmente Estados Unidos, en detrimento de los mercados emergentes y, de forma especialmente notoria, de los mercados andinos. La Tabla 11 detalla esta distribución.

Tabla 11. Mercados financieros abordados

Mercado / Índice	País	Tipo	Estudios
DJIA	EE.UU.	Desarrollado	E04, E13
S&P 100	EE.UU.	Desarrollado	E10
S&P 500	EE.UU.	Desarrollado	E11, E12, E15
NASDAQ 100 / Russell 2000	EE.UU.	Desarrollado	E15 (multi-índice)
CSI 300	China	Emergente	E05, E14

Mercado / Índice	País	Tipo	Estudios
BIST30	Turquía	Emergente	E06
B3 / Ibovespa	Brasil	Emergente	E02, E07, E09
SET50	Tailandia	Emergente	E03
VN30	Vietnam	Pre-emergente	E08
Multi-mercado global	Multi-país	Mixto	E09 (Brasil, EE.UU., Europa, China + commodities)

Del total de 14 estudios primarios, 6 evalúan exclusivamente mercados desarrollados de Estados Unidos: DJIA (E04, E13), S&P 100 (E10), S&P 500 (E11, E12, E15) y los índices adicionales NASDAQ 100 y Russell 2000 (E15), frente a 7 estudios que abordan mercados emergentes o pre-emergentes: CSI 300 de China (E05, E14), BIST30 de Turquía (E06), B3 de Brasil (E02, E07, E09), SET50 de Tailandia (E03) y VN30 de Vietnam (E08); el estudio E09 adopta un enfoque multi-mercado que combina diez acciones por país de Brasil, Estados Unidos, Europa y China junto con diez commodities. Ningún estudio aborda la Bolsa de Valores de Lima ni ningún otro mercado andino, lo cual constituye la brecha geográfica directa que justifica la presente investigación.

Las adaptaciones específicas para mercados emergentes documentadas en la literatura pueden agruparse en seis estrategias diferenciadas. La primera es la selección de activos por liquidez, aplicada por Conegundes y Pereira (2020; E07) y Nguyen et al. (2022; E08) en B3 y VN30 respectivamente; ambos restringen el universo a las acciones más líquidas del mercado correspondiente, dado que la profundidad limitada del libro de órdenes impide ejecutar volúmenes significativos sin impacto de precio. La segunda es la detección de turbulencia mediante distancia de Mahalanobis (E08, E10), particularmente relevante para mercados con alta volatilidad cíclica. La tercera es la incorporación de mecanismos explícitos de diversificación, como la entropía de Shannon de Candar y Üstündağ (2022; E06), para

contrarrestar la alta concentración sectorial característica de mercados como BIST30, B3 o BVL. La cuarta es la modelación de costos de transacción realistas: Conegundes y Pereira (2020; E07) emplean 0.02366% (la tasa real de B3 para day trade), Silva et al. (2025; E02) usan un costo del 3% asociado a la liquidación forzada por turbulencia, Yang et al. (2026; E14) y Huang et al. (2025; E05) emplean 0.25%, y Nguyen et al. (2022; E08) y Sun et al. (2026; E10) adoptan 0.1% y 0.2% respectivamente; en el otro extremo, varios estudios asumen costos nulos (E06: 0%), un supuesto que sus propios autores reconocen como limitación. La quinta estrategia es la integración de sentimiento en idioma local: Silva et al. (2025; E02) procesan noticias en portugués sobre el mercado brasileño con la API de Gemini Pro, demostrando la viabilidad operativa del enfoque LLM para idiomas distintos del inglés en mercados emergentes, antecedente metodológico directo para la integración de sentimiento en español que propone la presente tesis. La sexta es el transfer learning desde mercados desarrollados, aplicada por Thongkairat y Yamaka (2025; E03) al pre-entrenar modelos en el S&P 500 y realizar fine-tuning sobre el SET50 para mitigar la escasez de datos históricos.

Los desafíos específicos que enfrentan los modelos DRL en mercados emergentes se reflejan tanto en los resultados reportados como en las limitaciones declaradas por los propios autores. La baja liquidez es reconocida explícitamente en cuatro estudios (E07, E08, E11, E12) mientras que el resto la omite, lo que constituye una limitación metodológica del campo. La concentración sectorial obliga a operar con universos reducidos: Silva et al. (2025; E02) trabajan con cinco activos del Ibovespa, Conegundes y Pereira (2020; E07) con diez de B3, Yang et al. (2026; E14) con nueve o diez del CSI 300 según el portafolio. Estos tamaños son comparables al universo invertible de la BVL una vez aplicados criterios mínimos de liquidez, lo cual refuerza la transferibilidad metodológica de E02 y E07 al contexto peruano. La disponibilidad limitada de datos históricos es otro desafío recurrente: Silva et al. (2025; E02) debieron excluir a Petrobras y Vale porque sus fundamentales trimestrales solo están

disponibles desde 2019, Nguyen et al. (2022; E08) reportan que algunos tickers del VN30 carecían de historial suficiente y debieron iniciar el período de entrenamiento en mayo de 2012 para garantizar la cobertura mínima. Pese a estas restricciones, los resultados son consistentemente favorables al DRL en mercados emergentes: Candar y Üstündağ (2022; E06) reportan que PPO con entropía de Shannon obtuvo 70.02% de retorno anual y Sharpe de 1.59 sobre el BIST30, superando ampliamente al benchmark (Sharpe de 0.42); Santos et al. (2023; E09) demostraron mediante el test de Ledoit-Wolf que el RL incrementa el retorno promedio en 12% sin un aumento proporcional del riesgo, con significancia estadística confirmada; Yang et al. (2026; E14) alcanzaron un Sharpe promedio de 2.978 sobre 100 simulaciones en el CSI 300 con su algoritmo VD-MEAC.

3.7.5 Respuesta a la pregunta P5

Los entornos de simulación empleados en los estudios revisados pueden clasificarse en tres categorías principales (implementaciones propias, FinRL y sus derivados, y OpenAI Gym personalizado combinado con Stable-Baselines3), con un solapamiento parcial entre las dos últimas. La Tabla 12 sintetiza la distribución.

Tabla 12. Entornos de simulación utilizados

Framework / Entorno	N.º estudios	Estudios
Implementación propia (custom env)	9	E03, E04, E06, E07, E11, E13, E14, E15, E12
FinRL / StockPortfolioEnv	4	E02, E08, E09, E10 (StockTradingEnv)
OpenAI Gym personalizado + Stable-Baselines3	5	E05, E10, E11, E12, E08

La mayoría de los estudios (9 de 14 primarios) implementan entornos propios desde cero, lo que limita la reproducibilidad y la comparabilidad directa entre trabajos. Cinco estudios (E02, E08, E09, E10 y, parcialmente, E05) emplean FinRL o sus variantes (StockPortfolioEnv,

StockTradingEnv), aprovechando la integración nativa de FinRL con Stable-Baselines3 y su soporte para la descarga y preprocesamiento de datos. Santos et al. (2023; E09) destacan en este grupo por publicar el código y los datos completos en Harvard Dataverse (DOI: 10.7910/DVN/JEKGJ8), siendo uno de los pocos estudios plenamente reproducibles. Yang et al. (2026; E14) también publican código en GitHub (YanYang/VD-MEAC). En contraste, la gran mayoría de los estudios no publica código (E02, E03, E04, E05, E06, E07, E08, E10, E11, E12, E13, E15), aunque varios mencionan el uso de bibliotecas open-source como Stable-Baselines3 y datasets públicos como Yahoo Finance, lo que permite una reproducibilidad parcial.

Los supuestos sobre ejecución de órdenes son notablemente uniformes y, en general, optimistas. Todos los estudios asumen ejecución al precio de cierre (o de apertura en el caso de E10 y, para subastas, en E07), sin impacto de mercado ni slippage. Conegundes y Pereira (2020; E07) justifican el supuesto de slippage cero por la ejecución en las subastas de apertura y cierre de B3, que tienen una duración mínima de cinco minutos. Ayari (2026; E12) asume explícitamente «zero slippage» como condición de su evaluación. Zhang (2026; E15) reconoce abiertamente que su modelo de costos de transacción «no es adecuado para mercados ilíquidos o emergentes». Esta uniformidad de supuestos optimistas, válida en mercados altamente líquidos como el NYSE o el SSE chino, no es trasladable directamente a la BVL, donde el bid-ask spread y el impacto sobre precios de transacciones de tamaño moderado son materialmente significativos; este hecho refuerza la necesidad de desarrollar un entorno de simulación parametrizado para las condiciones operativas peruanas, objetivo que constituye el OE1 de la presente investigación.

Los períodos de entrenamiento y prueba varían considerablemente entre estudios, desde 6 meses de backtesting en E05 (lo que constituye una limitación explícita reconocida por sus autores) hasta 25 años de datos panel en E11, que cubre dos ciclos económicos completos. La

estrategia más rigurosa es la walk-forward validation, aplicada en E08 (rolling trimestral con reentrenamiento), E10 (rolling trimestral con selección por Sharpe en validación), E11 (walk-forward purificado en 2000–2025), E12 (expanding window trimestral, 4 trimestres de prueba en 2022) y E15 (walk-forward con reentrenamiento trimestral en múltiples índices). Otros estudios emplean splits estáticos train/test que no capturan el carácter iterativo de la recalibración real (E02, E05, E06, E09). La presente investigación adoptará el esquema walk-forward con reentrenamiento trimestral propuesto por Nguyen et al. (2022; E08), por considerarlo el más apropiado para un mercado con cambios de régimen frecuentes como la BVL.

Las brechas identificadas por los propios autores convergen en cuatro líneas de trabajo futuro que articulan precisamente los aportes que la presente investigación se propone realizar. La primera, manifestada en E03, E10, E11, E12, E14 y E15, es la necesidad de aplicar DRL en mercados emergentes diversos para validar la generalización de las metodologías; la BVL responde directamente a este vacío como mercado andino sin antecedentes en la literatura. La segunda, planteada por E07 y E11, es la integración de datos de sentimiento como una fuente complementaria al precio y a los fundamentales; la presente investigación la aborda mediante un pipeline de sentimiento en español procesado por API de LLM, siguiendo el patrón validado por Silva et al. (2025; E02) para portugués. La tercera, recurrente en E03, E06 y E07, es la incorporación de restricciones operativas realistas (costos, slippage, baja liquidez); el entorno de simulación parametrizado para la BVL atenderá este aspecto. La cuarta, señalada en E15, es la mejora de la interpretabilidad de los modelos para satisfacer requerimientos regulatorios y de gestión; este aspecto se aborda parcialmente mediante el diseño de escenarios de ablación de señales, que permitirán atribuir el desempeño a cada bloque de información.

3.8 Conclusiones

La revisión de 15 estudios primarios permite sintetizar los siguientes hallazgos. En primer lugar, el DRL ha demostrado capacidad consistente para superar a las estrategias tradicionales. Los algoritmos actor-critic, particularmente PPO, DDPG y SAC, dominan la literatura y producen Sharpe ratios entre 0.7 y 2.9. Las funciones de recompensa ajustadas al riesgo mejoran la estabilidad y el control de drawdown.

En segundo lugar, se identifica una brecha significativa en la cobertura geográfica. Ningún estudio aborda la BVL ni mercados andinos. La integración de señales triple (mercado + fundamentales + sentimiento en idioma local) solo ha sido explorada preliminarmente por Silva et al. (2025) en Brasil sin diferencias estadísticamente significativas entre configuraciones, y no existe un dataset estructurado que integre estas fuentes para la BVL.

En tercer lugar, la ausencia de evidencia para la BVL constituye el problema central identificado: los inversionistas peruanos no disponen de información empírica para evaluar la adopción de estrategias DRL. Las condiciones estructurales de la BVL difieren sustancialmente de los mercados evaluados, invalidando la transferencia directa de resultados.

Finalmente, la revisión identifica oportunidades metodológicas que la investigación aprovechará: la función de recompensa Sharpe de Huang et al. (2025), la entropía de Shannon de Candar y Üstündağ (2022) para diversificación en mercados concentrados, la estrategia ensemble de Nguyen et al. (2022) para adaptación al régimen de mercado, el framework FinRL de Santos et al. (2023) como base del entorno, y el diseño de escenarios de señales de Silva et al. (2025) para el análisis de ablación. Estas oportunidades, combinadas con la construcción de un pipeline de integración de datos multi-fuente, definen el alcance de esta investigación.

Capítulo 4. Objetivo 1 (PENDIENTE)

Del capítulo 4 hasta el N deben ir los resultados. Introducción, enunciar el resultado, relacionarlo con el objetivo, presentar modo de validar su construcción.

Capítulo 5. Presentación de los resultados del dataset unificado (OE2)

5.1 Introducción

El presente capítulo expone y justifica el desarrollo de los resultados asociados al segundo objetivo específico (OE2) de la investigación: *la construcción de un dataset unificado para la Bolsa de Valores de Lima (BVL) mediante la implementación de pipelines de extracción, procesamiento e integración de datos de mercado, indicadores fundamentales y scores de sentimiento derivados de noticias financieras locales*. Concretamente, se desarrollan los cuatro resultados que componen el objetivo: el Resultado 3 (pipeline de datos de mercado), el Resultado 4 (pipeline de indicadores fundamentales), el Resultado 5 (pipeline de sentimiento de noticias) y el Resultado 6 (integración en el dataset unificado). Los cuatro se encuentran implementados y verificados; las salvedades de alcance que subsisten (principalmente la composición del conjunto de ratios fundamentales y el carácter cualitativo de la validación del sentimiento) se señalan en cada sección y se consolidan al final del capítulo.

La exposición se organiza en una sección por resultado. Cada sección sigue una estructura homogénea: primero se enuncia el resultado obtenido a modo de resumen; luego se lo relaciona con el objetivo específico y se explicita el medio de verificación y el indicador objetivamente verificable comprometidos en el plan de proyecto (Tabla 2 del Capítulo 1); a continuación se describe la metodología de extracción de manera que el procedimiento sea reproducible, haciendo énfasis en la justificación de las decisiones de diseño y de calidad de datos adoptadas; y, finalmente, se presentan las evidencias (estadísticas descriptivas y visualizaciones generadas por los notebooks exploratorios) que sustentan el cumplimiento del indicador.

El código fuente que constituye el medio de verificación común a los cuatro resultados reside en el repositorio del proyecto, disponible en https://github.com/rodholguin/20221466_ProyectoFinCarrera. A lo largo del capítulo se hace

referencia a los módulos y notebooks de ese repositorio por su ruta relativa; su estructura se resume más adelante en la sección de reproducibilidad (5.6).

Conviene precisar el alcance metodológico común a los cuatro resultados. El universo de estudio está conformado por cinco empresas listadas en la BVL, seleccionadas para representar sectores económicos distintos y así poder evaluar la diversificación en el entorno de simulación: Banco de Crédito del Perú (CREDITC1, banca), Compañía de Minas Buenaventura (BUENAVC1, minería), Alicorp (ALICORC1, alimentos), Saga Falabella (SAGAC1, retail) y Corporación Aceros Arequipa (CORAREC1, manufactura). El horizonte trabajado inicialmente para la extracción fue 2005–2025, no obstante, como se documenta más adelante, el horizonte efectivamente cubierto difiere entre fuentes. Una decisión transversal a las tres fuentes de extracción (mercado, fundamentales y sentimiento) es la ausencia de imputación de datos faltantes: los valores se conservan tal como los entrega cada fuente, evitando introducir información sintética que pudiera sesgar el aprendizaje del agente. La integración (R6) introduce, por su naturaleza, algunos tratamientos explícitos de huecos al combinar fuentes de distinta frecuencia y cobertura, que se distinguen cuidadosamente de la imputación y se detallan en su sección. Las restantes transformaciones aplicadas son correcciones de escala documentadas (ajuste por acciones corporativas) y proyecciones temporales explícitas (propagación de fundamentales), que no constituyen imputación de valores ausentes.

5.2 Resultado 3: Pipeline de datos de mercado (OHLCV e indicadores técnicos)

5.2.1 Enunciado del resultado

Se implementó un pipeline funcional y reproducible de recopilación y procesamiento de datos de mercado para las cinco empresas del universo. El insumo de precio definido para el agente es el precio de cierre diario, coherente con un agente que decide a frecuencia diaria (la justificación de esta elección se desarrolla en la sección 5.5.4, junto a la integración). El pipeline obtiene la serie diaria de precios de cierre oficiales de la BVL, incorpora una capa de ajuste por acciones corporativas (splits y dividendos) que produce tres series de precio (crudo, ajustado por splits y de retorno total) y deriva sobre ella un conjunto de indicadores técnicos; de forma complementaria, completa las columnas de apertura, máximo, mínimo y volumen con datos de Yahoo Finance en las fechas en que esa fuente coincide con la BVL, aunque tales columnas no se usan como señal del agente. El dataset resultante cubre un horizonte efectivo de 2012–2025 (catorce años de cotizaciones diarias) para los cinco activos, sin valores faltantes en las series de precio y sin saltos artificiales atribuibles a la mezcla de fuentes.

5.2.2 Relación con el objetivo y verificación comprometida

Este resultado materializa la primera de las tres fuentes de señales del dataset unificado del OE2. Conforme a la Tabla 2 del Capítulo 1, el medio de verificación comprometido es el *código fuente y las estadísticas descriptivas del dataset de precios*, y el indicador objetivamente verificable es la disponibilidad de un *dataset de precios de cierre diarios con al menos cinco años de cobertura para el universo seleccionado, sin valores faltantes significativos*. El código reside en el módulo *src/market/* del repositorio (principalmente *market_client.py*, *corporate_actions.py* y *technical_indicators.py*), y las estadísticas descriptivas se generan en el notebook *exploracion_datos_bvl.ipynb*, del cual se reproducen las figuras de esta sección. En el cronograma del Plan de Proyecto del Anexo A, este resultado corresponde a las tareas

2.1 (pipeline de datos de mercado) y 2.2 (cálculo e incorporación de indicadores técnicos), y a la tarea de verificación y validación 2.3 (estadísticas descriptivas y control de faltantes). El indicador se cumple holgadamente: catorce años de cobertura diaria frente a los cinco previstos, y cero valores faltantes en el precio de cierre de los cinco activos.

5.2.3 Descubrimiento de la fuente y contrato de la API

La fuente primaria de precios es la propia BVL. A diferencia de fuentes financieras internacionales documentadas, la BVL no publica una API oficial documentada para sus cotizaciones históricas, por lo que el endpoint utilizado se identificó mediante ingeniería inversa del sitio web público (bvl.com.pe). El proceso, registrado en una secuencia de seis scripts de sondeo, consistió en: (i) descartar rutas REST adivinadas por convención; (ii) descargar y analizar sistemáticamente los bundles JavaScript del sitio en busca de referencias a la API; (iii) extraer del bundle compilado la URL base real del servicio, confirmando que el portal está construido en Angular; (iv) probar la familia de endpoints identificada hasta encontrar la combinación que devolvía datos reales; y (v) verificar el rango histórico disponible. El endpoint confirmado es una petición GET a *dataondemand.bvl.com.pe/v1/stock-quote/share-values/{nemónico}* con parámetros de fecha inicial y final en formato ISO 8601, que requiere cabeceras de navegador (Origin y Referer del dominio de la BVL) como única protección anti-scraping. La respuesta entrega el precio de cierre referencial oficial por día, que es precisamente el insumo de precio definido para el agente; las columnas de apertura, máximo, mínimo y volumen, que el agente no utiliza, se completan de forma complementaria con una segunda fuente cuando está disponible.

La segunda fuente es Yahoo Finance, consultada mediante la librería *yfinance*. Su rol es estrictamente de enriquecimiento puntual: aporta las columnas de apertura, máximo, mínimo y volumen únicamente en las fechas en que la BVL ya dispone de un registro de cierre. Para dos de los cinco tickers (SAGAC1 y CORAREC1), Yahoo no ofrece cobertura, por lo que en ellos

el registro proviene íntegramente de la BVL. La verificación del rango histórico mostró que, si bien el endpoint de la BVL acepta cualquier rango solicitado, solo devuelve datos reales a partir del 2 de enero de 2012 para los cinco activos, hecho que determina el horizonte efectivo del dataset de mercado.

5.2.4 Decisión central: la BVL como fuente autoritativa y el horizonte 2012–2025

La decisión de diseño más relevante de este pipeline consiste en establecer a la BVL como la fuente «sana y original» que prevalece sobre Yahoo, en lugar de tratar a ambas como sustitutas simétricas. Esta jerarquía no fue arbitraria, sino la respuesta a un problema detectado empíricamente. En una primera versión del pipeline, las fechas sin registro en la BVL se rellenaban con la fila completa de Yahoo (incluido el precio de cierre) cuando dicha fecha caía dentro de la cobertura de Yahoo. Esta práctica producía saltos diarios artificiales de hasta +421% en CREDITC1 y +397% en BUENAVC1, que no correspondían a movimientos reales de mercado ni a acciones corporativas, sino a la mezcla de dos fuentes expresadas en bases distintas.

El análisis de la causa reveló dos fenómenos. Primero, para CREDITC1 (un ticker de muy baja liquidez, del orden de 33 000 acciones negociadas por día) el precio de cierre de Yahoo, pese a solicitarse sin ajuste automático, viene expresado en la base de acciones vigente a la fecha de descarga y no en la vigente en cada fecha histórica; esto generaba un desfase de escala sistemático respecto al cierre crudo de la BVL. Segundo, para BUENAVC1 el ticker de Yahoo (BVN) corresponde a un ADR cotizado en la Bolsa de Nueva York y denominado en dólares, es decir, un instrumento distinto de la acción local en soles, con liquidez, spreads y paridad propios. La conclusión de diseño fue inequívoca: Yahoo nunca debe aportar el precio de cierre ni extender la cobertura hacia atrás del inicio de la BVL. En consecuencia, el dataset de mercado final adopta el horizonte 2012–2025 y descarta deliberadamente el tramo anterior (2008–2011 para CREDITC1/ALICORC1 y 2005–2011 para BUENAVC1), que solo Yahoo

cubría. Dicho historial se conserva en los archivos crudos de Yahoo únicamente como referencia y diagnóstico, pero no ingresa al dataset combinado.

La Figura 1 evidencia visualmente esta decisión. Para cada activo se contrasta la cobertura de ambas fuentes: la serie de la BVL (azul) comienza en 2012, mientras que la de Yahoo (naranja) se extiende antes, pero, en CREDITC1 y BUENAVC1, discurre en una escala manifiestamente distinta a la de la BVL en el tramo solapado, precisamente el desajuste que habría contaminado el dataset de haberse usado Yahoo como relleno de cierre. En ALICORC1, en cambio, ambas series coinciden en escala, lo que confirma que el problema es específico de los tickers de baja liquidez y del ADR, y no un defecto general de Yahoo.




Figura 3. Cobertura temporal por fuente (BVL vs. Yahoo Finance) para los cinco activos. La BVL determina el horizonte efectivo (2012–2025); el tramo previo de Yahoo se conserva solo como referencia y no integra el dataset final. Fuente: notebook exploracion_datos_bvl.ipynb, sección 3.

5.2.5 Ajuste por acciones corporativas

Los precios crudos contienen saltos generados por splits y acciones liberadas que, de no corregirse, el agente interpretaría erróneamente como variaciones de mercado. Para aislar esta distorsión, la capa de acciones corporativas (*corporate_actions.py*) deriva, a partir del cierre crudo, tres series de precio bajo la convención de ajuste hacia atrás (estándar CRSP): *close_raw* (precio efectivamente negociado, base para análisis de liquidez), *close_split_adj* (ajustado por splits y acciones liberadas) y *close_total_return* (ajustado además por la reinversión de dividendos). Esta última es la serie sobre la que se calculan los indicadores técnicos, por ser la que mejor representa la rentabilidad real percibida por el inversionista y la señal limpia que observa el agente.

La cobertura de fuentes de acciones corporativas es heterogénea entre activos, lo que obligó a un tratamiento diferenciado y explícitamente documentado:

- **CREDITC1 y ALICORC1:** se usan los splits y dividendos de yfinance del ticker correspondiente, por tratarse del mismo instrumento en soles. Para CREDITC1 esta fuente se validó de forma independiente: el producto acumulado de los ratios de sus once splits entre 2013 y 2023 da 4,1834, cifra que reproduce con un error de apenas 0,04% el desfase de escala observado empíricamente entre el cierre crudo de la BVL y el de Yahoo en ese período, lo que confirma la corrección de los ratios.
- **BUENAVC1:** dado que BVN es un ADR en dólares, sus acciones corporativas no corresponden a la acción local en soles; ante la ausencia de una fuente automatizada de hechos de importancia de la BVL/SMV en soles, se deja sin ajustar.
- **SAGAC1 y CORAREC1:** sin cobertura en Yahoo, se aplica una rutina de detección de candidatos a split (saltos diarios superiores al 40%) para revisión manual; en el horizonte 2012–2025 no se detectó ningún candidato, por lo que quedan sin ajuste.

La Figura 4 ilustra el efecto del ajuste sobre CREDITC1, el activo más afectado por distribuir acciones liberadas casi todos los años. El panel izquierdo superpone las tres series a lo largo del horizonte completo; el panel derecho amplía la acción liberada de junio de 2014 (ratio 1,2585), donde el cierre crudo cae de S/ 6,40 a S/ 5,00 sin un movimiento de mercado equivalente, mientras que la serie ajustada por splits permanece estable en torno a S/ 1,82–1,86, sin salto. Este caso documenta visualmente por qué es indispensable ajustar el precio antes de alimentar al agente.




Figura 4. Acciones corporativas de CREDITC1 (BCP). Izquierda: las tres series de precio en el horizonte 2012–2025.

Derecha: detalle de la acción liberada de junio de 2014; el salto del precio crudo desaparece tras el ajuste. Fuente: notebook `exploracion_datos_bvl.ipynb`, sección 9.

Un caso límite documentado es el salto de +46,9% de BUENAVC1 el 21 de septiembre de 2020, único candidato detectado sin posibilidad de confirmación automatizada como acción corporativa real. Este caso se deja sin ajustar y se marca para revisión manual, antes que arriesgar una corrección injustificada.

5.2.6 Indicadores técnicos derivados

Sobre la serie de retorno total se calculan, por activo, los indicadores técnicos que componen parte del espacio de observación del agente: el retorno diario, las medias móviles simple de 20 y 50 días y exponencial de 12 y 26 períodos, el MACD junto con su línea de señal, el RSI de 14 días según la formulación de Wilder y la volatilidad anualizada en ventana móvil de 20 días. Se conserva además el retorno diario calculado sobre el precio crudo para análisis de liquidez

que requieran el precio efectivamente negociado. Los primeros valores de cada indicador son nulos por construcción, al no disponer aún de la ventana completa; este comportamiento es esperado y no se rellena. La Figura 5 muestra el panel de indicadores para CREDITC1 en los últimos tres años, ejemplo de la representación que recibe el agente.




Figura 5. Indicadores técnicos de CREDITC1 (BCP) en los últimos tres años: precio con medias móviles, MACD, RSI de 14 días y volumen. Fuente: notebook exploracion_datos_bvl.ipynb, sección 5.

5.2.7 Control de calidad y estadísticas descriptivas

El pipeline aplica tres controles de calidad: el filtrado de cierres en cero que la BVL devuelve en días sin referencia oficial; la normalización de zona horaria de los registros de Yahoo a fechas sin zona horaria, compatible con la BVL; y un reporte de discrepancias que compara, en las fechas solapadas, el cierre ajustado por splits de la BVL contra el de Yahoo, señalando divergencias superiores al 2%. Con el objetivo de garantizar la calidad de los datos extraídos

del proyecto, no se aplica imputación alguna: el volumen permanece nulo en todos los registros provenientes de la BVL (el endpoint no lo entrega) y los huecos de cobertura no se rellenan.

La Tabla 13 resume las estadísticas descriptivas del dataset final y constituye, junto con las figuras, la evidencia directa del indicador. Los cinco activos cubren de manera homogénea el período 2012-01-02 a 2025-12-31 (catorce años), con entre 3 321 y 3 513 registros diarios cada uno, y (el dato decisivo para el indicador) cero valores faltantes en el precio de cierre. La columna de volumen promedio aparece como no disponible en los tres activos que carecen de enriquecimiento de Yahoo (BUENAVC1, SAGAC1 y CORAREC1), reflejo de la limitación del endpoint de la BVL ya señalada, no de una pérdida de datos.

Tabla 13. Estadísticas descriptivas del dataset de mercado (horizonte efectivo 2012–2025).

Ticker	Empresa	Registros	Precio mín. (S/)	Precio máx. (S/)	Vol. prom.	NaN en cierre
CREDITC1	BCP	3 511	1,98	8,40	543 958	0
BUENAVC1	Buenaventura	3 499	12,05	117,00	N/D	0
ALICORC1	Alicorp	3 513	3,90	11,99	373 148	0
SAGAC1	Saga Falabella	3 321	4,25	9,80	N/D	0
CORAREC1	Aceros Arequipa	3 513	0,37	2,97	N/D	0

La efectividad del ajuste por acciones corporativas se constata cuantitativamente: tras la corrección del merge, ningún retorno diario sobre la serie de retorno total supera el 100% en ninguno de los cinco activos (el máximo observado es 46,9% en BUENAVC1, el salto no confirmado ya comentado), frente a los saltos de hasta +421% y +397% que presentaban

CREDITC1 y BUENAVC1 antes de la corrección. La validación de las series ajustadas se completa con dos visualizaciones adicionales del notebook: los precios normalizados en base 100 (Figura 6), que permiten comparar el rendimiento relativo de los cinco activos sobre una escala común, y la matriz de correlación de retornos (Figura 7), insumo directo para la discusión de diversificación que motiva la elección de un activo por sector.




Figura 6. Precios de cierre normalizados en base 100, rendimiento relativo de los cinco activos en el horizonte 2012–2025.

Fuente: notebook exploracion_datos_bvl.ipynb, sección 4.




Figura 7. Matriz de correlación de los retornos diarios entre los cinco activos. Las correlaciones moderadas respaldan la diversificación buscada al seleccionar un activo por sector. Fuente: notebook exploracion_datos_bvl.ipynb, sección 8.

En síntesis, el Resultado 3 se cumple satisfactoriamente: el indicador objetivamente verificable preveía al menos cinco años de precios de cierre diarios sin faltantes significativos, y el pipeline entrega catorce años de cobertura diaria continua, con cero valores faltantes en el precio de cierre y con una capa de ajuste por acciones corporativas validada empíricamente que garantiza una señal de precio libre de artefactos.

5.3 Resultado 4: Pipeline de indicadores fundamentales trimestrales

5.3.1 Enunciado del resultado

Se implementó un pipeline de extracción de estados financieros trimestrales (balance general, estado de resultados y flujo de efectivo) para las cinco empresas del universo, a partir del web service SOAP de Datos Abiertos de la Superintendencia del Mercado de Valores (SMV). De cada empresa se obtiene el detalle de cuentas contables y un conjunto de campos resumen, a partir de los cuales se derivan cinco ratios financieros. Cada registro incorpora una fecha de conocimiento público que permite integrar el dato al panel diario sin incurrir en sesgo de anticipación. El dataset cubre el horizonte completo 2005–2025 (84 trimestres por activo), sin huecos y sin necesidad de imputación.

5.3.2 Relación con el objetivo y verificación comprometida

Este resultado aporta la segunda fuente de señales del dataset unificado. El medio de verificación comprometido es el *código fuente y una muestra de datos extraídos validados manualmente*, y el indicador objetivamente verificable es la disponibilidad de *indicadores fundamentales trimestrales para el período de estudio*. El conjunto de indicadores trabajado está conformado por cinco ratios derivados directamente de los estados financieros (ROE, ROA, margen neto, deuda/patrimonio y deuda/activo), escogidos por ser calculables de manera homogénea para los cinco activos a partir de los campos resumen del servicio. El código reside en *src/fundamentals/fundamentals_client.py* y las evidencias se generan en el notebook *exploracion_fundamentales_bvl.ipynb*. En el cronograma del Plan de Proyecto (Anexo A), este resultado corresponde a la tarea 2.4 (integración del código de estados financieros y extracción de fundamentales desde la SMV) y a la tarea de verificación y validación 2.5 (validación manual de una muestra). El indicador se cumple: se dispone de indicadores fundamentales trimestrales para todo el período de estudio en los cinco activos. La subsección 5.3.6

documenta, además, la exploración de indicadores adicionales (como el P/E y el Dividend Yield) para enriquecer ese conjunto, y por qué no fue posible incorporarlos con la fiabilidad necesaria.

5.3.3 Descubrimiento de la fuente y contrato del servicio SOAP

A diferencia del pipeline de mercado, la búsqueda de la fuente de fundamentales partió de dos candidatos. El primero, el endpoint de estados financieros de la BVL (dataondemand, familia financialstatements), se sondeó exhaustivamente con decenas de combinaciones de método, ubicación del ticker y nombres de campo, y en todas devolvió HTTP 200 con cuerpo nulo o error 404. Se concluyó que dicho endpoint está inoperativo para fundamentales (estado confirmado a junio de 2026), por lo que se conserva en el código solo como stub de compatibilidad. El segundo candidato, el servicio SOAP de la SMV, sí respondía, y se adoptó como fuente primaria y única viable.

La elección de la SMV se justifica plenamente desde lo metodológico: es el organismo regulador ante el cual las empresas listadas están legalmente obligadas a presentar sus estados financieros, de modo que los datos son oficiales, estructurados, de acceso gratuito y (de manera crucial para evitar el sesgo de anticipación) se publican bajo la misma cronología que un inversionista real habría tenido. El servicio se expone mediante un WSDL (*mvnet.smv.gob.pe/ws_od_eeff/WebServiceInfoFinanciera.asmx*). Su contrato se determinó por sondeo, ya que los nombres y valores de los parámetros no están documentados: las operaciones principales aceptan los parámetros Ejercicio (año), Periodo (trimestre como dígito «1» a «4») y Tipo («I» para individual o «C» para consolidado). Se utiliza el tipo individual para los cinco activos por consistencia y porque es el que todas reportan a tiempo.

Una particularidad determinante del servicio es que no admite filtro por empresa: cada llamada devuelve los datos de las aproximadamente 261 empresas registradas en la SMV para el

trimestre solicitado, con un peso del orden de 8 MB por respuesta. El filtrado al universo de cinco activos se realiza en el cliente mediante el código único de registro (RPJ) de cada empresa, con un respaldo de coincidencia parcial por nombre. Los códigos RPJ, no documentados públicamente, se obtuvieron buscando cada empresa dentro de la respuesta completa del servicio; se recogen en la Tabla 14. Esta desambiguación fue especialmente necesaria en el caso de Saga Falabella, cuyo RPJ (014313) debió distinguirse de otras entidades del mismo grupo presentes en el registro (Banco Falabella y Falabella Perú).

Tabla 14. Códigos RPJ confirmados para el filtrado por empresa en el servicio de la SMV.

Ticker BVL	RPJ	Nombre en el registro SMV	Moneda de reporte
CREDITC1	B80005	Banco de Crédito del Perú	PEN
BUENAVC1	B20003	Compañía de Minas Buenaventura S.A.A.	PEN→USD (desde 2006-Q4)
ALICORC1	B30006	Alicorp S.A.A.	PEN (USD en 2025-Q4)
SAGAC1	014313	Saga Falabella S.A.	PEN
CORAREC1	CI0003	Corporación Aceros Arequipa S.A.	PEN

5.3.4 Procesamiento, esquema de datos y prevención del sesgo de anticipación

Las respuestas del servicio se transforman a un formato largo (tidy), en el que cada fila corresponde a una cuenta contable de un trimestre. El esquema canónico resultante, definido en *src/universe.py*, se resume en la Tabla 15; los montos se conservan en miles de la moneda reportada, unidad nativa del servicio. Para reducir la carga de red, dado que cada llamada descarga las 261 empresas, se implementó un sistema de caché en dos niveles (memoria de proceso y disco), de modo que el procesamiento del segundo al quinto activo reutiliza las

respuestas ya descargadas para el primero; al concluir la extracción, el directorio de caché contiene un archivo JSON por cada combinación de operación, trimestre y tipo del rango cubierto.

Tabla 15. Esquema canónico del dataset de fundamentales (formato largo).

Columna	Descripción
ticker	Código de la acción en la BVL (p. ej., ALICORC1).
period	Fecha de cierre del trimestre, en formato ISO 8601 (p. ej., 2023-12-31).
known_date	Fecha estimada de publicación pública del estado financiero (cierre del trimestre + 45 días).
account	Código de cuenta con prefijo de estado financiero (ver Tabla 4).
value	Monto de la cuenta, en miles de la moneda reportada.
currency	Moneda de presentación: PEN o USD.
source	Fuente del dato; siempre «smv» en el pipeline actual.

Los códigos de cuenta de la SMV se preprocesan con prefijos que identifican el estado financiero de origen y la naturaleza del monto, según la Tabla 16. Cabe destacar que la operación de ganancias y pérdidas devuelve simultáneamente dos montos por cuenta (el del trimestre aislado y el acumulado del ejercicio), que el pipeline separa en dos registros con sufijos _Q y _YTD respectivamente.

Tabla 16. Prefijos de cuentas y su correspondencia con los estados financieros.

Prefijo	Estado financiero / contenido
BG_	Balance general (situación financiera); saldo al cierre del período.
GP_Q_	Ganancias y pérdidas, valor del trimestre aislado.

Prefijo	Estado financiero / contenido
GP_YTD_	Ganancias y pérdidas, acumulado del ejercicio.
CF_	Flujo de efectivo, acumulado del ejercicio.
INFO_	Resumen de alto nivel: ActivoTotal, PasivoTotal, PatrimonioTotal, TotalIngreso, UtilidadNeta.

El campo de fecha de conocimiento público es crítico para la integridad metodológica del modelo de decisión. Se calcula como la fecha de cierre del trimestre más 45 días calendario. La normativa de la SMV fija fechas límite de presentación de los estados financieros intermedios individuales que equivalen a unos 30 días tras el cierre para los tres primeros trimestres y a aproximadamente 46 días para el cuarto (al 30 de abril, 31 de julio, 31 de octubre y 15 de febrero, respectivamente; SMV, 2023, art. 15). El uso uniforme de 45 días constituye así un desfase fijo que cubre con margen el plazo de los tres primeros trimestres y aproxima el del cuarto, garantizando que en ningún día de negociación el modelo utilice información que aún no estuviera públicamente disponible.

En la fase de integración (R6), los fundamentales se incorporan al panel diario mediante una unión temporal hacia atrás sobre esta fecha, garantizando que en ningún día de negociación se utilice información que no habría estado públicamente disponible en ese momento. Esta es la única transformación temporal aplicada (una proyección de frecuencia, no una imputación de valores).

5.3.5 Hallazgos de calidad de datos relevantes para la tesis

La extracción produjo varios hallazgos que constituyen material citable para la discusión metodológica:

- **Cambios de moneda de reporte:** Buenaventura reportó sus primeros siete trimestres en soles y, a partir del cuarto trimestre de 2006, cambió a dólares, coherente con ser

una minera cuyos ingresos están atados a commodities cotizados en dólares. De forma análoga, Alicorp reportó un único trimestre (cuarto de 2025) en dólares. En ambos casos, los ratios no se ven afectados (numerador y denominador comparten moneda dentro de cada fila), pero los montos absolutos no son comparables a través de esos puntos de corte sin conversión de tipo de cambio, que se decidió no implementar; los trimestres en moneda distinta se excluyen automáticamente de los gráficos de montos absolutos, no de los de ratios.

- **Taxonomía contable del banco:** El BCP, supervisado por la Superintendencia de Banca y Seguros, reporta con un plan de cuentas más granular (443 cuentas frente a unas 398 de las demás empresas). Los ratios de rentabilidad se calculan igual, pero indicadores como deuda/activo tienen una lectura distinta en un banco, donde el pasivo incluye los depósitos de clientes (el modelo de negocio) y no apalancamiento financiero en el sentido de una empresa no financiera.

La normalización de moneda contempló incluso una codificación corrupta de la tilde observada en algunas respuestas del servicio, mapeando explícitamente todas las variantes a códigos limpios.

5.3.6 Exploración de indicadores adicionales (P/E y Dividend Yield)

Sobre el conjunto de cinco ratios se exploró la posibilidad de enriquecerlo con dos indicadores de mercado habituales: la relación precio-beneficio (P/E) y el rendimiento por dividendo (Dividend Yield). Ambos requieren un insumo que ninguna fuente disponible ofrece de forma fiable para los cinco activos en todo el horizonte: el número de acciones en circulación por trimestre (P/E, vía la utilidad por acción) o los dividendos por acción (DY). Para el número de acciones se evaluaron tres alternativas, documentadas en los scripts *check_shares_sources.py* y *check_shares_b.py* del repositorio:

- **Campo `sharesOutstanding` de `yfinance`:** entrega solo el valor actual, no una serie histórica por trimestre; para los instrumentos peruanos resultó además ausente o inconsistente.
- **Capital Emitido de la SMV (cuenta 1D0701) dividido por el valor nominal de la acción:** exige conocer un valor nominal estable y verificado por empresa y período, dato que no está en el servicio (vive en estatutos y prospectos) y que puede cambiar por reorganizaciones de capital; además mezcla acciones comunes, de inversión y en cartera.
- **Endpoint `share` de la BVL:** no devuelve información de acciones en circulación.

A ello se suma que la operación de cambios en el patrimonio del servicio SOAP no respondió en una prueba en vivo y que las memorias anuales viven en un sistema no explorado, cuya extracción representaría un subproyecto en sí mismo. El único camino acotado sería reconstruir las acciones de CREDITC1 reutilizando su factor de splits ya validado (Sección 5.2.5), lo que cubriría solo uno de los cinco activos. Ante la ausencia de una fuente confiable de acciones en circulación para el universo completo, el P/E queda fuera del conjunto de indicadores; no obstante, la función `compute_ratios` prevé un parámetro de mercado que permitiría incorporarlo si en el futuro se resuelve ese insumo. El Dividend Yield es un caso más cercano: los dividendos por acción de CREDITC1 y ALICORC1 ya están disponibles a través del pipeline de mercado, de modo que su cálculo es factible para esos dos activos; se documenta aquí como un enriquecimiento natural del conjunto, acotado por la misma limitación de fuente para los tres activos restantes.

5.3.7 Evidencias del resultado

La Tabla 17 reporta las estadísticas descriptivas del dataset de fundamentales y evidencia el cumplimiento del indicador: los cinco activos cubren 84 trimestres (83 en CREDITC1, por un único trimestre no reportado), desde el primer trimestre de 2005 hasta el cuarto de 2025, con

el número de cuentas y la moneda esperados por empresa. Se incluye, a título ilustrativo, el último ROE y ROA calculado para cada activo.

Tabla 17. Estadísticas descriptivas del dataset de fundamentales (horizonte 2005–2025).

Ticker	Rango	Cuentas	Moneda	ROE (últ.)	ROA (últ.)
CREDITC1	2005-Q1 / 2025-Q4 (83 periodos)	443	PEN	5,82%	0,78%
BUENAVC1	2005-Q1 / 2025-Q4 (84 periodos)	398	PEN/USD	9,44%	7,25%
ALICORC1	2005-Q1 / 2025-Q4 (84 periodos)	398	PEN/USD	-4,86%	-0,72%
SAGAC1	2005-Q1 / 2025-Q4 (84 periodos)	398	PEN	17,94%	5,03%
CORAREC1	2005-Q1 / 2025-Q4 (84 periodos)	397	PEN	1,87%	0,98%

La estructura del balance de los cinco activos (Figura 8) muestra cómo se financia el activo total y permite apreciar visualmente la diferencia estructural del banco (con un peso del pasivo muy superior por la naturaleza de los depósitos) frente a las empresas no financieras, así como la escala relativa de cada empresa. La validación de la identidad contable (activo igual a pasivo más patrimonio) aparece como línea superpuesta.




Figura 8. Estructura del balance (activo, pasivo y patrimonio) de los cinco activos, 2005–2025; los trimestres en moneda distinta se excluyen y señalan. Fuente: notebook exploracion_fundamentales_bvl.ipynb, sección 3.

La evolución trimestral de los cuatro ratios principales (Figura 9) constituye la señal fundamental que observa el agente. Se aprecia, por ejemplo, el ratio deuda/activo estructuralmente alto y estable del banco frente a la mayor variabilidad de las empresas no financieras, y los episodios de rentabilidad negativa de Buenaventura en años de bajo precio del oro. La comparativa del último trimestre disponible (Figura 10) sintetiza el contraste sectorial entre los cinco activos.




Figura 9. Evolución trimestral de los ratios fundamentales (ROE, ROA, margen neto y deuda/activo) de los cinco activos, 2005–2025. Fuente: *notebook exploracion_fundamentales_bvl.ipynb*, sección 5.




Figura 10. Comparativa de ratios fundamentales entre las cinco empresas en el último trimestre disponible. Fuente: *notebook exploracion_fundamentales_bvl.ipynb*, sección 6.

En conjunto, el Resultado 4 se cumple: se dispone de indicadores fundamentales trimestrales para todo el período de estudio en los cinco activos, con cobertura completa, calidad documentada y sin imputación. El conjunto de cinco ratios cubre la rentabilidad y el apalancamiento de cada empresa de forma homogénea y comparable, y la exploración de

indicadores adicionales como el P/E y el Dividend Yield (Sección 5.2.6) deja trazada la vía para enriquecerlo en cuanto se disponga de una fuente confiable de acciones en circulación.

5.4 Resultado 5: Pipeline de sentimiento de noticias

5.4.1 Enunciado del resultado

Se implementó un pipeline completo que construye, para las cinco empresas del universo, una señal diaria de sentimiento de prensa derivada de noticias en español. El pipeline recopila las noticias desde la plataforma Media Cloud (acotadas a la colección nacional de Perú y filtradas a un conjunto de medios económicos de referencia mediante consultas booleanas diseñadas por empresa) y clasifica el sentimiento de cada noticia con un modelo de lenguaje local, agregando luego un score diario por activo. El corpus íntegro, de 11 566 noticias, fue clasificado en su totalidad (cero noticias sin clasificar) y produce los archivos de sentimiento diario que alimentan la integración del dataset unificado (R6).

5.4.2 Relación con el objetivo y verificación comprometida

Este resultado aporta la tercera fuente de señales del dataset unificado. El medio de verificación comprometido es el *código fuente y las métricas de calidad de clasificación en una muestra manual*, y el indicador objetivamente verificable es la generación de *scores de sentimiento diarios para el período de estudio con concordancia aceptable respecto a un etiquetado manual*. El código reside en *src/sentiment/mediacloud_client.py* (recopilación) y *src/sentiment/llm_sentiment.py* (clasificación y agregación diaria); las evidencias se generan en los notebooks *exploracion_noticias_mediacloud.ipynb* (corpus crudo) y *exploracion_sentimiento_bvl.ipynb* (resultados de la clasificación). En el Plan de Proyecto (Anexo A), este resultado corresponde a las tareas 2.6 (recopilación de noticias) y 2.7 (clasificación de sentimiento y agregación de scores diarios), y a la tarea de verificación y validación 2.8 (validación sobre muestra manual). El componente de generación de scores

diarios se cumple en su totalidad; el componente de concordancia respecto a un etiquetado manual se aborda mediante una validación cualitativa (face validity) y no mediante una métrica cuantitativa de acuerdo inter-anotador, salvedad que se detalla en la subsección 5.4.6.

5.4.3 Metodología de recopilación y clasificación

A diferencia de R3 y R4, donde el trabajo consistió en descubrir un endpoint o un contrato no documentado, en R5 tanto la fuente (la API de Media Cloud) como el motor de clasificación (un modelo servido localmente) son herramientas documentadas; el esfuerzo de diseño se concentró en tres frentes: elegir el ámbito de búsqueda correcto, acotar las consultas para evitar la ambigüedad de nombres y clasificar miles de noticias sin incurrir en costo de API. El ámbito se fijó en la colección nacional de Perú, identificada mediante la API de directorio de la plataforma y compartida por los cinco activos. Para cada empresa se construyó una consulta booleana que combina los nombres y alias del emisor con un vocabulario de anclaje financiero (acción, bolsa, BVL, utilidad, inversión, mercado, entre otros), necesario para desambiguar términos polisémicos: «Buenaventura» captura además una ciudad colombiana homónima y a futbolistas de ese apellido, y «Falabella» captura la cadena chilena, por lo que se exigieron las frases «Minas Buenaventura» y «Saga Falabella» respectivamente. Una asimetría de diseño relevante (citada más adelante como causa de ruido) es que la consulta de Aceros Arequipa quedó sin ancla financiera, solo con la frase exacta del nombre.

Sobre el resultado se aplicó un filtro por dominio que conserva únicamente tres medios nacionales de referencia (gestion.pe, elcomercio.pe y larepublica.pe), descartando tabloides, medios deportivos y fuentes extranjeras que se infiltran en la colección nacional agregada. El pipeline incorpora reintentos con espera exponencial ante errores transitorios y una pausa entre páginas para respetar los límites de tasa. Una limitación estructural de la fuente, determinante para la clasificación, es que la operación de listado no devuelve el cuerpo del artículo: la

clasificación opera únicamente sobre el titular, suficiente para el sentimiento financiero de corto plazo, pero de cobertura textual parcial.

La clasificación se resolvió con un modelo de lenguaje local (gemma3:4b servido mediante Ollama), en lo que constituye una divergencia respecto al plan original, que contemplaba una API de un modelo comercial. La motivación fue de costo y privacidad: clasificar más de once mil noticias con un proveedor en la nube habría implicado un costo por token y una dependencia de cuota, mientras que el modelo local no tiene costo marginal por llamada. El precio de esa decisión es la velocidad: sin GPU, el ritmo medido fue de diez a diecisiete segundos por artículo, lo que obligó a ejecutar la clasificación en varias sesiones a lo largo de varios días. Esto fue posible sin pérdida de trabajo gracias a una caché por noticia que se persiste a disco periódicamente, de modo que cada relanzamiento del proceso retoma exactamente donde se interrumpió. El clasificador produce, por noticia, una etiqueta en tres clases (positivo, negativo, neutral) y una confianza autoreportada, en formato JSON estricto; los scores por noticia (con la codificación +1, 0, -1) se promedian luego a un score diario por activo, acompañado del conteo de noticias del día.

5.4.4 Resultados de la clasificación

La Tabla 18 resume el corpus clasificado por activo. El volumen es marcadamente heterogéneo: CREDITC1 (banca, blue-chip) concentra 7 933 noticias, un orden de magnitud por encima de SAGAC1 (380) o CORAREC1 (690), lo que refleja la realidad de la cobertura mediática peruana (la banca genera mucha más prensa que el retail o la manufactura) y no un artefacto del pipeline. La consecuencia directa, relevante para la integración, es que la señal de sentimiento cubre apenas entre el 7,7% y el 58,3% de los días de mercado según el activo, con un promedio del 24,5%.

Tabla 18. Resumen de la clasificación de sentimiento por activo.

Ticker	Noticias	Días con señal	% cobertura mercado	Score medio	% pos / neu / neg	Confianza media
CREDITC1	7 933	2 734	58,3%	-0,07	24,9 / 41,5 / 33,6	0,731
BUENAVC1	978	697	18,3%	+0,07	47,1 / 11,0 / 41,8	0,787
ALICORC1	1 585	1 085	25,9%	+0,04	39,3 / 25,2 / 35,5	0,761
SAGAC1	380	331	7,7%	+0,03	32,1 / 34,2 / 33,7	0,724
CORAREC1	690	495	12,2%	-0,03	38,4 / 20,7 / 40,9	0,767

La composición de etiquetas por activo (Figura 11) muestra un balance razonable entre las tres clases, con CREDITC1 destacando por su alta proporción de noticias neutrales. La confianza autoreportada del modelo (Figura 12) se mantiene en un rango angosto (entre 0,60 y 0,95 en las 11 566 noticias) y es sistemáticamente menor para la clase neutral (media 0,668) que para positivo o negativo (alrededor de 0,78); esto es coherente (el modelo declara menos certeza cuando no encuentra una señal clara de impacto), pero advierte que la confianza es una heurística interna del modelo y no una probabilidad calibrada, por lo que no debe usarse como peso estadístico sin más.




Figura 11. Composición de sentimiento (positivo, neutral, negativo) por activo, a nivel de noticia. Fuente: notebook exploracion_sentimiento_bvl.ipynb, sección 3.




Figura 12. *Confianza autoreportada del modelo por etiqueta. El rango angosto [0,60–0,95] indica que no es una probabilidad calibrada. Fuente: notebook exploracion_sentimiento_bvl.ipynb, sección 4.*

La serie temporal del score diario suavizado (Figura 13) permite observar la evolución del clima de prensa por activo a lo largo del horizonte, así como la densidad muy desigual de la señal: densa y continua para CREDITC1, dispersa para SAGAC1 y CORAREC1. La cobertura por año (Figura 14) confirma la tendencia creciente del volumen de prensa a partir de 2017 y el dominio sostenido de CREDITC1.




Figura 13. Score de sentimiento diario por activo (con media móvil de ~180 días). Fuente: notebook exploracion_sentimiento_bvl.ipynb, sección 5.




Figura 14. Noticias clasificadas por año y empresa. Fuente: notebook exploracion_sentimiento_bvl.ipynb, sección 6.

5.4.5 Relación del sentimiento con el retorno de mercado

Más allá de describir el corpus, se exploró si la señal de sentimiento guarda relación con el retorno de mercado, cruzando el score diario con los retornos del dataset de R3. La correlación contemporánea (score del día con el retorno del mismo día) es prácticamente nula en los cinco activos, mientras que la correlación con el retorno del día siguiente es positiva en los cinco casos (consistente en signo, aunque débil en magnitud), con Alicorp destacando (Pearson 0,081). Una correlación lineal débil no implica ausencia de valor: no descarta una relación no lineal que un agente de aprendizaje por refuerzo podría aprovechar mejor que un coeficiente de correlación, pero sí pone un techo realista a la expectativa de esta señal por sí sola. El análisis de evento (Figura 15), que promedia el retorno del día siguiente según el signo del sentimiento del día, refuerza esta lectura: en cuatro de los cinco activos el retorno medio tras un sentimiento positivo es el más alto de los tres grupos, un patrón direccional consistente con la hipótesis de trabajo, aunque de magnitud pequeña (décimas de punto porcentual).




Figura 15. Retorno medio del día siguiente según el signo del sentimiento del día. Fuente: *notebook exploracion_sentimiento_bvl.ipynb*, sección 10.

Un hallazgo adicional, útil para la integración, es que el conteo diario de noticias (no el score, sino el volumen de cobertura) correlaciona positivamente con la volatilidad para CREDITC1 y ALICORC1 (alrededor de 0,18): los días de mayor cobertura de prensa tienden a coincidir con periodos de mayor volatilidad, lo que sugiere que el número de noticias puede ser, en sí mismo, una variable informativa independiente del sentimiento.

5.4.6 Limitaciones de la clasificación

La validación de calidad es cualitativa (revisión de los titulares de mayor confianza por etiqueta y activo), no una métrica cuantitativa de acuerdo contra un conjunto etiquetado por humanos; esta es la salvedad respecto al indicador (**se realizará luego a medida de verificación**, se priorizó tener la integración funcional). Esa inspección reveló la limitación más importante del resultado: un nivel de ruido temático en la etapa de recuperación de noticias, anterior a la clasificación. Una fracción de los titulares no es información específica de la empresa, sino menciones incidentales, por ejemplo, los resúmenes diarios de cierre de la Bolsa de Valores de Lima, que listan varios valores y aparecen replicados el mismo día como noticia de varias empresas a la vez. El caso es estructural para Aceros Arequipa, cuya consulta carece de ancla financiera y por ello admite cualquier mención del nombre. Es importante precisar que esto no es un error del modelo (que clasifica correctamente el sentimiento del texto que recibe) sino un problema de relevancia en la consulta de noticias, y es la explicación más plausible de por qué la correlación con el retorno es débil. Otras limitaciones documentadas son la dependencia exclusiva del titular, la confianza no calibrada del modelo, la cobertura muy desigual entre activos y el uso de solo tres medios nacionales (que omite prensa internacional relevante para Buenaventura, que cotiza también en Nueva York). **Se tiene pensado añadir una columna adicional de relevancia (clasificación alto-bajo-medio) para mitigar este problema.**

5.5 Resultado 6: Dataset unificado

5.5.1 Enunciado del resultado

Se construyó el panel único que combina las tres fuentes de señales: mercado e indicadores técnicos (R3), sentimiento de noticias (R5) y fundamentales trimestrales (R4) sobre el calendario común de días hábiles de la Bolsa de Valores de Lima, sin sesgo de anticipación en ninguna de ellas y con un tratamiento explícito de los huecos de cada fuente. El resultado es un archivo consolidado de 17 565 filas (5 activos $\times$ 3 513 días bursátiles) y 36 columnas, con clave (ticker, fecha), que cubre el horizonte 2012-01-02 a 2025-12-31 y constituye el espacio de observación que consumirá el entorno de simulación. A diferencia de R3, R4 y R5 (cada uno una fuente nueva), R6 no agrega datos: los combina, y es precisamente en esa combinación donde surgieron la mayoría de las decisiones de diseño documentadas aquí, ninguna resuelta de antemano.

5.5.2 Relación con el objetivo y verificación comprometida

Este resultado es la culminación del OE2: el dataset integrado que habilita los experimentos posteriores. El medio de verificación comprometido es el *archivo consolidado, el diccionario de datos y las estadísticas descriptivas*, y el indicador objetivamente verificable es un *dataset integrado con las tres fuentes de señales alineadas temporalmente, listo para consumo por el entorno de simulación*. El archivo consolidado es *data/processed/dataset_unificado.parquet*; el diccionario de datos se presenta en la Tabla 19 (esquema de las 36 columnas); las estadísticas descriptivas se generan en el notebook *exploracion_integracion_bvl.ipynb*, y el código reside en *src/integration/build_dataset.py*. El indicador se cumple en su totalidad: las tres fuentes quedan alineadas sobre un calendario común, sin look-ahead, y el panel resultante es directamente consumible por el entorno. Las cuatro «vistas» de señales que requieren los

experimentos (solo mercado, con sentimiento, con fundamentales y completa) son selecciones de columnas sobre este mismo panel, no datasets separados.

5.5.3 Decisiones de diseño de la integración

El calendario bursátil se construye como la unión de las fechas con cotización de cualquiera de los cinco activos (3 513 días). Se decidió que esta responsabilidad recae en la capa de datos (R6) y no en el entorno de simulación, porque el calendario define las filas del panel; delegarlo al entorno habría obligado a reconciliar cinco series con índices de fecha distintos en tiempo de ejecución. Sobre ese calendario, cada fuente recibió un tratamiento explícito:

- **Sentimiento: alineación sin decaimiento precalculado.** En vez de fijar a mano una tasa de decaimiento del sentimiento (un hiperparámetro que se optimizaría sobre una métrica proxy, no sobre el desempeño real del agente), se decidió, por sugerencia del asesor, que ese decaimiento lo aprenda el agente. El panel guarda por ello cuatro columnas crudas en lugar de un score ya decaído: el último score observado (con relleno hacia adelante), los días hábiles transcurridos desde la última noticia, una bandera de si hubo noticia ese día y el conteo de noticias. Así una etapa posterior puede aprender cómo descontar la señal a partir de los días transcurridos, sin que el investigador fije la tasa.
- **Sentimiento: roll-forward de noticias en día no bursátil.** Entre el 7,4% y el 25,1% de las noticias caen en días no bursátiles (sobre todo fines de semana). Sin una regla, se perderían. Se reasignan al siguiente día hábil (no al anterior, que sería look-ahead: ese día ya cerró antes de que la noticia existiera); si ese día ya tenía noticia propia, ambas se reagregan con media ponderada por número de artículos. Roll-forward y relleno hacia adelante son mecanismos distintos que se componen: el primero ubica un

evento puntual en el calendario, el segundo mantiene el último valor los días posteriores sin noticia (mientras la bandera vuelve a cero y el contador de días sigue creciendo).

- **Fundamentales: propagación sin look-ahead.** Cada día de mercado recibe el último trimestre que ya era público, mediante una unión temporal hacia atrás sobre la fecha de conocimiento público. Como la primera fecha de conocimiento de los cinco activos (15 de mayo de 2005) es muy anterior al inicio del horizonte de mercado, no hay huecos al comienzo del panel.
- **Mercado: días sin cotización de un activo.** Al reindexar cada activo sobre el calendario común quedaron expuestos días en que la BVL operó pero un activo no cotizó (192 en SAGAC1, 14 en BUENAVC1, 2 en CREDITC1). En esas filas se arrastra el último precio conocido (precio «stale») y se recalculan los indicadores técnicos sobre la serie ya completa (de modo que el retorno diario es cero y la volatilidad decae correctamente durante el tramo sin operación) y una bandera de «no negociado» marca esas filas para que el entorno pueda modelar el costo de iliquidez. Coherentemente con la decisión de usar solo el precio de cierre (documentada para el conjunto del proyecto), no se completan apertura, máximo, mínimo ni volumen.

5.5.4 Decisión de usar únicamente el precio de cierre

Una decisión transversal a R3 y R6, ahora formalizada, es emplear únicamente el precio de cierre (ajustado por acciones corporativas y dividendos) como insumo de precio del agente, en lugar de perseguir el OHLCV completo. La justificación es cuádruple. Primero, los indicadores técnicos ya implementados se calculan exclusivamente sobre la serie de cierre; ninguno usa apertura, máximo, mínimo ni volumen. Segundo, el agente decide una vez al día: el rango intradía del día en curso no es información sobre la que pueda actuar de forma causal, y su único aporte sería un estimador de volatilidad más eficiente, una ganancia estadística y no de

señal. Tercero, el volumen no está disponible para tres de los cinco activos bajo ninguna circunstancia, por lo que no puede ser una variable uniforme. Cuarto, usar OHLCV completo solo para los dos activos que sí lo tienen introduciría una asimetría de información dentro del mismo portafolio, difícil de justificar frente a usar el cierre de forma homogénea en los cinco. El tradeoff aceptado es renunciar a un estimador de volatilidad basado en rango y a cualquier señal de volumen, a cambio de una representación de estado consistente y comparable entre los cinco activos, construida sobre la misma fuente y el mismo tipo de ajuste.

5.5.5 Diccionario de datos del panel unificado

La Tabla 19 documenta las 36 columnas del panel, agrupadas por origen. Constituye el diccionario de datos comprometido como medio de verificación.

Tabla 19. Diccionario de datos del panel unificado (36 columnas, clave ticker + date).

Grupo	Columnas	Descripción
Identificación	ticker, date	Clave del panel: activo y día bursátil.
Mercado (R3)	open, high, low, close, volume, source, close_raw, close_split_adj, close_total_return, is_split_adjusted, is_div_adjusted	Precio y banderas de ajuste; close_total_return es la serie que ve el agente.
No-trade (R6)	is_no_trade	1 si el activo no cotizó ese día (precio stale); 0 en otro caso.
Indicadores técnicos	ret_1d, ret_1d_raw, sma_20, sma_50, ema_12, ema_26, macd, macd_signal, rsi_14, volatility_20	Recalculados en R6 sobre la serie completa (incluye tramos no negociados).
Sentimiento (R5)	sentiment_score_last, days_since_news, has_news, n_articles	Último score (forward-fill), días desde la última noticia, bandera y conteo del día.
Fundamentales (R4)	period, known_date, currency, roe, roa, net_margin, debt_equity, debt_ratio	Trimestre propagado sin look-ahead y los cinco ratios derivados.

5.5.6 Evidencias del resultado

La integración no introdujo valores faltantes en las señales clave del panel: los ratios fundamentales y las cuatro columnas de sentimiento tienen cero NaN en las 17 565 filas, y el único residuo es el mínimo irreducible de catorce filas por activo en el RSI (las primeras catorce sesiones, sin ventana completa). La Tabla 20 resume la cobertura por activo, que expone con nitidez la asimetría de liquidez del universo: SAGAC1 concentra el 92% de los días sin negociación del panel.

Tabla 20. Cobertura del panel unificado por activo.

Ticker	Filas propias (R3)	Días no negociados	Cobertura sentim. (post roll-forward)	NaN RSI
CREDITC1	3 511	2	60,7%	14 (0,4%)
BUENAVC1	3 499	14	19,1%	14 (0,4%)
ALICORC1	3 513	0	28,2%	14 (0,4%)
SAGAC1	3 321	192	9,2%	14 (0,4%)
CORAREC1	3 513	0	13,6%	14 (0,4%)

El roll-forward de noticias recupera entre 0,9 y 1,6 puntos porcentuales de cobertura por activo (304 días-activo en total que de otro modo se habrían perdido). La cola de la variable «días desde la última noticia» es muy pesada y desigual entre activos (con máximos de 277 a 403 días hábiles), lo que motiva su transformación logarítmica al construir la observación del agente (Figura 16).




Figura 16. Distribución de «días desde la última noticia» por activo, en escala cruda y logarítmica. Fuente: notebook

exploracion_integracion_bvl.ipynb, sección 3.

La propagación de los fundamentales produce la característica forma escalonada del valor a lo largo del tiempo: el ratio cambia exactamente en cada fecha de conocimiento público, sin interpolación, como ilustra el ROE del banco entre 2019 y 2021 (Figura 17). El tratamiento de los días sin cotización se aprecia en la Figura 18, que muestra una racha de SAGAC1 con precio constante durante el tramo no negociado y el salto real al reanudarse la negociación.




Figura 17. ROE de CREDITC1 (zoom 2019–2021): escalones discretos de la propagación hacia adelante desde cada fecha de conocimiento público. Fuente: notebook exploracion_integracion_bvl.ipynb, sección 5.




Figura 18. *SAGAC1: racha de sesiones sin operar (precio stale) y salto real al reanudar la negociación. Fuente: notebook exploracion_integracion_bvl.ipynb, sección 6.*

En síntesis, el Resultado 6 se cumple plenamente: existe un archivo consolidado, con su diccionario de datos y sus estadísticas descriptivas, que integra las tres fuentes de señales alineadas temporalmente sin sesgo de anticipación, listo para ser consumido por el entorno de simulación.

5.6 Consideraciones de reproducibilidad

El conjunto de pipelines se organiza en un repositorio modular cuya configuración (universo de activos, fuentes y rutas) se centraliza en un archivo *config.yaml*, de modo que la reproducción de los resultados no exige modificar el código fuente. La Tabla 21 resume la estructura del repositorio relevante para los tres resultados reportados. El detalle de implementación a nivel de código no se reproduce en este capítulo, pero se encuentran completos en el repositorio del trabajo.

Tabla 21. Estructura del repositorio relevante para R3, R4 y R5.

Componente	Función
config.yaml	Configuración central: universo, fuentes y rutas.
src/universe.py	Definición del universo y esquemas canónicos (mercado, fundamentales, sentimiento).
src/market/market_client.py	Extracción y combinación de datos de mercado (BVL + Yahoo).
src/market/corporate_actions.py	Capa de ajuste por splits y dividendos (tres series de precio).
src/market/technical_indicators.py	Cálculo de indicadores técnicos.
src/fundamentals/fundamentals_client.py	Extracción SMV, caché y cálculo de ratios.
src/sentiment/mediacloud_client.py	Extracción de noticias, consultas ancladas y lista blanca de medios.
src/sentiment/llm_sentiment.py	Clasificación de sentimiento (Ollama) y agregación diaria.
src/integration/build_dataset.py	Integración del panel unificado y vistas de señales (R6).

Componente	Función
scripts/probe_*, scripts/check_*	Sondas de descubrimiento de endpoints y validación de fuentes.

La reproducibilidad se refuerza con la convención de almacenamiento por capas en formato Parquet; se tiene una capa *raw* que conserva la salida de cada fuente por separado, una capa *interim* con las series combinadas y enriquecidas, y una capa *processed* reservada para el dataset unificado final de la integración (R6). Los sistemas de caché que hacen idempotente la re-ejecución de la extracción de fundamentales y de la clasificación de sentimiento, las sondas que documentan cómo se identificaron las fuentes no documentadas, y los tres notebooks de exploración que constituyen el medio de verificación de cada resultado. Esta separación por capas permite reconstruir el proceso desde cualquier etapa y auditar cada transformación aplicada.

Capítulo 6. Conclusiones y trabajos futuros

6.1 Conclusiones

6.2 Trabajos futuros

Referencias

- Araci, D. (2019). FinBERT: Financial sentiment analysis with pre-trained language models (arXiv:1908.10063). arXiv. <https://doi.org/10.48550/arXiv.1908.10063>
- Artzner, P., Delbaen, F., Eber, J. M., & Heath, D. (1999). Coherent measures of risk. *Mathematical Finance*, 9(3), 203–228. <https://doi.org/10.1111/1467-9965.00068>
- Arulkumaran, K., Deisenroth, M. P., Brundage, M., & Bharath, A. A. (2017). Deep reinforcement learning: A brief survey. *IEEE Signal Processing Magazine*, 34(6), 26–38. <https://doi.org/10.1109/MSP.2017.2743240>
- Ayari, R. (2026). Feature configuration effects in DRL portfolio management: A risk-focused evaluation under market stress. *Quantitative Finance*, 26(1), 119–136. <https://doi.org/10.1080/14697688.2025.2592822>
- Bekaert, G., & Harvey, C. R. (2003). Emerging markets finance. *Journal of Empirical Finance*, 10(1–2), 3–55. [https://doi.org/10.1016/S0927-5398\(02\)00054-3](https://doi.org/10.1016/S0927-5398(02)00054-3)
- Bodie, Z., Kane, A., & Marcus, A. J. (2014). *Investments* (10th ed.). McGraw-Hill Education.
- Bolsa de Valores de Lima [BVL]. (2023). *Memoria anual 2022*. Bolsa de Valores de Lima S.A.A.
- Brockman, G., Cheung, V., Pettersson, L., Schneider, J., Schulman, J., Tang, J., & Zaremba, W. (2016). OpenAI Gym. arXiv:1606.01540.
- Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D., Wu, J., Winter, C., ... Amodei, D. (2020). Language models are few-shot learners. In *Advances in Neural Information Processing Systems* (Vol. 33, pp. 1877–1901).
- Candar, M., & Üstündağ, A. (2022). Equity portfolio optimization using reinforcement learning: Emerging market case. In *Intelligent and Fuzzy Systems, Lecture Notes in Networks and Systems* (Vol. 505, pp. 131–139). Springer Nature Switzerland AG. https://doi.org/10.1007/978-3-031-09176-6_16
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.
- Conegundes, L., & Pereira, A. C. M. (2020). Beating the stock market with a deep reinforcement learning day trading system. In *2020 IEEE International Joint Conference on Neural Networks (IJCNN)*. IEEE.
- DeMiguel, V., Garlappi, L., & Uppal, R. (2009). Optimal versus naive diversification: How inefficient is the 1/N portfolio strategy? *The Review of Financial Studies*, 22(5), 1915–1953. <https://doi.org/10.1093/rfs/hhm075>

- Du, K., Xing, F., Mao, R., & Cambria, E. (2024). Financial sentiment analysis: Techniques and applications. *ACM Computing Surveys*, 56(9), Article 220. <https://doi.org/10.1145/3649451>
- Fabozzi, F. J., & Modigliani, F. (2009). *Capital markets: Institutions and instruments* (4th ed.). Pearson Prentice Hall.
- Gemma Team. (2025). Gemma 3 technical report. Google DeepMind. arXiv:2503.19786. <https://arxiv.org/abs/2503.19786>
- Gu, F., Jiang, Z., García-Fernández, A. F., Stefanidis, A., Su, J., & Li, H. (2025). *MTS: A deep reinforcement learning portfolio management framework with time-awareness and short-selling* (arXiv:2503.04143). arXiv. <https://doi.org/10.48550/arXiv.2503.04143>
- Haarnoja, T., Zhou, A., Abbeel, P., & Levine, S. (2018). Soft Actor-Critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. *Proceedings of the 35th International Conference on Machine Learning (ICML)*. arXiv.. <https://arxiv.org/abs/1801.01290>
- Harris, C. R., Millman, K. J., van der Walt, S. J., et al. (2020). Array programming with NumPy. *Nature*, 585, 357–362.
- Hasbrouck, J. (2007). *Empirical market microstructure: The institutions, economics, and econometrics of securities trading*. Oxford University Press.
- Hernández Sampieri, R., Fernández Collado, C., & Baptista Lucio, P. (2014). *Metodología de la investigación* (6ª ed.). McGraw-Hill.
- Huang, G., Zhou, X., & Song, Q. (2025). *A deep reinforcement learning framework for dynamic portfolio optimization: Evidence from China's stock market* [Working paper]. Chongqing University.
- Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95.
- IBM. (2024). *What is an API (Application Programming Interface)?* IBM Think.
- Jiang, Z., Xu, D., & Liang, J. (2017). A deep reinforcement learning framework for the financial portfolio management problem. *arXiv preprint arXiv:1706.10059*.
- Jurafsky, D., & Martin, J. H. (2025). *Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition* (3rd ed., draft). Prentice Hall.
- Kitchenham, B., & Charters, S. (2007). *Guidelines for performing systematic literature reviews in software engineering* (Version 2.3, EBSE Technical Report EBSE-2007-01). Keele University & University of Durham.
- Lawton, S. R., & Jeewa, A. (2024). Deep reinforcement learning for automated stock trading using different reward schemes. In *2024 IEEE International Conference on Future Machine*

Ledoit, O., & Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411. [https://doi.org/10.1016/S0047-259X\(03\)00096-4](https://doi.org/10.1016/S0047-259X(03)00096-4)

Lillicrap, T. P., Hunt, J. J., Pritzel, A., Heess, N., Erez, T., Tassa, Y., Silver, D., & Wierstra, D. (2016). Continuous control with deep reinforcement learning. *4th International Conference on Learning Representations (ICLR)*. <https://arxiv.org/abs/1509.02971>

Liu, C., Arulappan, A., Naha, R., Mahanti, A., Kamruzzaman, J., & Ra, I. H. (2024). Large language models and sentiment analysis in financial markets: A review, datasets and case study. *IEEE Access*.

Liu, X.-Y., Yang, H., Chen, Q., Zhang, R., Yang, L., Xiao, B., & Wang, C. D. (2020). FinRL: A deep reinforcement learning library for automated stock trading in quantitative finance. *Deep RL Workshop, NeurIPS 2020*.

Liu, X.-Y., Yang, H., Gao, J., & Wang, C. D. (2021). FinRL: Deep reinforcement learning framework to automate trading in quantitative finance. *ACM International Conference on AI in Finance (ICAIF)*.

Loughran, T., & McDonald, B. (2011). When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks. *The Journal of Finance*, 66(1), 35–65. <https://doi.org/10.1111/j.1540-6261.2010.01625.x>

Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1), 77–91. <https://doi.org/10.1111/j.1540-6261.1952.tb01525.x>

McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 56–61.

McKinney, W. (2017). *Python for data analysis* (2nd ed.). O'Reilly Media.

Michaud, R. O. (1989). The Markowitz optimization enigma: Is 'optimized' optimal? *Financial Analysts Journal*, 45(1), 31–42. <https://doi.org/10.2469/faj.v45.n1.31>

Mishkin, F. S. (2019). *The economics of money, banking, and financial markets* (12th ed.). Pearson.

Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., Graves, A., Riedmiller, M., Fidjeland, A. K., Ostrovski, G., Petersen, S., Beattie, C., Sadik, A., Antonoglou, I., King, H., Kumaran, D., Wierstra, D., Legg, S., & Hassabis, D. (2015). Human-level control through deep reinforcement learning. *Nature*, 518(7540), 529–533. <https://doi.org/10.1038/nature14236>

MSCI. (2024). *MSCI Global Investable Market Indexes Methodology*. MSCI Inc.

- Nguyen, H.-T. N., Mac, B.-N. N., Tran, A.-D., Nguyen, N.-T., & Pham, D.-T. (2022). Deep reinforcement learning approach using customized technical indicators for a pre-emerging market: A case study of Vietnamese stock market. In *2022 RIVF International Conference on Computing and Communication Technologies (RIVF)*. IEEE. <https://doi.org/10.1109/RIVF55975.2022.10013836>
- Nie, Y., Kong, Y., Dong, X., Mulvey, J. M., Poor, H. V., Wen, Q., & Zohren, S. (2024). A survey of large language models for financial applications: Progress, prospects and challenges (arXiv:2406.11903). arXiv.
- Ollama. (s. f.). Ollama: Get up and running with large language models locally [software]. Recuperado de <https://ollama.com>
- Ortegón, E., Pacheco, J. F., & Prieto, A. (2005). *Metodología del marco lógico para la planificación, el seguimiento y la evaluación de proyectos y programas* (Serie Manuales N.º 42). CEPAL. <https://repositorio.cepal.org/handle/11362/5607>
- Pardo, R. (2008). *The evaluation and optimization of trading strategies* (2nd ed.). Wiley Trading.
- Paszke, A., Gross, S., Massa, F., et al. (2019). PyTorch: An imperative style, high-performance deep learning library. *NeurIPS 2019*, 8024–8035.
- Python Software Foundation. (n.d.). *Python language reference*. Retrieved from <https://docs.python.org/>
- Raffin, A., Hill, A., Gleave, A., Kanervisto, A., Ernestus, M., & Dormann, N. (2021). Stable-Baselines3: Reliable reinforcement learning implementations. *Journal of Machine Learning Research*, 22(268), 1–8.
- Roberts, H., Bhargava, R., Valiukas, L., Jen, D., Malik, M. M., Bishop, C. S., Ndulue, E. B., Dave, A., Clark, J., Etling, B., Faris, R., Shahar, A., Wihbey, J., & Zuckerman, E. (2021). Media Cloud: Massive open source collection of global news on the open web. Proceedings of the International AAAI Conference on Web and Social Media, 15, 1034–1045. <https://doi.org/10.1609/icwsm.v15i1.18127>
- Rockafellar, R. T., & Uryasev, S. (2000). Optimization of conditional value-at-risk. *Journal of Risk*, 2(3), 21–42. <https://doi.org/10.21314/JOR.2000.038>
- Santos, G. C., Garruti, D., Barboza, F., Souza, K. G. de, Domingos, J. C., & Veiga, A. (2023). Management of investment portfolios employing reinforcement learning. *PeerJ Computer Science*, 9, e1695. <https://doi.org/10.7717/peerj-cs.1695>
- Schröer, C., Kruse, F., & Gómez, J. M. (2021). A systematic literature review on applying CRISP-DM process model. *Procedia Computer Science*, 181, 526–534. <https://doi.org/10.1016/j.procs.2021.01.199>
- Sharpe, W. F. (1994). The Sharpe ratio. *The Journal of Portfolio Management*, 21(1), 49–58. <https://doi.org/10.3905/jpm.1994.409501>

- Silva, K. C., Fernandes, D., Fernandes, M., Soares, F., & Sousa, T. M. de. (2025). Systematic review of portfolio optimization in the Brazilian financial market: Integrating news and fundamental indicators with deep reinforcement learning. In *CSCI 2024, Communications in Computer and Information Science* (Vol. 2503, pp. 19–32). Springer Nature Switzerland AG. https://doi.org/10.1007/978-3-031-94940-1_2
- Silva, K. C., Sá, F., Fernandes, D., Fernandes, M., & Soares, F. (2025). A deep reinforcement learning approach for portfolio optimization of Brazilian assets using fundamental and sentiment indicators. In *Proceedings of the 49th IEEE Annual Computers, Software, and Applications Conference (COMPSAC 2025)*. IEEE. <https://doi.org/10.1109/COMPSAC65507.2025.00258>
- Sortino, F. A., & van der Meer, R. (1991). Downside risk. *The Journal of Portfolio Management*, 17(4), 27–31. <https://doi.org/10.3905/jpm.1991.409343>
- Superintendencia del Mercado de Valores [SMV]. (2023). *Memoria anual 2022*. Superintendencia del Mercado de Valores del Perú.
- Superintendencia del Mercado de Valores (SMV). (2023). Normas sobre preparación, presentación y difusión de estados financieros, memoria anual e informe de gerencia aplicables a las entidades supervisadas por la SMV (Resolución SMV N.º 013-2023-SMV/01). Diario Oficial El Peruano. <https://www.gob.pe/institucion/smv/normas-legales/4924243-013-2023-smv-01>
- Sun, Y. J., Lu, Z. Y., Liao, C. H., Dai, T. S., & Yuan, S. M. (2026). Optimizing stock portfolios with deep reinforcement learning after FNN-based fundamental analysis. *Quantitative Finance*, 26(1), 137–159. <https://doi.org/10.1080/14697688.2025.2604770>
- Sutton, R. S., & Barto, A. G. (2018). *Reinforcement learning: An introduction* (2nd ed.). MIT Press.
- Teles, L. E. P., & Figueiredo, C. M. S. (2025). Comparing LLMs for sentiment analysis in financial market news. arXiv:2510.15929. <https://arxiv.org/abs/2510.15929>
- Thongkairat, S., & Yamaka, W. (2025). A combined algorithm approach for optimizing portfolio performance in automated trading: A study of SET50 stocks. *Mathematics*, 13(3), 461. <https://doi.org/10.3390/math13030461>
- Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021.
- Xue, P., & Ye, Y. (2025). Attention-enhanced reinforcement learning for dynamic portfolio optimization (arXiv:2510.06466). arXiv. <https://arxiv.org/abs/2510.06466>
- Yang, Y., Wang, T., Fu, Y., Huang, J., & Zhou, D. (2026). Portfolio management based on value distribution reinforcement learning algorithm. *Frontiers in Artificial Intelligence*, 8, 1709493. <https://doi.org/10.3389/frai.2025.1709493>

Zhang, B. (2026). Graph attention-based heterogeneous multi-agent deep reinforcement learning for adaptive portfolio optimization. *Scientific Reports*, 16, 2674. <https://doi.org/10.1038/s41598-025-32408-w>

Anexos

Los anexos deben ser referenciados desde el documento. Por ejemplo, debe existir un párrafo

donde se diga que determinada información puede ser vista en el Anexo X

Los anexos pueden numerarse con letras o número de acuerdo con su preferencia.

Anexo A: Plan de Proyecto

● Justificación

La justificación del proyecto se estructura siguiendo los criterios propuestos por Hernández Sampieri et al. (2014) para evaluar la importancia de una investigación: conveniencia, relevancia social, implicaciones prácticas, valor teórico y utilidad metodológica.

Conveniencia

El proyecto genera evidencia empírica actualmente inexistente sobre la viabilidad e idoneidad de agentes de deep reinforcement learning (DRL) para la optimización dinámica de portafolios en la Bolsa de Valores de Lima (BVL). Esta evidencia es necesaria porque las condiciones estructurales del mercado peruano (altos costos de transacción, baja liquidez y alta concentración sectorial) impiden extrapolar directamente los resultados validados en mercados desarrollados y emergentes de alta capitalización.

Relevancia social

Los beneficiarios directos son los inversionistas y gestores de portafolios del mercado peruano, quienes dispondrían de una base informada para evaluar la adopción de estrategias cuantitativas y algorítmicas. De manera indirecta, la academia y la industria financiera local se benefician al reducirse la brecha tecnológica respecto a mercados donde estas técnicas ya se aplican con resultados documentados. Finalmente, entidades como fondos de inversión y empresas pueden llegar a aprovechar la información para destinar su capital.

Implicaciones prácticas

El proyecto entrega artefactos reutilizables: un entorno de simulación parametrizado para las condiciones operativas de la BVL, un dataset unificado que integra tres fuentes de señales (mercado, fundamentales y sentimiento en español) y un conjunto de agentes DRL entrenados y evaluados. Estos productos pueden servir de base para futuras investigaciones y para el desarrollo de herramientas de apoyo a la decisión de inversión.

Valor teórico

La investigación llena un vacío de conocimiento concreto: ningún estudio de la literatura revisada aborda la BVL ni otros mercados andinos, y la integración estructurada de señales de mercado, fundamentales y sentimiento en idioma local solo ha sido explorada de forma preliminar en el mercado brasileño. El proyecto aporta así una primera caracterización empírica del desempeño del DRL bajo las condiciones de un mercado emergente andino.

Utilidad metodológica

El proyecto produce un pipeline de integración de datos multi-fuente y un esquema de clasificación de sentimiento financiero en español basado en modelos de lenguaje de gran escala (LLM) en modalidad zero-shot, replicables en otros mercados de la región. Asimismo, la adaptación de un entorno de simulación a las fricciones reales de un mercado de baja liquidez constituye un aporte metodológico transferible.

- **Viabilidad**

El análisis de viabilidad evalúa la disponibilidad de recursos, conocimientos y fuentes de información necesarios para ejecutar el proyecto, así como la factibilidad tanto del proceso como de los productos resultantes.

Viabilidad técnica

El proyecto se sustenta en un ecosistema de software libre y maduro (Python, Pandas, NumPy, PyTorch, OpenAI Gym, FinRL y Stable-Baselines3), ampliamente validado en la literatura de DRL aplicado a finanzas. El tesista cuenta con los conocimientos de programación, aprendizaje automático y finanzas cuantitativas requeridos, consolidados durante la fase de formulación del proyecto. La arquitectura prevista (redes MLP sobre datos tabulares y tensores de tamaño moderado, con un universo reducido de activos) no exige cómputo intensivo, por lo que resulta ejecutable en CPU o en instancias de GPU de bajo costo bajo demanda.

Viabilidad de la información

Las tres fuentes de datos son accesibles: los datos de cierre se obtienen de la BVL, los indicadores fundamentales trimestrales se extraen de la Superintendencia del Mercado de Valores (SMV) y las noticias se recopilan mediante la API de Media Cloud y se clasifican con un LLM local (Ollama), sin costo de consumo de API. El antecedente de Silva et al. (2025) en el mercado brasileño confirma la viabilidad operativa del enfoque de sentimiento basado en LLM para idiomas distintos del inglés en mercados emergentes.

Viabilidad económica

Los costos del proyecto son bajos y asumibles por el tesista. El software es de código abierto y, por tanto, sin costo de licencias; los costos previstos de la API de LLM son acotados dado el volumen moderado de noticias de un universo reducido de emisores; y las necesidades de cómputo se cubren con recursos de la universidad y, de ser necesario, con instancias de GPU en la nube de costo reducido. El detalle de la estimación de costos se presenta en la sección A.7.

Viabilidad temporal y operativa

El alcance acotado del proyecto (universo de activos filtrado por liquidez, evaluación mediante backtesting, tres algoritmos DRL y tres estrategias de referencia) es compatible con el horizonte de marzo a noviembre de 2026. Desde el punto de vista operativo y legal, el proyecto emplea datos de fuentes públicas con fines exclusivamente académicos, sin despliegue en producción ni emisión de recomendaciones de inversión sobre capital real, lo que evita restricciones regulatorias. Se concluye que el proyecto es viable en sus dimensiones técnica, de información, económica, temporal y operativa.

- **Alcance**

A continuación, se describen las actividades de primer nivel de descomposición que el proyecto sí incluye y las que quedan explícitamente excluidas.

Actividades incluidas

- Construcción de los pipelines de extracción, procesamiento e integración de las tres fuentes de datos (mercado, fundamentales y sentimiento) y consolidación del dataset unificado de la BVL (OE2: R3, R4, R5 y R6).
- Diseño e implementación de un entorno de simulación de tipo Gym/FinRL parametrizado para las condiciones operativas de la BVL (costos de transacción, restricciones de liquidez y universo de activos), documentado mediante la metodología CRISP-DM (OE1: R1 y R2).
- Entrenamiento de tres agentes DRL (PPO, DDPG y SAC) y estudio comparativo frente a las estrategias de referencia (Markowitz, Buy & Hold y Equal Weight), bajo cuatro configuraciones de señales de entrada y con evaluación walk-forward mediante las métricas Sharpe ratio, Maximum Drawdown y retorno anualizado (OE3: R7 y R8).
- Documentación de los resultados (Capítulo 4), redacción de conclusiones y trabajos futuros (Capítulo 5), integración del documento final y preparación de la sustentación.

Actividades excluidas

- Despliegue en producción u operación en tiempo real; el proyecto se limita a la simulación y al backtesting.
- Trading intradiario y negociación de instrumentos distintos a la renta variable (renta fija, derivados, divisas, criptomonedas o commodities).
- Emisión de recomendaciones de inversión a clientes reales o gestión de capital real.
- Diseño y entrenamiento de un modelo propio de procesamiento de lenguaje natural para la clasificación de sentimiento de noticias.

Universo y datos: El estudio se circunscribe a un universo de acciones de renta variable de la BVL filtrado por criterios de liquidez (las acciones más líquidas que cumplan los umbrales mínimos definidos), con al menos cinco años de datos diarios y frecuencia de operación diaria, en línea con los tamaños de universo empleados por estudios comparables de la literatura (entre cinco y diez activos).

● Limitaciones

- **De tiempo:** el horizonte de ejecución está fijado entre junio y noviembre de 2026, con un único desarrollador (el tesista) de dedicación parcial, condicionado además por el calendario académico (entregas del curso, exámenes y reuniones de asesoría).
- **De presupuesto:** los recursos son limitados y financiados por el tesista, sin partida para fuentes de datos premium de pago ni para capacidad de cómputo masivo en GPU externo al proporcionado por la universidad.
- **De datos:** el historial de indicadores fundamentales en la SMV puede ser limitado para algunos emisores, lo que podría obligar a excluirlos del universo; y la cobertura de noticias en español es desigual entre emisores.
- **De funcionalidad:** el proyecto contempla únicamente backtesting; no se garantiza el desempeño en operación real, y los resultados están condicionados al régimen de mercado del período evaluado, riesgo que se mitiga mediante la validación walk-forward sobre múltiples ventanas temporales

- **Identificación de los riesgos del proyecto**

ID	Descripción	Síntomas	Prob.	Impacto	Severidad	Mitigación	Contingencia
R-01	Cambios en la estructura o en las interfaces de acceso de la SMV o de la BVL que inutilicen los extractores de datos.	Errores de parseo, cambios de formato o de endpoints, descargas vacías.	Media	Alto	Alta	Encapsular la lógica de extracción en módulos aislados; descargar y respaldar tempranamente snapshots completos de los datos.	Operar sobre los respaldos locales; recurrir a fuentes alternativas (Yahoo Finance para precios).
R-03	Daño o indisponibilidad del servidor de entrenamiento (fallo de hardware, corte de servicio, sobrecarga, corrupción del entorno).	Caída del servidor, pérdida de conexión, procesos detenidos sin checkpoint.	Media	Alto	Alta	Guardar checkpoints periódicos en almacenamiento externo; monitorear salud del servidor; usar tmux/screen con registro de logs.	Recuperar último checkpoint desde respaldo y reanudar en instancia alternativa (local o nube).
R-04	Cobertura insuficiente o ruidosa de noticias en español para varios emisores del universo.	Pocos artículos por día; numerosos días sin noticias para un emisor.	Media	Medio	Media	Recopilar de múltiples portales; usar una ventana de agregación amplia y propagación hacia adelante del score de sentimiento.	Restringir la fuente de sentimiento a los emisores con cobertura adecuada; tratar el sentimiento como señal opcional en las configuraciones.
R-06	Retraso del cronograma por depuración (debugging) extensa o tiempos de ejecución muy prolongados.	Hitos vencidos; acumulación de tareas pendientes entre fases.	Alta	Alto	Muy alta	Incluir holguras (buffers) entre fases; priorizar los resultados críticos; desarrollar de forma iterativa con un producto mínimo viable.	Recortar el alcance opcional (menos configuraciones de señales o menos semillas); reprogramar tareas no críticas.
R-07	Pérdida de información o de trabajo por fallo de hardware o ausencia de respaldo.	Pérdida de archivos, código o modelos entrenados.	Baja	Alto	Media	Usar control de versiones (Git/GitHub) y respaldos automáticos en la nube desde el inicio.	Restaurar el trabajo desde el repositorio remoto y los respaldos en la nube.

ID	Descripción	Síntomas	Prob.	Impacto	Severidad	Mitigación	Contingencia
R-08	Eventos externos que afecten la disponibilidad del tesista o asesor (enfermedades, accidentes, situaciones familiares, etc.)	Hitos vencidos; acumulación de tareas pendientes, pérdida de comunicación entre tesista-asesor.	Baja	Alto	Media	Sin mitigación.	Redefinir plazos de entrega y prioridades de entrega. En caso corresponda, coordinar para la asignación de un co-asesor.

- **Estructura de descomposición del trabajo (EDT)**

La EDT descompone el proyecto de forma jerárquica orientada a los entregables y resultados, organizándolos en cinco paquetes de trabajo: la gestión transversal del proyecto y los tres objetivos específicos (que agrupan los resultados R1 a R8), más la documentación y el cierre. La representación adoptada es esquemática mediante codificación jerárquica.

Código	Bloque de Trabajo
1	Gestión del proyecto
1.1	Planificación detallada y validación del plan con el asesor
1.2	Reuniones semanales de seguimiento con el asesor
1.3	Control de avance, gestión de riesgos y respaldos (control de versiones)
2	OE2 – Construcción del dataset unificado (fuente de datos)
2.1	Pipeline de datos de mercado: precios de cierre e indicadores técnicos (R3)
2.2	Pipeline de indicadores fundamentales trimestrales (R4)
2.3	Pipeline de recopilación de noticias y scoring de sentimiento con LLM local (R5)
2.4	Integración temporal y construcción del dataset unificado (R6)
2.5	Verificación y validación de los datos (estadísticas, muestras, diccionario)
3	OE1 – Entorno de simulación de la BVL
3.1	Informe de aplicación de la metodología CRISP-DM (R1)
3.2	Diseño e implementación del entorno de simulación (R2)
3.3	Pruebas del entorno: unitarias y de ejecución de episodios (V&V)
4	OE3 – Entrenamiento y evaluación comparativa
4.1	Entrenamiento de agentes DRL: PPO, DDPG y SAC, con múltiples semillas (R7)
4.2	Estudio comparativo y backtesting walk-forward (R8)
4.3	Análisis estadístico, intervalos de confianza y visualizaciones (V&V)
5	Documentación y cierre

Código	Bloque de Trabajo
5.1	Redacción del capítulo de presentación de resultados
5.2	Redacción de conclusiones y trabajos futuros
5.3	Integración y revisión final del documento (formato y citas)
5.4	Preparación y sustentación de la defensa

● Lista de tareas

La lista de tareas detalla, para cada actividad, su duración estimada (en semanas), el esfuerzo asociado (en horas-persona, h-p) y el costo estimado (en soles peruanos, S/). Incluye las actividades de verificación y validación (V&V), las reuniones con el asesor y las actividades del curso.

Supuestos de estimación

- Moneda: soles peruanos (S/).
- Tarifa de referencia del tesista: S/ 25 por hora-persona, empleada únicamente para estimar el costo de oportunidad del esfuerzo (no implica un desembolso real).
- Dedicación estimada del tesista: aproximadamente 22 a 24 horas semanales a lo largo de unas 26 semanas (junio a noviembre de 2026).
- Las horas del asesor se consideran un aporte institucional y no se costean como desembolso, aunque sí se registran como parte del seguimiento.
- Los costos directos del proyecto (API de LLM, cómputo en la nube, internet/energía y materiales) se detallan por separado tras la lista de tareas.

Cód.	Tarea	Tipo	Dur. (sem)	Esf. (h-p)	Costo (S/)
Fase 0 – Gestión del proyecto (transversal: junio a noviembre)					
1.1	Planificación detallada del proyecto y validación del plan con el asesor	Gestión	1.0	8	200
1.2	Reuniones semanales de seguimiento con el asesor (26 reuniones de 0,5 h + preparación)	Gestión	26	26	650
1.3	Control de avance, gestión de riesgos y respaldos en control de versiones	Gestión	26	20	500
Fase 1 – OE2: Construcción del dataset unificado (junio a inicios de julio)					

Cód.	Tarea	Tipo	Dur. (sem)	Esf. (h-p)	Costo (S/)
2.1	Diseño e implementación del pipeline de datos de mercado (precios de cierre) desde la BVL (R3)	Desarrollo	1.5	30	750
2.2	Cálculo e incorporación de indicadores técnicos al pipeline de mercado (R3)	Desarrollo	0.5	12	300
2.3	V&V del pipeline de mercado: estadísticas descriptivas y control de faltantes	V&V	0.5	8	200
2.4	Integración del código de EEFF y extracción de fundamentales desde la SMV (R4)	Desarrollo	1.5	30	750
2.5	V&V del pipeline de fundamentales: validación manual de una muestra	V&V	0.5	8	200
2.6	Pipeline de recopilación de noticias financieras en español de portales locales (R5)	Desarrollo	1.0	24	600
2.7	Clasificación de sentimiento vía LLM local y agregación de scores diarios (R5)	Desarrollo	1.0	20	500
2.8	V&V del pipeline de sentimiento: muestra etiquetada manual, concordancia y F1	V&V	0.5	10	250
2.9	Integración temporal y construcción del dataset unificado de tres fuentes (R6)	Desarrollo	1.0	20	500
2.10	Diccionario de datos y estadísticas descriptivas del dataset unificado (V&V)	V&V	0.5	10	250
Fase 2 – OE1: Entorno de simulación de la BVL (julio a inicios de agosto)					
3.1	Elaboración del informe CRISP-DM: comprensión del negocio y de los datos, preparación y diseño (R1)	Desarrollo	1.5	24	600
3.2	Diseño del entorno: espacios de estado y acción, función de recompensa, costos y liquidez (R2)	Desarrollo	1.0	20	500

Cód.	Tarea	Tipo	Dur. (sem)	Esf. (h-p)	Costo (S/)
3.3	Implementación del entorno de simulación custom (Gym/FinRL) para la BVL (R2)	Desarrollo	2.0	40	1000
3.4	V&V del entorno: pruebas unitarias y ejecución de episodios completos sin errores	V&V	1.0	16	400
Fase 3 – OE3: Entrenamiento y estudio comparativo (agosto a octubre)					
4.1	Configuración e integración de Stable-Baselines3 (PPO, DDPG, SAC) con el entorno (R7)	Desarrollo	1.0	18	450
4.2	Entrenamiento y ajuste de hiperparámetros de los agentes (≥ 3 semillas por algoritmo) (R7)	Desarrollo	3.0	60	1500
4.3	V&V de los agentes: análisis de curvas de convergencia y estabilidad entre semillas	V&V	0.5	10	250
4.4	Diseño experimental e implementación de las estrategias de referencia (baselines) (R8)	Desarrollo	1.0	20	500
4.5	Backtesting walk-forward con reentrenamiento trimestral y múltiples semillas (R8)	Desarrollo	2.5	50	1250
4.6	Cálculo de métricas, pruebas estadísticas e intervalos de confianza (R8)	V&V	1.0	20	500
4.7	Generación de visualizaciones: curvas de valor, drawdown, heatmaps y boxplots (R8)	Desarrollo	0.5	12	300
Fase 4 – Documentación y cierre (octubre a noviembre)					
5.1	Redacción del Capítulo 4: presentación de resultados y su validación	Documentación	2.0	36	900
5.2	Redacción del Capítulo 5: conclusiones y trabajos futuros	Documentación	1.0	16	400
5.3	Integración del documento completo, formato y revisión de citas	Documentación	1.0	20	500

Cód.	Tarea	Tipo	Dur. (sem)	Esf. (h-p)	Costo (S/)
5.4	Levantamiento de observaciones del asesor y correcciones finales	Documentación	1.5	24	600
5.5	Preparación del material de sustentación y ensayo de la defensa	Documentación	1.0	16	400
5.6	Sustentación de la tesis	Cierre	0.5	6	150
Total de mano de obra (esfuerzo del tesista)				634	15,850

La columna de costo de la tabla anterior corresponde a la valorización del esfuerzo del tesista (mano de obra), que asciende a S/ 15,850 sobre un esfuerzo total de 634 horas-persona. El presupuesto consolidado del proyecto que incorpora, además de la mano de obra, el equipamiento (por depreciación), el software y los servicios, se desarrolla en la sección A.10 (Costeo del Proyecto). La programación semanal detallada de estas tareas, con fechas de inicio y fin y dependencias, se presenta en la sección A.8 y en el archivo Excel adjunto.

● **Cronograma del proyecto**

El cronograma del proyecto programa las tareas de la sección anterior a lo largo de las 26 semanas comprendidas entre el lunes 1 de junio y finales de noviembre de 2026, correspondientes a la fase de desarrollo. Previamente, se realizaron reuniones semanales desde el 18 de febrero con el asesor del proyecto, con el objetivo de entender y definir el problema, investigar sobre técnicas de inteligencia artificial actuales aplicadas al contexto del trabajo y discutir posibles soluciones para el problema central; además, se validó en conjunto la estructuración y desarrollo de los capítulos 1, 2 y 3.

Para cada tarea se establecen su fecha de inicio y fin y sus dependencias; la duración programada incorpora holguras y, por construcción, es mayor o igual que la duración estimada de cada tarea. El detalle completo a nivel de tarea, con el desglose semanal en formato de diagrama de Gantt, las fechas, las dependencias y los hitos del proyecto, se presenta en el archivo Excel adjunto «*Cronograma_Detallado_Tesis.xlsx*». A modo de resumen, la siguiente matriz sintetiza la distribución temporal de las etapas a lo largo de los seis meses; las celdas marcadas indican los meses en que cada etapa se encuentra activa y los solapamientos reflejan el carácter iterativo del trabajo.

Etapas	Jun	Jul	Ago	Sep	Oct	Nov
Gestión del proyecto	■	■	■	■	■	■
OE2 – Dataset unificado (R3–R6)	■	■				

Etapas	Jun	Jul	Ago	Sep	Oct	Nov
OE1 – Entorno de simulación (R1, R2)		■	■			
OE3 – Entrenamiento y estudio comparativo (R7, R8)			■	■	■	
Documentación, correcciones y sustentación				■	■	■

● Lista de recursos

A continuación, se listan los recursos del proyecto indicando, para cada uno, su descripción, su cantidad y la oportunidad (fase) en que se emplean.

○ Personas involucradas y necesidades de capacitación

Persona / Rol	Cantidad	Oportunidad de uso
Tesista — Rodrigo A. Holguin Huari (desarrollador principal: análisis, implementación, experimentación y redacción)	1	Todas las fases
Asesor — Dr. Edwin R. Villanueva Talavera (orientación metodológica y revisión)	1	Reuniones semanales y revisión de entregables en todas las fases

Necesidades de capacitación: el proyecto se cubre mediante autoformación del tesista, sin necesidad de capacitación externa con costo. Las áreas a reforzar son el uso de FinRL y Stable-Baselines3, el ajuste de algoritmos DRL (PPO, DDPG y SAC), la ingeniería de prompts para la clasificación de sentimiento con LLM y las técnicas de recopilación (scraping) de noticias, todo ello a partir de la documentación oficial y de cursos en línea de acceso libre.

○ Estándares utilizados en el proyecto

Si bien el proyecto no se rige por estándares regulatorios formales, sí adopta estándares de facto, metodológicos y de la industria que aseguran la calidad, la reproducibilidad y la consistencia del trabajo:

Estándar	Tipo	Aplicación en el proyecto
CRISP-DM	De facto / proceso	Estructura el diseño del entorno y el trabajo con datos (OE1, OE2)

Estándar	Tipo	Aplicación en el proyecto
Interfaz OpenAI Gym / Gymnasium	De facto (RL)	Define la interfaz del entorno de simulación (OE1)
PEP 8	Industria (Python)	Estilo y legibilidad del código fuente
APA, 7.ª edición	Documentación	Citación y referencias del documento de tesis
ISO 8601	Internacional	Formato de fechas en la integración temporal del dataset (OE2)
Git / versionado	Buenas prácticas	Control de versiones del código y respaldos

○ Equipamiento requerido

Descripción	Cantidad	Oportunidad de uso
Laptop personal del tesista (estación de desarrollo)	1	Todas las fases: desarrollo, integración y redacción
Equipo de cómputo de la universidad: servidor/estación de trabajo de Deep Learning con tarjeta	1	Fase 3 (OE3): entrenamiento de agentes y backtesting (R7, R8)

○ Herramientas requeridas

Herramienta	Uso en el proyecto
Python 3.x	Lenguaje base de todo el desarrollo (todas las fases)
Pandas y NumPy	Manipulación e integración de datos (OE2, OE3)
PyTorch	Backend de aprendizaje profundo de los agentes (OE3)
OpenAI Gym / Gymnasium	Interfaz del entorno de simulación (OE1)
FinRL	Base del entorno de simulación adaptado a la BVL (OE1)
Stable-Baselines3	Implementación de los algoritmos PPO, DDPG y SAC (OE3)
Matplotlib y Seaborn	Visualización de los resultados (OE3)
MediaCloud	Recopilación de noticias financieras (OE2, R5)
LLM local vía Ollama (gemma3:4b)	Clasificación de sentimiento de noticias en español (OE2, R5)

Herramienta	Uso en el proyecto
APIs de la SMV y la BVL	Extracción de datos de mercado y fundamentales (OE2, R3 y R4)
Git y GitHub	Control de versiones y respaldo del código (todas las fases)
Jupyter / VS Code	Entorno de desarrollo y experimentación (todas las fases)

● Costeo del Proyecto

El costeo del proyecto consolida el costo económico total, distinto del gasto o desembolso efectivo. Se valoriza el equipo humano por horas-persona, el equipamiento por su depreciación durante el período de uso (no por su valor de adquisición) y el software bajo el criterio de costo total de propiedad (TCO); el software de código abierto no genera costo de licencia. La partida se presenta a un solo nivel, conforme a la plantilla del curso.

Ítem	Descripción	Unidad	Cantidad	Valor Unitario (S/.)	Monto Total (S/.)	Monto Acumulado (S/.)
0	Costo total del proyecto	—	—	—	—	S/ 21,777
1.	Recursos humanos	—	—	—	S/ 18,690	S/ 18,690
1.1	Tesista (análisis, implementación, experimentación y redacción)	Horas	634	25.00	S/ 15,850	
1.2	Asesor — Dr. Edwin Villanueva (orientación y revisión)	Horas	26	100.00	S/ 2,600	
1.3	Apoyo de alumno de maestría (código de extracción de EEFF)	Horas	8	30.00	S/ 240	
2.	Equipamiento (costo por uso — depreciación)	—	—	—	S/ 2,167	S/ 20,857
2.1	Laptop personal del tesista (S/ 4 000; vida útil 48 meses)	Mes	6	83.33	S/ 500	
2.2	Equipo de cómputo de la universidad — GPU 50 GB, 32 GB RAM (S/ 40 000; 48 meses)	Mes	2	833.33	S/ 1,667	
3.	Software y servicios (TCO / amortización)	—	—	—	S/ 0	S/ 20,857
3.1	Software de código abierto (Python, PyTorch, SB3, FinRL, Gym, MediaCloud, Gemma local, etc.)	Licencia	1	0.00	S/ 0	

Ítem	Descripción	Unidad	Cantidad	Valor Unitario (S/.)	Monto Total (S/.)	Monto Acumulado (S/.)
4.	Servicios e insumos operativos	—	—	—	S/ 620	S/ 21,477
4.1	Internet y energía eléctrica (porción atribuible)	Mes	6	70.00	S/ 420	
4.2	Materiales de oficina e impresiones	Global	1	100.00	S/ 100	
4.3	Empastado y materiales de sustentación	Global	1	100.00	S/ 100	

Costo total del proyecto: S/ 21,477. Conviene distinguir este costo económico del gasto (desembolso efectivo) que asume el tesista, estimado en alrededor de **S/ 620** (internet, energía, y materiales): el tiempo del tesista, las horas del asesor y el uso del equipo de cómputo de la universidad constituyen costos (contabilizados por valorización y depreciación) pero no representan un desembolso monetario directo.

Anexo B: Formulario de extracción



formulario_ext.xlsx